

La Variable Importance

*Bias e Correlazione nella Selezione di Variabili in
Random Forest*

AUTORI:

Francesco Faillace

Lorenzo Maria Pennelli

Eros Pinzani



UNIVERSITÀ
DEGLI STUDI
FIRENZE

Da un secolo, oltre.

Contesto: Random Forest

Algoritmi Ensembled-Tree che combinano Bagging con una selezione randomica dei predittori.

- **Bagging**

Tecnica che riduce la varianza di un modello statistico creando più sotto-alberi tramite **bootstrap** e **aggregando** i risultati per ottenere una previsione più stabile e accurata.

- **Feature subsampling**

Ad ogni split ciascun albero sceglie casualmente un sottoinsieme di predittori (**mtry**) da cui sceglie il migliore in modo da ridurre la correlazione e la varianza

Punti di Forza

- Robusto all'overfitting
- Gestisce variabili continue, categoriali e dati mancanti
- Forniscono una stima dell'errore di test (OOB error)
- Nessuna assunzione sulla distribuzione dei dati

Limitazioni

- Complesso da analizzare teoricamente
- Difficile da interpretare
- Costoso in memoria e in inferenza

Contesto: Variable Importance

È la misura del contributo specifico di ciascun predittore nel determinare il risultato della variabile target. Identifica quali fattori guidano maggiormente le previsioni del modello.

MDI — Mean Decrease Impurity

(Gini Importance)

Misura quanto ogni variabile contribuisce a ridurre l'impurezza all'interno dei nodi degli alberi. Per ogni variabile usata per uno split, si calcola di quanto diminuisce l'impurezza tra il nodo padre e i nodi figli.

Questo valore viene sommato e mediato su tutti gli alberi della foresta.

$$MDI(X_j) = \frac{1}{B} \sum_{b=1}^B \sum_{\substack{t \in T_b \\ v(t)=j}} p_b(t) \Delta i(t, X_j)$$

✓ Vantaggi

Calcolata a costo zero durante il training, non richiede dati aggiuntivi.

✗ Problema fondamentale

Bias sistematico verso variabili ad alta cardinalità, $E[MDI(X_j)] > 0$ anche se $X_j \perp Y$.
Il bias cresce col numero di valori distinti, indipendentemente dalla rilevanza reale.

MDA — Mean Decrease Accuracy

(Permutation Importance)

Misura l'importanza di una variabile osservando quanto peggiora l'accuratezza del modello se i suoi valori Out-of-Bag (OOB) vengono mescolati casualmente. Se l'accuratezza crolla, la variabile è fondamentale; se rimane invariata, la variabile è trascurabile.

$$MDA(X_j) = \frac{1}{B} \sum_{b=1}^B (Acc_b^{OOB} - Acc_{b,\pi_j}^{OOB})$$

✓ Meno sensibile alla cardinalità rispetto alla MDI

✗ Limitazioni

Con variabili correlate distribuisce l'importanza arbitrariamente tra variabili simili.
È più lento da calcolare.

Il bias della MDI: perché favorisce alta cardinalità

- **Più valori possibili = più opportunità di sembrare utile per caso.**


Le variabili continue offrono **centinaia di soglie** rispetto all'unico taglio di una binaria.

Questo eccesso di tentativi permette al **puro rumore** di simulare, per puro caso, una **soglia utile**.

- **Il feature subsampling amplifica il problema**


Ad ogni split si considerano solo **$m_{try} < p$ variabili**, una variabile ad alta cardinalità ha più probabilità di risultare la “migliore” nel sottoinsieme estratto per puro caso

Variabile binaria



1 soglia

Variabile continua



centinaia di soglie


Esperimento 1 — Bias MDI

Setup:

$n=600$, Y = rumore puro, 4 predittori tutti rumore con cardinalità crescente

Bias della MDI verso variabili ad alta cardinalità

Y è rumore puro — nessun predittore ha alcun legame con Y



Il problema della correlazione e l'instabilità

Cosa succede quando due predittori sono fortemente correlati?

Premessa

Entrambe le variabili sembrano ugualmente utili

- Con **p alta**, X_1 e X_2 producono quasi lo stesso guadagno di MSE
- La foresta **non distingue** quale sia davvero **causale**

Meccanismo

Chi vince dipende dal caso

- **Bootstrap** e **mtry** scelgono casualmente quale variabile è disponibile ad ogni split.
- La "vincitrice" accumula importanza per pura fortuna

Effetto

L'importanza si distribuisce arbitrariamente

- La **classifica** cambia ad ogni **run**, anche sugli stessi dati.


Esperimento 2 — L'effetto della Correlazione

Setup:

$p=12$ predittori - struttura AR(1) con $\rho=0.95$ - solo X_1 è causale - $n=150$ - 30 run con diversi seeds

Il paradosso della correlazione nelle variable importance

Distribuzione dell'importanza su 30 run ($n=150$, $p=12$, AR(1), $\rho=0.95$)



Possibile soluzione: Conditional Importance

Definizione

Estensione della MDA che permuta X_j rispetto alla sua distribuzione **condizionale** $X_j \mid Z$, anziché rispetto alla distribuzione marginale.

In questo modo isola il **contributo unico** di X_j al netto delle variabili correlate Z .

Meccanismo

Le **osservazioni OOB** vengono partizionate in base ai valori delle variabili **correlate Z** (sfrutta la struttura degli alberi).

X_j viene poi permutata esclusivamente all'interno di **ciascun gruppo**, preservando così la reale **struttura di dipendenza**.

$$\text{CPI}(X_j) = \frac{1}{B} \sum_{b=1}^B [\text{Acc}_b(\text{OOB}_b) - \text{Acc}_{b,\pi(Z)}(\text{OOB}_b)]$$

$$Z_j = \{X_k: |\hat{p}(X_j, X_k)| > \lambda\}$$

Proprietà

✓ Non distorta

Elimina il bias da cardinalità a livello di splitting.

$$E[\text{CPI}(X_j)] = 0 \text{ se } X_j \perp Y \mid Z$$

✓ Stabile con variabili correlate

Permutando dentro Z , l'importanza non viene distribuita arbitrariamente tra X_j e Z

✗ Implementazione: cforest (R)

Elevato costo computazionale

Esp. 3 — MDI vs Permutation vs Conditional Importance

Setup:

$p=12$ predittori - struttura AR(1) con $\rho=0.95$ - solo X_1 è causale - $n=150$ - output normalizzato

- MDI**

Distribuisce importanza su X_2 (≈ 0.6) e X_3 – X_4 (≈ 0.3).
Profilo 'sfumato'.

- Permutation**

Simile a MDI nelle prime posizioni, importanza residua su molte variabili lontane.

- Conditional**

Concentra ≈ 0.95 su X_1 . X_2 scende a ≈ 0.45 .
Tutto il resto vicino a zero. ✓

Confronto tra indici di importanza

Solo X_1 è causale — dati AR(1) con $\rho=0.95$




Esperimento 4 — Validazione Quantitativa

Setup:

$p=12$ predittori - struttura AR(1) con $\rho=0.95$ - X_1, X_4, X_7 sono causali - $n=100$

Scelte 3 variabili per simulare un caso più reale.

- **MDI (Inaffidabile e distorto):**
 - F1-score medio più basso (circa 35%).
 - Fortemente instabile (punti dispersi da 0% a 75%).
- **MDA (Migliore ma instabile):**
 - Netto salto predittivo con una mediana più alta (circa 60%).
 - Massima variabilità verticale (scatola molto ampia).
 - Risente della multicollinearità.
- **Conditional Importance:**
 - Garantisce la massima stabilità e consistenza.
 - La scatola è estremamente compatta e schiacciata sulla mediana (circa 66%): azzera i crolli verso il basso tipici di MDI e MDA.



Conclusioni - Riepilogo

Metodo	Bias cardinalità	Instabilità Correlazione	X ₁ identificata	Costo
MDI (randomForest)	Sì	Sì	Sì (instabile)	Basso
MDA (randomForest)	Parzialmente	Sì	Sì	Medio
Conditional Importance (cforest)	No	No	Sì	Alto

References

- Slides del corso riguardanti *Random Forest* e *Variable Importance*
- Strobl, C., Boulesteix, A.-L., Zeileis, A., Hothorn, T. (2007). *Bias in Random Forest Variable Importance Measures: Illustrations, Sources and a Solution*. *BMC Bioinformatics*, 8, 25.
- Strobl, C., Boulesteix, A.-L., Kneib, T., Augustin, T., Zeileis, A. (2008). *Conditional Variable Importance for Random Forests*. *BMC Bioinformatics*, 9, 307.
- <https://erwanscornet.github.io/talks/mdi.pdf>
- Claude per aiuto sul codice e impaginazione slide