

Feature Selection Prima della CV

Come una Procedura Innocente Invalida l'Intera Analisi

Eros Pinzani

Contents

1	Setup	1
1.1	Pacchetti	1
1.2	Parametri Globali	2
2	Background Teorico	3
2.1	Il Data Generating Process	3
2.2	Il Meccanismo del Leakage	3
2.3	Collegamento all'Ottimismo del Corso	4
2.4	Derivazione Teorica: perché l'ottimismo cresce come $\sqrt{2\log p/n}$	4
3	Funzioni Principali	5
4	Esperimento 1 — Dimostrazione Base	9
4.1	Il Risultato ($n = 200$, $p = 500$, $k = 20$)	9
4.2	Heatmap dell'Ottimismo $f(n, p)$ a $k = 20$	12
4.3	L'Effetto di k	14
5	Esperimento 2 — Validazione della Previsione Teorica	16
6	Esperimento 3: Robustezza con Predittori Correlati	19
6.1	Struttura AR(1)	19
7	Esperimento 4 — Il Problema è Architettureale: il Criterio di Selezione Non Conta	21
7.1	Approfondimento: perché usare $ \hat{\beta}_{\text{Ridge}} $ e non $ \hat{\beta}_{\text{Lasso}} $ come criterio di ranking	21
8	Conclusioni	26
8.1	Tre messaggi da portare a casa	26
8.2	Questa non è teoria accademica	27

1 Setup

1.1 Pacchetti

```
# Lista dei pacchetti necessari
pkgs <- c("glmnet", "ggplot2", "dplyr", "tidyr",
          "patchwork", "reshape2", "scales", "MASS")

# Installazione automatica solo dei pacchetti mancanti
to_install <- pkgs[!pkgs %in% installed.packages()[, "Package"]]
```

```

if (length(to_install) > 0) {
  repos <- getOption("repos")
  if (is.null(repos) || identical(repos[["CRAN"]], "@CRAN@") || is.na(repos[["CRAN"]])) {
    repos[["CRAN"]] <- "https://cloud.r-project.org"
    options(repos = repos)
  }
  install.packages(to_install, dependencies = TRUE, quiet = TRUE)
}

suppressPackageStartupMessages({
  library(glmnet)      # Lasso e Elastic Net
  library(ggplot2)     # visualizzazioni
  library(dplyr)       # manipolazione dati
  library(tidyr)       # pivoting e reshaping
  library(patchwork)   # composizione di grafici multipli
  library(reshape2)    # melt per le heatmap
  library(scales)      # scala colori nei grafici
  library(MASS)        # murnorm per predittori correlati
})

theme_set(theme_bw(base_size = 11))

```

1.2 Parametri Globali

```

# =====
# QUICK_RUN = TRUE → risultati rapidi (pochi minuti)
#                               indicato per sviluppo e test
# QUICK_RUN = FALSE → analisi completa (15-30 minuti)
#                               usare prima della presentazione finale
# =====
QUICK_RUN <- FALSE

# Numero di simulazioni Monte Carlo
B <- if (QUICK_RUN) 30 else 100
# Fold per la cross-validation esterna
FOLDS <- 10
# Fold per la CV interna del Ridge (Esperimento 4)
FOLDS_INNER <- 5
# Seed master per riproducibilità (seed per la b-esima run = SEED + b)
SEED <- 2025

# k dedicato alla validazione teorica (Esperimento 2).
# Deve soddisfare  $k \ll p$  per ogni punto della griglia: la derivazione
# asintotica del massimo di  $p$  normali assume che si stia cercando il
# massimo su un pool molto più grande dei  $k$  selezionati.
# Con  $grid\_p\_min = 20$  e  $k\_theory = 5$  il rapporto minimo  $p/k$  è 4,
# sufficiente perché l'approssimazione sia valida in tutta la griglia.
k_theory <- 5

# Griglia di parametri per la heatmap (Esperimento 1) e la
# validazione teorica (Esperimento 2)
if (QUICK_RUN) {
  grid_n <- c(50, 200, 500)

```

```

grid_p <- c(20, 100, 500)
} else {
  grid_n <- c(50, 100, 200, 500)
  grid_p <- c(20, 50, 100, 200, 500)
}

cat("Configurazione:", if (QUICK_RUN) "QUICK (B =", "FULL (B =", B,
  "| grid n:", paste(grid_n, collapse = ","),
  "| grid p:", paste(grid_p, collapse = ","), ")\n")

```

```
## Configurazione: FULL (B = 100 | grid n: 50,100,200,500 | grid p: 20,50,100,200,500 )
```

2 Background Teorico

2.1 Il Data Generating Process

In **tutti** gli esperimenti di questo notebook adottiamo un DGP in cui non esiste **nessun segnale predittivo**:

$$X_j \stackrel{\text{iid}}{\sim} \mathcal{N}(0, 1), \quad j = 1, \dots, p$$

$$Y \sim \text{Bernoulli}(0.5), \quad Y \perp X_1, \dots, X_p$$

Qualsiasi AUC significativamente superiore a 0.5 non riflette una capacità predittiva reale: è un **artefatto della procedura di analisi**.

Nota sul DGP: Y è binaria perché usiamo l’AUC come metrica di valutazione, che è definita per classificatori. Un DGP con Y continua e RMSE come metrica produrrebbe lo stesso fenomeno, ma l’AUC è più drammaticamente comunicabile — un valore di 0.85 in un contesto di classificazione è inequivocabilmente interpretato come “il modello funziona bene”.

2.2 Il Meccanismo del Leakage

La cross-validation simula il caso in cui un modello viene addestrato su certi dati e valutato su dati **mai visti**. L’ipotesi fondamentale è che il validation set sia completamente ignoto durante la fase di training.

Quando si selezionano le variabili **prima** del loop di CV, questa ipotesi viene violata silenziosamente:

La selezione delle top- k variabili usa la correlazione di ogni X_j con Y calcolata sull’**intero dataset** — incluse le osservazioni che finiranno nel validation set.

Le variabili selezionate non sono quelle davvero correlate con Y nella popolazione (non ce ne sono, per costruzione), ma quelle che per **puro caso** mostrano la correlazione campionaria più alta con Y in quel campione specifico. La CV valuta il modello come se queste variabili fossero scelte in modo “onesto”, ma non lo sono.

Pipeline errata:

1. Calcola $\text{cor}(X_j, Y)$ per tutti i p predittori sull’**INTERO dataset**
2. Seleziona i top- k per valore assoluto della correlazione
3. Applica 10-fold CV sul modello con i k predittori selezionati ← troppo tardi

Pipeline corretta:

Per ogni fold $f = 1, \dots, 10$:

1. Usa SOLO il training fold per calcolare $\text{cor}(X_j, Y_{\text{train}})$
2. Seleziona i top-k ← la selezione non vede mai il validation set
3. Fitta il modello sul training fold con i k predittori selezionati
4. Valuta sul validation fold f

2.3 Collegamento all'Ottimismo del Corso

Il termine di ottimismo dell'errore di training, derivato a lezione, è:

$$\text{Opt} = \frac{2}{n} \sum_{i=1}^n \text{Cov}(Y_i, \hat{Y}_i)$$

Questo termine misura quanto le predizioni $\hat{Y}_i$ sono artificialmente vicine alle Y_i su cui il modello viene poi valutato. Nella pipeline corretta, il modello non ha mai visto le Y_i del validation set, quindi la covarianza per quelle osservazioni è piccola.

Nella pipeline errata, le k variabili selezionate sono state scelte **perché** covariavano con Y sull'intero dataset. I fitted values $\hat{Y}_i = \hat{\beta}^\top x_i$ sono costruiti su predittori già “ottimizzati” rispetto alle stesse Y_i su cui vengono valutati:

$$\text{Cov}(Y_i, \hat{Y}_i) \Big|_{\text{pipeline errata}} \gg \text{Cov}(Y_i, \hat{Y}_i) \Big|_{\text{pipeline corretta}}$$

Il termine di ottimismo viene inflazionato non dall'overfitting del modello, ma dalla **pre-selezione delle variabili**. La CV non può vederlo perché è avvenuto prima del loop.

2.4 Derivazione Teorica: perché l'ottimismo cresce come $\sqrt{2 \log p / n}$

Questa sezione costruisce la previsione teorica che verrà poi confrontata con le simulazioni nell'Esperimento 2.

Passo 1 — Distribuzione della correlazione campionaria sotto H_0 .

Definiamo la correlazione campionaria punto-biserial tra X_j e Y :

$$r_j = \frac{\sum_{i=1}^n (x_{ij} - \bar{x}_j)(y_i - \bar{y})}{(n-1) s_j s_y}$$

Nota tecnica: con Y binaria e X_j continua, questa è formalmente la correlazione punto-biserial, che coincide algebricamente con la correlazione di Pearson ed ha la medesima struttura asintotica sotto indipendenza.

Sotto H_0 : $X_j \perp Y$, per il Teorema Centrale del Limite applicato al prodotto di due variabili indipendenti a media zero:

$$\sqrt{n} r_j \xrightarrow{d} \mathcal{N}(0, 1)$$

ovvero $r_j \approx \mathcal{N}(0, 1/n)$ per n sufficientemente grande.

Passo 2 — Distribuzione del massimo di p correlazioni.

Se $r_1, \dots, r_p$ sono approssimativamente i.i.d. $\mathcal{N}(0, 1/n)$, i valori standardizzati $Z_j = \sqrt{n} r_j$ sono approssimativamente i.i.d. $\mathcal{N}(0, 1)$.

Per un risultato classico sulle statistiche d'ordine delle normali standard, il massimo in valore assoluto di p variabili i.i.d. $\mathcal{N}(0, 1)$ si concentra attorno a:

$$E\left[\max_{j=1}^p |Z_j|\right] \approx \sqrt{2 \log p}$$

Derivazione informale: cerchiamo t^* tale che $P(\max_j |Z_j| > t^*) \approx \frac{1}{2}$. Applicando l'union bound e l'approssimazione di Mills $1 - \Phi(t) \approx \phi(t)/t$ per t grande:

$$p \cdot 2(1 - \Phi(t^*)) \approx \frac{1}{2} \implies \frac{2p \phi(t^*)}{t^*} \approx \frac{1}{2} \implies t^{*2} \approx 2 \log p$$

Passo 3 — Previsione dell'ottimismo.

Riportando alla scala originale delle correlazioni (dividendo per $\sqrt{n}$):

$$\max_{j=1}^p |r_j| \approx \sqrt{\frac{2 \log p}{n}}$$

La variabile “migliore” tra p candidate, per puro caso, ha correlazione campionaria con Y pari a circa $\sqrt{2 \log p / n}$. Selezionando le top- k su questa base e costruendo un classificatore, l'ottimismo in AUC è proporzionale a questo valore.

Esempio numerico: per $n = 200$, $p = 500$, $k = 20$:

$$\sqrt{\frac{2 \log 500}{200}} \approx \sqrt{\frac{2 \times 6.21}{200}} \approx \sqrt{0.062} \approx 0.25$$

Una correlazione campionaria di 0.25 su puro rumore è sufficiente per portare l'AUC stimato dalla CV dal suo valore teorico di 0.50 a valori vicini a 0.85.

3 Funzioni Principali

```
# =====
# FUNZIONE 1: Calcolo dell'AUC (metodo rank-based / Wilcoxon)
#
# Equivalente alla statistica U di Wilcoxon-Mann-Whitney:
# P(score di un positivo > score di un negativo)
# Non richiede pacchetti esterni ed è numericamente stabile.
# =====
compute_auc <- function(y_true, y_prob) {
  y_true <- as.integer(y_true)
  n1 <- sum(y_true == 1)
  n0 <- sum(y_true == 0)
  # Casi degeneri: se un solo fold non ha positivi o negativi
  if (n1 == 0 || n0 == 0) return(NA_real_)
  r <- rank(y_prob, ties.method = "average")
  (sum(r[y_true == 1]) - n1 * (n1 + 1) / 2) / (n1 * n0)
}

# =====
# FUNZIONE 2: CV con pipeline ERRATA (leakage)
#
# La feature selection avviene FUORI dal loop di CV:
```

```

# le correlazioni vengono calcolate sull'intero dataset,
# incluse le osservazioni che finiranno nel validation set.
# Questo è il difetto strutturale che produce AUC inflazionato.
# =====
cv_auc_leaky <- function(X, y, k, n_folds = 10) {
  n <- nrow(X)
  # Assegna nomi espliciti alle colonne: quando R converte una
  # matrice indicizzata in data.frame usa il deparse dell'espressione
  # come prefisso (es. "X_sel.tr..." vs "X_sel.te..."), producendo
  # nomi diversi tra train e test e rompendo predict().
  # Assegnare nomi fissi risolve il problema alla radice.
  colnames(X) <- paste0("x", seq_len(ncol(X)))

  # === BUG: selezione delle top-k usando TUTTO il dataset ===
  cors <- abs(cor(X, y)) # correlazione punto-biserial
  top_k <- order(cors, decreasing = TRUE)[1:k]
  X_sel <- X[, top_k, drop = FALSE] # sottomatrice con le k variabili "migliori"
  # =====

  # CV sul modello con le variabili già selezionate
  folds <- sample(rep(seq_len(n_folds), length.out = n))
  aucs <- numeric(n_folds)

  for (f in seq_len(n_folds)) {
    tr_idx <- which(folds != f)
    te_idx <- which(folds == f)

    df_tr <- data.frame(y = y[tr_idx], X_sel[tr_idx, , drop = FALSE])
    df_te <- as.data.frame(X_sel[te_idx, , drop = FALSE])

    fit <- tryCatch(
      glm(y ~ ., data = df_tr, family = binomial()),
      error = function(e) NULL
    )
    if (is.null(fit)) { aucs[f] <- 0.5; next }

    probs <- predict(fit, newdata = df_te, type = "response")
    aucs[f] <- compute_auc(y[te_idx], probs)
  }
  mean(aucs, na.rm = TRUE)
}

# =====
# FUNZIONE 3: CV con pipeline CORRETTA
#
# La feature selection avviene DENTRO ogni fold:
# le correlazioni vengono calcolate solo sul training fold,
# senza mai "vedere" le osservazioni di validazione.
# =====
cv_auc_correct <- function(X, y, k, n_folds = 10) {
  n <- nrow(X)
  # Stessa ragione di cv_auc_leaky: nomi espliciti per coerenza
  # tra i data.frame di training e test in ogni fold.

```

```

colnames(X) <- paste0("x", seq_len(ncol(X)))
folds <- sample(rep(seq_len(n_folds), length.out = n))
aucs <- numeric(n_folds)

for (f in seq_len(n_folds)) {
  tr_idx <- which(folds != f)
  te_idx <- which(folds == f)

  # === CORRETTO: selezione solo sul training fold ===
  cors <- abs(cor(X[tr_idx, ], y[tr_idx]))
  top_k <- order(cors, decreasing = TRUE)[1:k]
  # =====

  X_tr_sel <- X[tr_idx, top_k, drop = FALSE]
  X_te_sel <- X[te_idx, top_k, drop = FALSE]

  df_tr <- data.frame(y = y[tr_idx], X_tr_sel)
  df_te <- as.data.frame(X_te_sel)

  fit <- tryCatch(
    glm(y ~ ., data = df_tr, family = binomial()),
    error = function(e) NULL
  )
  if (is.null(fit)) { aucs[f] <- 0.5; next }

  probs <- predict(fit, newdata = df_te, type = "response")
  aucs[f] <- compute_auc(y[te_idx], probs)
}
mean(aucs, na.rm = TRUE)
}

# =====
# FUNZIONE 4: Embedded Filter - Ridge Importance
#
# Usa |^Ridge| come criterio di ranking delle feature.
# Pipeline ERRATA: il ranking usa tutto il dataset (incluse le
# osservazioni che finiranno nel validation set).
# =====
ridge_filter_wrong <- function(X, y, k, n_folds = 10) {
  n <- nrow(X)
  colnames(X) <- paste0("x", seq_len(ncol(X)))

  # === BUG: Ridge fit sull'INTERO dataset per ottenere i pesi ===
  cv_full <- cv.glmnet(X, y, family = "binomial",
    type.measure = "auc", alpha = 0,
    nfolds = n_folds)
  coef_full <- as.numeric(coef(cv_full, s = "lambda.min"))[-1]
  top_k <- order(abs(coef_full), decreasing = TRUE)[1:k]
  X_sel <- X[, top_k, drop = FALSE]
  # =====

  folds <- sample(rep(seq_len(n_folds), length.out = n))
  aucs <- numeric(n_folds)

```

```

for (f in seq_len(n_folds)) {
  tr_idx <- which(folds != f)
  te_idx <- which(folds == f)
  df_tr <- data.frame(y = y[tr_idx], X_sel[tr_idx, , drop = FALSE])
  df_te <- as.data.frame(X_sel[te_idx, , drop = FALSE])
  fit <- tryCatch(
    glm(y ~ ., data = df_tr, family = binomial()),
    error = function(e) NULL
  )
  if (is.null(fit)) { aucs[f] <- 0.5; next }
  probs <- predict(fit, newdata = df_te, type = "response")
  aucs[f] <- compute_auc(y[te_idx], probs)
}
mean(aucs, na.rm = TRUE)
}

```

```

# =====
# FUNZIONE 5: Embedded Filter - Ridge Importance
#               Pipeline CORRETTA (nested CV)
#
# Per ogni fold esterno:
# 1. cv.glmnet(alpha=0) solo sul training fold + e pesi
# 2. Seleziona top-k per |^| + mai visto il validation fold
# 3. Logit su training, valuta sul validation fold
# =====
ridge_filter_correct <- function(X, y, k, n_folds = 10,
                                n_folds_inner = 5) {
  n <- nrow(X)
  colnames(X) <- paste0("x", seq_len(ncol(X)))

  folds <- sample(rep(seq_len(n_folds), length.out = n))
  aucs <- numeric(n_folds)
  for (f in seq_len(n_folds)) {
    tr_idx <- which(folds != f)
    te_idx <- which(folds == f)

    # === CORRETTO: Ridge fit SOLO sul training fold ===
    cv_tr <- tryCatch(
      cv.glmnet(X[tr_idx, ], y[tr_idx], family = "binomial",
        type.measure = "auc", alpha = 0,
        nfolds = n_folds_inner),
      error = function(e) NULL
    )
    if (is.null(cv_tr)) { aucs[f] <- 0.5; next }
    coef_tr <- as.numeric(coef(cv_tr, s = "lambda.min"))[-1]
    top_k <- order(abs(coef_tr), decreasing = TRUE)[1:k]
    # =====

    X_tr_sel <- X[tr_idx, top_k, drop = FALSE]
    X_te_sel <- X[te_idx, top_k, drop = FALSE]
    df_tr <- data.frame(y = y[tr_idx], X_tr_sel)
    df_te <- as.data.frame(X_te_sel)
    fit <- tryCatch(

```



```

    glm(y ~ ., data = df_tr, family = binomial()),
    error = function(e) NULL
  )
  if (is.null(fit)) { aucs[f] <- 0.5; next }
  probs <- predict(fit, newdata = df_te, type = "response")
  aucs[f] <- compute_auc(y[te_idx], probs)
}
mean(aucs, na.rm = TRUE)
}

# =====
# GENERATORI DI DATI
# =====

# Predittori i.i.d.  $N(0,1)$ : baseline degli Esperimenti 1-4
gen_iid <- function(n, p) matrix(rnorm(n * p), n, p)

# Predittori con struttura AR(1): correlazione  $\rho^{|i-j|}$ 
# Simulazione sequenziale efficiente:  $X[j] = \rho * X[j-1] + \text{eps}$ 
gen_ar1 <- function(n, p, rho) {
  X <- matrix(0, n, p)
  X[, 1] <- rnorm(n)
  sd_innov <- sqrt(1 - rho^2) # varianza dell'innovazione
  for (j in 2:p) {
    X[, j] <- rho * X[, j - 1] + rnorm(n, sd = sd_innov)
  }
  X
}

```

4 Esperimento 1 — Dimostrazione Base

Questo esperimento risponde alla domanda fondamentale: *quanto è grande il leakage in uno scenario realistico?*

Fissa i parametri al caso di riferimento ($n = 200$, $p = 500$, $k = 20$) e misura l'AUC stimato dalla CV con pipeline errata e corretta su 100 run Monte Carlo. La terza dimensione di analisi è la heatmap che mostra come l'ottimismo varia al variare di n e p a $k = 20$ fisso.

4.1 Il Risultato ($n = 200$, $p = 500$, $k = 20$)

```

# Parametri del caso di riferimento
n_exp1 <- 200; p_exp1 <- 500; k_exp1 <- 20

# Monte Carlo: B run con seed diversi per riproducibilità
res_exp1 <- matrix(NA, B, 2, dimnames = list(NULL, c("leaky", "correct")))

for (b in seq_len(B)) {
  set.seed(SEED + b)
  X <- gen_iid(n_exp1, p_exp1)
  y <- rbinom(n_exp1, 1, 0.5) #  $Y \sim \text{Bernoulli}(0.5)$ , indep. da  $X$ 
}

```

```

res_exp1[b, "leaky"] <- cv_auc_leaky(X, y, k = k_exp1, n_folds = FOLDS)
res_exp1[b, "correct"] <- cv_auc_correct(X, y, k = k_exp1, n_folds = FOLDS)

if (b %% 10 == 0) cat("  Run", b, "/", B, "\n")
}

##  Run 10 / 100
##  Run 20 / 100
##  Run 30 / 100
##  Run 40 / 100
##  Run 50 / 100
##  Run 60 / 100
##  Run 70 / 100
##  Run 80 / 100
##  Run 90 / 100
##  Run 100 / 100

# Statistiche riassuntive
cat("\n--- Risultati Esperimento 1 (n=200, p=500, k=20, B=", B, "run) ---\n")

##
## --- Risultati Esperimento 1 (n=200, p=500, k=20, B= 100 run) ---
cat("AUC pipeline ERRATA : media =", round(mean(res_exp1[, "leaky"]), 3),
    " | sd =", round(sd(res_exp1[, "leaky"]), 3), "\n")

## AUC pipeline ERRATA : media = 0.808 | sd = 0.027
cat("AUC pipeline CORRETTA: media =", round(mean(res_exp1[, "correct"]), 3),
    " | sd =", round(sd(res_exp1[, "correct"]), 3), "\n")

## AUC pipeline CORRETTA: media = 0.507 | sd = 0.062
cat("Ottimismo medio (AUC_errata - AUC_corretta):",
    round(mean(res_exp1[, "leaky"]) - mean(res_exp1[, "correct"]), 3), "\n")

## Ottimismo medio (AUC_errata - AUC_corretta): 0.3

# Preparazione dati in formato long per ggplot2
df_exp1 <- data.frame(res_exp1) |>
  pivot_longer(everything(), names_to = "pipeline", values_to = "auc") |>
  mutate(pipeline = factor(pipeline,
                           levels = c("leaky", "correct"),
                           labels = c("Pipeline Errata", "Pipeline Corretta")))

p_exp1_plot <- ggplot(df_exp1, aes(x = pipeline, y = auc, fill = pipeline)) +
  geom_boxplot(width = 0.5, outlier.size = 1.5, alpha = 0.85) +
  geom_hline(yintercept = 0.5, linetype = "dashed", linewidth = 0.8,
             color = "grey30") +
  annotate("text", x = 0.46, y = 0.46, label = "AUC casuale",
           size = 3.2, color = "grey30", hjust = 0.5) +
  scale_fill_manual(values = c("Pipeline Errata" = "#e74c3c",
                               "Pipeline Corretta" = "#2ecc71")) +
  scale_y_continuous(limits = c(0.40, 1.00), breaks = seq(0.4, 1.0, 0.1)) +
  labs(
    title = "Pipeline Errata vs Pipeline Corretta",
    subtitle = paste0("n = 200, p = 500, k = 20 | B = ", B,

```

```


      " run Monte Carlo"),
  x = NULL, y = "AUC stimato dalla 10-fold CV",
  caption = "La linea tratteggiata indica AUC = 0.50 (classificatore casuale)"
) +
theme(legend.position = "none",
      plot.title      = element_text(face = "bold"),
      plot.subtitle   = element_text(size = 9, color = "grey40"))

print(p_exp1_plot)

```

Pipeline Errata vs Pipeline Corretta

$n = 200$, $p = 500$, $k = 20$ | $B = 100$ run Monte Carlo



La linea tratteggiata indica $AUC = 0.50$ (classificatore casuale)

La figura mostra il risultato centrale del progetto: le due distribuzioni di AUC **non si sovrappongono quasi per niente**, nonostante i dati siano puro rumore per costruzione.

4.2 Heatmap dell'Ottimismo $f(n, p)$ a $k = 20$

```
# Griglia completa: per ogni  $(n, p)$  calcola l'ottimismo medio su  $B$  run  
# L'ottimismo è definito come  $AUC_{errata} - 0.50$   
# (usiamo 0.50 come baseline teorica invece di  $AUC_{correct}$  per  
# separare l'effetto del leakage dalla varianza del CV)
```

```

grid_params <- expand.grid(n = grid_n, p = grid_p)
grid_params$ottimismo <- NA

for (i in seq_len(nrow(grid_params))) {
  ni <- grid_params$n[i]; pi <- grid_params$p[i]
  auc_vals <- numeric(B)
  for (b in seq_len(B)) {
    set.seed(SEED + b * 1000 + i)
    X <- gen_iid(ni, pi)
    y <- rbinom(ni, 1, 0.5)
    auc_vals[b] <- cv_auc_leaky(X, y, k = 20, n_folds = FOLDS)
  }
  grid_params$ottimismo[i] <- mean(auc_vals, na.rm = TRUE) - 0.50
  cat("  n =", ni, "p =", pi,
      "| ottimismo medio =", round(grid_params$ottimismo[i], 3), "\n")
}

```

```

##  n = 50 p = 20 | ottimismo medio = 0.006
##  n = 100 p = 20 | ottimismo medio = 0.007
##  n = 200 p = 20 | ottimismo medio = 0.001
##  n = 500 p = 20 | ottimismo medio = 0.002

##  n = 50 p = 50 | ottimismo medio = 0.168
##  n = 100 p = 50 | ottimismo medio = 0.165
##  n = 200 p = 50 | ottimismo medio = 0.138
##  n = 500 p = 50 | ottimismo medio = 0.088

##  n = 50 p = 100 | ottimismo medio = 0.235
##  n = 100 p = 100 | ottimismo medio = 0.255
##  n = 200 p = 100 | ottimismo medio = 0.195
##  n = 500 p = 100 | ottimismo medio = 0.132

##  n = 50 p = 200 | ottimismo medio = 0.301
##  n = 100 p = 200 | ottimismo medio = 0.3
##  n = 200 p = 200 | ottimismo medio = 0.252
##  n = 500 p = 200 | ottimismo medio = 0.171

##  n = 50 p = 500 | ottimismo medio = 0.375
##  n = 100 p = 500 | ottimismo medio = 0.333
##  n = 200 p = 500 | ottimismo medio = 0.305
##  n = 500 p = 500 | ottimismo medio = 0.213

```

```

p_heat <- ggplot(grid_params,
  aes(x = factor(p), y = factor(n), fill = ottimismo)) +
  geom_tile(color = "white", linewidth = 0.5) +
  geom_text(aes(label = round(ottimismo, 2)), size = 3.5,
    color = "white", fontface = "bold") +
  scale_fill_gradient2(
    low = "#f0f4f8",
    mid = "#f39c12",
    high = "#c0392b",
    midpoint = 0.15,
    name = "AUC - 0.50",
    limits = c(0, NA),
    labels = scales::number_format(accuracy = 0.01)
  )


```

```

) +
labs(
  title = "Ottimismo del leakage: AUC stimato - 0.50",
  subtitle = paste0("k = 20 variabili selezionate | B = ", B,
    " run Monte Carlo | DGP: Y ~ X1,...,X"),
  x = "p (numero di predittori disponibili)",
  y = "n (dimensione campionaria)",
  caption = "Zone rosse = rischio elevato (p grande, n piccolo)"
) +
theme(plot.title = element_text(face = "bold"),
  plot.subtitle = element_text(size = 9, color = "grey40"))

print(p_heat)

```



La heatmap mostra come il rischio sia concentrato nell'angolo **alto-p** / **basso-n**: con molti predittori e pochi dati, la procedura errata produce stime completamente fasulle. Le coordinate di dataset biomedici comuni (es. microarray: $n \approx 50$, $p \approx 1000$) cadono sistematicamente nella zona rossa.

4.3 L'Effetto di k

```

# A parità di n=200, p=500, come cambia l'ottimismo al variare di k?
k_vals <- c(5, 10, 20, 50, 100, 200)
res_k <- data.frame(k = k_vals, ottimismo = NA, sd = NA)

for (i in seq_along(k_vals)) {
  ki <- k_vals[i]
  aucs_k <- numeric(B)
  for (b in seq_len(B)) {
    set.seed(SEED + b + i * 10000)
    X <- gen_iid(200, 500)
    y <- rbinom(200, 1, 0.5)
    aucs_k[b] <- cv_auc_leaky(X, y, k = ki, n_folds = FOLDS)
  }
}

```

```


res_k$ottimismo[i] <- mean(aucs_k, na.rm = TRUE) - 0.50
res_k$sd[i] <- sd(aucs_k, na.rm = TRUE)
cat(" k =", ki, "| AUC medio =",
    round(mean(aucs_k, na.rm = TRUE), 3),
    "| ottimismo =", round(res_k$ottimismo[i], 3), "\n")
}

## k = 5 | AUC medio = 0.722 | ottimismo = 0.222
## k = 10 | AUC medio = 0.767 | ottimismo = 0.267
## k = 20 | AUC medio = 0.804 | ottimismo = 0.304
## k = 50 | AUC medio = 0.773 | ottimismo = 0.273
## k = 100 | AUC medio = 0.727 | ottimismo = 0.227
## k = 200 | AUC medio = 0.524 | ottimismo = 0.024

p_k <- ggplot(res_k, aes(x = factor(k), y = ottimismo)) +
  geom_col(fill = "#e74c3c", alpha = 0.85, width = 0.5) +
  geom_errorbar(aes(ymin = ottimismo - sd, ymax = ottimismo + sd),
    width = 0.15, linewidth = 0.7) +
  labs(
    title = "Ottimismo al variare di k (variabili selezionate)",
    subtitle = "n = 200, p = 500 | DGP: Y ~ X1,...,X500",
    x = "k (numero di variabili selezionate)",
    y = "Ottimismo medio (AUC - 0.50)",
    caption = "Barre di errore = ±1 deviazione standard tra le run"
  ) +
  theme(plot.title = element_text(face = "bold"),
    plot.subtitle = element_text(size = 9, color = "grey40"))

print(p_k)

```



L'ottimismo cresce inizialmente con k , raggiunge un picco, e poi decresce: selezionare molte variabili rumore a bassa correlazione aggiunge più rumore alla stima dei coefficienti che segnale spurio. C'è un k ottimale — intorno a 20 in questo scenario — che massimizza l'artefatto. Questo riflette il trade-off bias-varianza

applicato alla dimensione del feature set.

5 Esperimento 2 — Validazione della Previsione Teorica

La Sezione 2.4 ha derivato che il massimo della correlazione campionaria sotto H_0 cresce come $\sqrt{2 \log p/n}$. Qui verifichiamo se questa previsione teorica **predice quantitativamente** l'ottimismo osservato nelle simulazioni.

Nota metodologica sulla scelta di k per questo esperimento. La formula $\sqrt{2 \log p/n}$ descrive il valore atteso del massimo di p correlazioni campionarie i.i.d. sotto H_0 : è una previsione sul *comportamento estremo* quando si cercano le top- k variabili in un pool di dimensione p . L'approssimazione è valida nel regime $p \gg k$, ossia quando il pool da cui si seleziona è molto più grande del sottoinsieme scelto.

Nell'Esperimento 1 abbiamo usato $k = 20$ per massimizzare la drammaticità del risultato ($n = 200$, $p = 500$). Tuttavia, la griglia di validazione include anche $p = 20$: con $k = 20$ e $p = 20$ si avrebbe $p = k$, ovvero la selezione includerebbe **tutti** i predittori disponibili e non avverrebbe nessuna vera selezione. In quel caso l'ottimismo è zero per costruzione, ma la formula teorica predice un valore non nullo — un punto degenero che rompe la relazione lineare e abbassa artificialmente l' R^2 .

Per questa ragione, la validazione teorica utilizza $k = k_{\text{theory}} = 5$, che garantisce un rapporto $p/k \geq 4$ per ogni cella della griglia (il minimo è $p = 20$, $k = 5$). Questo mantiene la griglia invariata e preserva la comparabilità visiva con la heatmap dell'Esperimento 1, correggendo al contempo il problema di specificazione del modello teorico.

```
# Per la validazione teorica non riusciamo grid_params (calcolata con k=20)
# perché include p=20 con k=20, un caso degenero in cui p=k e non avviene
# nessuna vera selezione. Ricalcoliamo una griglia dedicata con k=k_theory.
grid_theory <- expand.grid(n = grid_n, p = grid_p)
grid_theory$ottimismo <- NA
```

```
for (i in seq_len(nrow(grid_theory))) {
  ni <- grid_theory$n[i]; pi <- grid_theory$p[i]
  auc_vals <- numeric(B)
  for (b in seq_len(B)) {
    set.seed(SEED + b * 2000 + i)
    X <- gen_iid(ni, pi)
    y <- rbinom(ni, 1, 0.5)
    auc_vals[b] <- cv_auc_leaky(X, y, k = k_theory, n_folds = FOLDS)
  }
  grid_theory$ottimismo[i] <- mean(auc_vals, na.rm = TRUE) - 0.50
  cat("  n =", ni, "p =", pi,
      "| ottimismo medio =", round(grid_theory$ottimismo[i], 3), "\n")
}
```

```
##  n = 50 p = 20 | ottimismo medio = 0.206
##  n = 100 p = 20 | ottimismo medio = 0.149
##  n = 200 p = 20 | ottimismo medio = 0.097
##  n = 500 p = 20 | ottimismo medio = 0.062
##  n = 50 p = 50 | ottimismo medio = 0.276
##  n = 100 p = 50 | ottimismo medio = 0.191
##  n = 200 p = 50 | ottimismo medio = 0.146
##  n = 500 p = 50 | ottimismo medio = 0.094
##  n = 50 p = 100 | ottimismo medio = 0.307
##  n = 100 p = 100 | ottimismo medio = 0.239
```



```

## n = 200 p = 100 | ottimismo medio = 0.168
## n = 500 p = 100 | ottimismo medio = 0.111

## n = 50 p = 200 | ottimismo medio = 0.341
## n = 100 p = 200 | ottimismo medio = 0.259
## n = 200 p = 200 | ottimismo medio = 0.191
## n = 500 p = 200 | ottimismo medio = 0.124

## n = 50 p = 500 | ottimismo medio = 0.368
## n = 100 p = 500 | ottimismo medio = 0.298
## n = 200 p = 500 | ottimismo medio = 0.222
## n = 500 p = 500 | ottimismo medio = 0.144

theory_df <- grid_theory |>
  mutate(
    teorico = sqrt(2 * log(p) / n),
    label = paste0("(", n, ", ", p, ")")
  )

lm_fit <- lm(ottimismo ~ 0 + teorico, data = theory_df)
r_sq <- cor(theory_df$teorico, theory_df$ottimismo)^2

cat("--- Validazione Teorica (k =", k_theory, ") ---\n")

## --- Validazione Teorica (k = 5 ) ---
cat("Coefficiente di calibrazione (a):", round(coef(lm_fit), 3), "\n")

## Coefficiente di calibrazione (a): 0.739
cat("R² (var. teorica → ottimismo sim.):", round(r_sq, 3), "\n")


## R² (var. teorica → ottimismo sim.): 0.928
# Punti simulati vs curva teorica
p_theory <- ggplot(theory_df,
  aes(x = teorico, y = ottimismo, color = factor(n))) +
  geom_abline(slope = 1, intercept = 0, linetype = "dotted",
    color = "grey60", linewidth = 0.8) +
  geom_smooth(method = "lm", formula = y ~ 0 + x,
    se = TRUE, color = "grey20", fill = "grey85",
    linewidth = 1, inherit.aes = FALSE,
    aes(x = teorico, y = ottimismo)) +
  geom_point(size = 3.5, alpha = 0.9) +
  scale_color_brewer(palette = "Set1", name = "n") +
  labs(
    title = "Simulazione vs Previsione Teorica",
    subtitle = bquote("Predittore teorico:" ~ sqrt(2*log(p)/n) ~
      "| k =" ~ .(k_theory) ~ "| B =" ~ .(B) ~ "run per cella"),
    x = expression(sqrt(2 * log(p) / n) ~ "(predittore teorico)",
    y = "Ottimismo simulato (AUC - 0.50)"
  ) +
  theme(plot.title = element_text(face = "bold"),
    plot.subtitle = element_text(size = 9, color = "grey40"))

print(p_theory)

```

Simulazione vs Previsione Teorica

Predittore teorico: $\sqrt{2\log(p)/n}$ | $k = 5$ | $B = 100$ run per cella



Il grafico va letto su due livelli distinti.

$L'R^2 = 0.936$ è la **misura rilevante**. Indica che la formula $\sqrt{2\log p/n}$ coglie la corretta *forma funzionale* della dipendenza dall'ottimismo: ogni variazione di n o p nella griglia produce uno spostamento dell'ottimismo simulato proporzionale a quello previsto dalla teoria. Il predittore teorico non è solo un'indicazione qualitativa — spiega il 93.6% della varianza dell'ottimismo al variare dei parametri del problema.

La retta tratteggiata ($y = x$, cioè $a = 1$) è lontana dai punti per una ragione precisa, non per un difetto del modello. Essa rappresenta il caso in cui la formula predice il valore assoluto dell'ottimismo senza fattori correttivi. Il coefficiente di calibrazione stimato è invece $a = 0.729 < 1$: la formula sistematicamente *sovrastima* l'ottimismo di circa il 27%. Questo è atteso per tre motivi che derivano dalle approssimazioni della derivazione teorica: (i) l'union bound utilizzato nel Passo 2 è per costruzione conservativo, producendo una soglia t^* leggermente superiore al vero massimo atteso; (ii) la formula descrive la correlazione della singola variabile migliore tra p , mentre il classificatore usa le top- $k = k_{\text{theory}}$, le cui correlazioni sono decrescenti e in media inferiori al massimo; (iii) la regressione logistica introduce varianza aggiuntiva nella stima dei coefficienti $\hat{\beta}$, attenuando la capacità discriminante rispetto a quella suggerita dalla sola correlazione campionaria.

Il coefficiente $a = 0.729$ è quindi un fattore di calibrazione empirico stabile che sintetizza questi effetti. La conclusione metodologica rimane invariata: la distanza dalla retta $y = x$ non indebolisce il risultato — al contrario, il fatto che a sia stabile, ben diverso da zero e stimabile con R^2 elevato dimostra che $\sqrt{2\log p/n}$ è un predittore quantitativo robusto dell'ottimismo indotto dal leakage.

6 Esperimento 3: Robustezza con Predittori Correlati

Tutti gli esperimenti precedenti usano predittori i.i.d. In pratica, i predittori sono quasi sempre correlati tra loro. Questo esperimento verifica se la correlazione interna a X modifica il fenomeno del leakage.

Ipotesi da testare: con predittori correlati, la feature selection tende a scegliere *interi blocchi* di variabili simili anziché una sola, amplificando l'ottimismo rispetto al caso indipendente.

6.1 Struttura AR(1)

```
# Parametri fissi: n=200, p=100 (p ridotto per contenere il tempo con MASS::murnorm)
# k=10, rho variabile in {0, 0.3, 0.6, 0.9}
n_e3 <- 200; p_e3 <- 100; k_e3 <- 10
rho_vals <- c(0, 0.3, 0.6, 0.9)

res_ar1 <- data.frame(rho = rho_vals, auc_leaky = NA, auc_correct = NA)

for (i in seq_along(rho_vals)) {
  rho_i <- rho_vals[i]
  auc_l <- auc_c <- numeric(B)

  for (b in seq_len(B)) {
    set.seed(SEED + b + i * 1e5)
    X <- if (rho_i == 0) gen_iid(n_e3, p_e3) else gen_ar1(n_e3, p_e3, rho_i)
    y <- rbinom(n_e3, 1, 0.5)

    auc_l[b] <- cv_auc_leaky(X, y, k = k_e3, n_folds = FOLDS)
    auc_c[b] <- cv_auc_correct(X, y, k = k_e3, n_folds = FOLDS)
  }
  res_ar1$auc_leaky[i] <- mean(auc_l, na.rm = TRUE)
  res_ar1$auc_correct[i] <- mean(auc_c, na.rm = TRUE)

  cat(" rho =", rho_i,
      "| AUC leaky =", round(res_ar1$auc_leaky[i], 3),
      "| AUC correct =", round(res_ar1$auc_correct[i], 3), "\n")
}

## rho = 0 | AUC leaky = 0.696 | AUC correct = 0.503
## rho = 0.3 | AUC leaky = 0.678 | AUC correct = 0.498
## rho = 0.6 | AUC leaky = 0.654 | AUC correct = 0.504
## rho = 0.9 | AUC leaky = 0.564 | AUC correct = 0.505

res_ar1$ottimismo <- res_ar1$auc_leaky - res_ar1$auc_correct
print(res_ar1)

## rho auc_leaky auc_correct ottimismo
## 1 0.0 0.6958271 0.5025201 0.19330696
## 2 0.3 0.6784048 0.4976275 0.18077729
## 3 0.6 0.6542212 0.5039997 0.15022151
## 4 0.9 0.5640921 0.5047529 0.05933915

# Confronto AR(1) vs iid
df_ar1 <- res_ar1 |>
  pivot_longer(c(auc_leaky, auc_correct),
               names_to = "pipeline", values_to = "auc") |>
  mutate(
```

```

    pipeline = factor(pipeline,
                      levels = c("auc_leaky", "auc_correct"),
                      labels = c("Errata", "Corretta"))
  )


p_ar1 <- ggplot(df_ar1, aes(x = factor(rho), y = auc, fill = pipeline)) +
  geom_col(position = position_dodge(0.7), width = 0.6, alpha = 0.85) +
  geom_hline(yintercept = 0.5, linetype = "dashed", linewidth = 0.7) +
  scale_fill_manual(values = c("Errata" = "#e74c3c", "Corretta" = "#2ecc71"),
                    name = "Pipeline") +
  labs(
    title = "Esperimento 3 - Struttura AR(1)",
    subtitle = paste0("n=", n_e3, ", p=", p_e3, ", k=", k_e3,
                      " | B=", B, " run | DGP: Y . X"),
    x = expression(rho ~ "(correlazione AR(1))"),
    y = "AUC medio stimato dalla CV"
  ) +
  theme(plot.title = element_text(face = "bold", color = "#e67e22"))

print(p_ar1)

```

Esperimento 3 — Struttura AR(1)

n=200, p=100, k=10 | B=100 run | DGP: Y . X



I risultati mostrano che la correlazione tra predittori **attenua** il leakage, ma non lo elimina. L'ottimismo (gap tra barra rossa e barra verde) si riduce progressivamente all'aumentare di ρ : da 0.19 nel caso i.i.d. ($\rho = 0$) a soli 0.05 con $\rho = 0.9$, una riduzione di oltre il 70%.

La spiegazione è coerente con la derivazione teorica della Sezione 2.4. La formula $\sqrt{2\log p/n}$ descrive il massimo spurio su p predittori **indipendenti**. Con struttura AR(1) ad alta correlazione, le p variabili non sono più p direzioni distinte nello spazio delle features: il numero effettivo di dimensioni indipendenti esplorabili dalla feature selection è molto inferiore a p , quindi la massima correlazione campionaria spuria che la procedura errata può sfruttare è più bassa. In termini della formula teorica, la correlazione tra predittori riduce il p effettivo.

Questo non significa però che la correlazione protegga dall'errore metodologico: anche a $\rho = 0.9$, la pipeline errata produce un AUC medio di 0.566 su dati che non contengono alcun segnale predittivo. Il messaggio è che la correlazione tra predittori **mitiga** la gravità del leakage, ma non ne cambia la natura. La procedura corretta rimane l'unica garanzia, indipendentemente dalla struttura di dipendenza dei predittori.

7 Esperimento 4 — Il Problema è Architetture: il Criterio di Selezione Non Conta

Questo esperimento risponde a una domanda precisa: il problema del leakage dipende dall'*algoritmo* usato per costruire il ranking delle feature, o dal *punto* in cui quel ranking viene calcolato nel workflow di validazione?

I metodi filter classici (come la correlazione di Pearson) e i metodi basati sull'importanza derivata da un modello penalizzato (come l'importanza da Ridge) sono concettualmente molto diversi: il secondo incorpora la struttura dell'intero modello penalizzato nel criterio di selezione, risultando in apparenza più rigoroso. Ma questa sofisticazione protegge dal leakage?

Confrontiamo tre pipeline su ($n = 50, p = 200$):

1. **Filter sbagliato (correlazione di Pearson):** top- $k = 20$ per $|r_j|$ calcolata sull'intero dataset, poi CV — il ranking usa la correlazione lineare tra X_j e Y
2. **Filter embedded sbagliato (importanza Ridge):** top- $k = 20$ per $|\hat{\beta}_j^{\text{Ridge}}|$ calcolato da `cv.glmnet(alpha=0)` sull'intero dataset, poi CV — il ranking usa i coefficienti Ridge fittati sull'intero dataset, incluse le osservazioni di validazione
3. **Filter embedded corretto (importanza Ridge, Nested CV):** stesso criterio Ridge del punto 2, ma il fit di `cv.glmnet` e la selezione delle top- k avvengono **solo sul training fold** per ogni fold esterno — le osservazioni di validazione non entrano mai nella fase di ranking e selezione

Le pipeline 1 e 2 differiscono solo nel criterio di ranking; la pipeline 3 usa lo stesso criterio della 2 ma nella posizione corretta nel workflow.

Previsione teorica: se conta la *posizione* più che il *criterio*, le pipeline 1 e 2 dovrebbero produrre ottimismo di magnitudine comparabile — entrambe selezionano $k = 20$ feature guardando Y sull'intero dataset. La pipeline 3 dovrebbe invece centrarsi su 0.50, indipendentemente dal fatto che usi lo stesso criterio Ridge della pipeline 2.

7.1 Approfondimento: perché usare $|\hat{\beta}_{\text{Ridge}}|$ e non $|\hat{\beta}_{\text{Lasso}}|$ come criterio di ranking

La scelta di Ridge ($\alpha = 0$) come metodo embedded per costruire il ranking di importanza delle feature non è arbitraria: deriva da una precisa considerazione sul comportamento dei coefficienti dei due metodi su dati privi di segnale predittivo.

Il problema del Lasso come criterio di ranking su dati puro rumore.

La regularization path del Lasso ha un punto critico chiamato $\lambda_{\max}$: il valore minimo di λ per cui tutti i coefficienti sono esattamente zero. Formalmente,

$$\lambda_{\max} = \frac{1}{n} \|X^\top y\|_\infty = \frac{1}{n} \max_j |X_j^\top y|$$

Sotto H_0 ($Y \perp X_1, \dots, X_p$), la quantità $\max_j |X_j^\top y|/n$ è proporzionale alla correlazione campionaria massima. Abbiamo dimostrato nella Sezione 2.4 che questa vale circa $\sqrt{2 \log p/n}$, che per $n = 50$ e $p = 200$ è circa 0.35. Di conseguenza, `cv.glmnet(alpha=1)` su dati puro rumore tende a scegliere un λ vicino a $\lambda_{\max}$, azzerando la grande maggioranza dei $p = 200$ coefficienti.

Il vettore $\hat{\beta}_{\text{Lasso}}$ risultante ha quasi tutti i valori esattamente zero: il **ranking per $|\hat{\beta}_j|$ è degenero**. Non si riesce a discriminare tra le p feature perché quasi tutte hanno importanza identicamente nulla. La selezione delle top- k diventerebbe arbitraria tra le pochissime feature non azzerate — e anche queste variano instabilmente tra le run Monte Carlo, poiché dipendono da quale delle p correlazioni casuali supera per caso la soglia di selezione. L'esperimento misurerebbe l'instabilità del ranking, non l'effetto della posizione della selezione.

Perché Ridge garantisce un ranking stabile.

Ridge non ha una soglia $\lambda_{\max}$ analoga: qualunque sia $\lambda > 0$, tutti i p coefficienti sono non nulli (solo compressi verso zero). La soluzione analitica è

$$\hat{\beta}_{\text{Ridge}} = (X^\top X + \lambda I)^{-1} X^\top y$$

Con λ anche molto grande, ogni predittore ottiene un coefficiente $\hat{\beta}_j \propto X_j^\top y/(n\lambda) \neq 0$. Su $p = 200$ predittori rumore, Ridge assegna a ognuno un'importanza strettamente positiva e ben ordinata: il ranking è sempre completo, riproducibile tra run diverse, e non degenero.

La conseguenza per l'esperimento.

Usare il Lasso come criterio embedded renderebbe il confronto tra le tre pipeline non interpretabile: il leakage della pipeline 2 “sbagliata” sarebbe confuso con l'instabilità del ranking degenero. Ridge, invece, produce un ranking spurio ma stabile — spurio perché su dati puro rumore ogni ranking è per costruzione privo di significato predittivo, ma stabile perché tutti i coefficienti sono non nulli e confrontabili. Questo garantisce che il confronto tra le tre pipeline misuri esattamente ciò che vogliamo: l'effetto della *posizione* della selezione, a parità di criterio.

```
# Riduce B per l'Esperimento 4: il Ridge corretto con nested CV
# è computazionalmente più oneroso (FOLDS × FOLDS_INNER fit di cv.glmnet)
B_e4   <- if (QUICK_RUN) 30 else 100
n_e4   <- 50; p_e4 <- 200
```

```
cat("Esperimento 4: B =", B_e4, "run (n=50, p=200)\n")
```

```
## Esperimento 4: B = 100 run (n=50, p=200)
```

```
cat("Ridge corretto usa nested CV:",
    FOLDS, "fold esterni ×", FOLDS_INNER, "fold interni per run\n\n")
```

```
## Ridge corretto usa nested CV: 10 fold esterni × 5 fold interni per run
```

```
res_e4 <- matrix(NA, B_e4, 3,
  dimnames = list(NULL, c("filter_wrong",
    "ridge_filter_wrong",
    "ridge_filter_correct")))

for (b in seq_len(B_e4)) {
  set.seed(SEED + b + 3e5)
  X <- gen_iid(n_e4, p_e4)
```

```

y <- rbinom(n_e4, 1, 0.5)

res_e4[b, "filter_wrong"] <- cv_auc_leaky(X, y, k = 20, n_folds = FOLDS)
res_e4[b, "ridge_filter_wrong"] <- ridge_filter_wrong(X, y, k = 20,
                                                       n_folds = FOLDS)
res_e4[b, "ridge_filter_correct"] <- ridge_filter_correct(X, y, k = 20,
                                                         n_folds = FOLDS,
                                                         n_folds_inner = FOLDS_INNER)

if (b %% 5 == 0) cat(" Run", b, "/", B_e4, "\n")
}

```

```

## Run 5 / 100
## Run 10 / 100
## Run 15 / 100
## Run 20 / 100
## Run 25 / 100
## Run 30 / 100
## Run 35 / 100
## Run 40 / 100
## Run 45 / 100
## Run 50 / 100
## Run 55 / 100
## Run 60 / 100
## Run 65 / 100
## Run 70 / 100
## Run 75 / 100
## Run 80 / 100
## Run 85 / 100
## Run 90 / 100
## Run 95 / 100
## Run 100 / 100

```

```

# Riepilogo
cat("\n--- Risultati Esperimento 4 (n=50,p=200, B=", B_e4, "run) ---\n")

```

```

##
## --- Risultati Esperimento 4 (n=50,p=200, B= 100 run) ---
for (nm in colnames(res_e4)) {
  cat(nm, ": media =", round(mean(res_e4[, nm], na.rm = TRUE), 3),
      " | sd =", round(sd(res_e4[, nm], na.rm = TRUE), 3), "\n")
}

```

```

## filter_wrong : media = 0.796 | sd = 0.101
## ridge_filter_wrong : media = 0.788 | sd = 0.093
## ridge_filter_correct : media = 0.494 | sd = 0.138

```

```

# Dati in formato long per i grafici
df_e4 <- data.frame(res_e4) |>
  pivot_longer(everything(), names_to = "pipeline", values_to = "auc") |>
  mutate(
    pipeline = factor(pipeline,
      levels = c("filter_wrong", "ridge_filter_wrong", "ridge_filter_correct"),
      labels = c("Filter (correlazione)\nSBAGLIATO",
        "Filter (Ridge importance)\nSBAGLIATO",
        "Filter (Ridge importance)\nCORRETTO")),
    colore = if_else(grepl("CORRETTO", pipeline), "corretto", "sbagliato")
  )


# Grafico unico dei 3 metodi
p_e4 <- ggplot(df_e4, aes(x = pipeline, y = auc, fill = colore)) +
  geom_boxplot(width = 0.5, outlier.size = 1.2, alpha = 0.85) +
  geom_hline(yintercept = 0.5, linetype = "dashed", linewidth = 0.8,
    color = "grey30") +
  scale_fill_manual(
    values = c("sbagliato" = "#e74c3c", "corretto" = "#2ecc71"),
    guide = "none"
  ) +
  scale_y_continuous(limits = c(0.35, 1.0), breaks = seq(0.4, 1.0, 0.1)) +
  labs(
    title = "Metodi Embedded: il problema è architetturale, non algoritmico",
    subtitle = paste0("n = 50, p = 200 | B = ", B_e4,
      " run Monte Carlo | DGP: Y \u22A5 X\u2081,...,X\u2082\u2080\u2080"),
    x = NULL, y = "AUC stimato dalla CV"
  ) +
  theme(
    plot.title = element_text(face = "bold"),
    plot.subtitle = element_text(size = 9, color = "grey40")
  )

print(p_e4)

```


Metodi Embedded: il problema è architetturale, non algoritmico

$n = 50$, $p = 200$ | $B = 100$ run Monte Carlo | DGP: $Y \perp X_1, \dots, X_{200}$



Il grafico mostra il risultato atteso e teoricamente motivato: **il criterio di selezione è irrilevante — conta solo la posizione della selezione nel workflow.**

Le pipeline 1 (correlazione di Pearson, fuori CV) e 2 (importanza Ridge, fuori CV) producono distribuzioni di AUC indistinguibili tra loro, entrambe significativamente superiori a 0.50 su dati che non contengono alcun segnale predittivo. La scelta del criterio di ranking — lineare o basata su modello penalizzato — non fa differenza: l'errore è che la selezione avviene sull'intero dataset, incluse le osservazioni che finiranno nel validation set. Le top- k feature “migliori” sono le stesse per entrambi i criteri nel senso che sfruttano la stessa correlazione campionaria casuale con Y .

La pipeline 3 (importanza Ridge, selezione dentro la CV) produce invece AUC centrate su 0.50: nessun ottimismo, nessun leakage. Questo nonostante usi lo stesso algoritmo Ridge della pipeline 2 — l'unica differenza è che il fit di `cv.glmnet` e la selezione delle top- k vengono ripetuti per ogni fold esterno, usando solo le osservazioni di training.

Il messaggio architetturale è netto: non esiste un criterio di selezione “sicuro” se applicato fuori dalla CV. Correlazione di Pearson, importanza da Ridge, importanza da Random Forest, p-value di un test univariato — qualunque criterio che usa Y per costruire il ranking sull'intero dataset introduce la stessa classe di leakage. La correzione non è scegliere un criterio più sofisticato: è inserire l'intera procedura di selezione *dentro* il loop di validazione.

```

# Tabella riassuntiva
tab_e4 <- as.data.frame(res_e4) |>
  summarise(across(everything(),
    list(media = \(x) round(mean(x, na.rm=TRUE), 3),
          sd    = \(x) round(sd(x, na.rm=TRUE), 3)))) |>
  pivot_longer(everything(),
    names_to = c("pipeline", ".value"),
    names_sep = "_(?=[^_]+)$") |>
  mutate(
    ottimismo = round(media - 0.5, 3),
    pipeline = c("Filter Sbagliato (top-k fuori CV)",
                  "Ridge Sbagliato ( su intero dataset)",
                  "Ridge Corretto (nested CV)")
  ) |>
  dplyr::select(Pipeline = pipeline, `AUC medio` = media, SD = sd, `Ottimismo` = ottimismo)

knitr::kable(tab_e4, caption = paste0(
  "Riepilogo Esperimento 4 (n=50, p=200, B=", B_e4, " run)",
  booktabs = TRUE, align = c("l", "c", "c", "c"))

```

Table 1: Riepilogo Esperimento 4 (n=50, p=200, B=100 run)

Pipeline	AUC medio	SD	Ottimismo
Filter Sbagliato (top-k fuori CV)	0.796	0.101	0.296
Ridge Sbagliato (su intero dataset)	0.788	0.093	0.288
Ridge Corretto (nested CV)	0.494	0.138	-0.006

Il messaggio chiave: la sofisticazione algoritmica del metodo di selezione è **irrilevante** rispetto alla sua posizione nel workflow. Le pipeline 1 e 2 producono ottimismo statisticamente indistinguibile perché commettono lo stesso errore architetturale — usano Y di tutte le osservazioni, incluso il validation set, per decidere quali k feature includere. Il “miglioramento” da correlazione di Pearson a importanza Ridge è un’illusione di rigore: il leakage è della stessa natura e della stessa magnitudine.

La pipeline 3 non produce ottimismo perché rispetta una sola regola: **il validation set non deve mai influenzare nessuna fase della costruzione del modello**, inclusa la selezione delle variabili. La nested CV è la struttura che garantisce questa separazione, qualunque sia il criterio di ranking scelto.

8 Conclusioni

8.1 Tre messaggi da portare a casa

1. La CV stima l’errore del modello, non dell’intera pipeline. Qualsiasi pre-processing che usa Y deve essere incluso dentro il loop di CV. La feature selection è il caso più comune e insidioso, ma lo stesso vale per la standardizzazione adattiva, l’imputazione con informazioni statistiche del dataset, e il tuning di qualsiasi iperparametro.

2. L’ottimismo cresce con p secondo $\sqrt{2\log p/n}$. Con $p = 500$ e $n = 200$, $k = 20$, questo produce un’AUC apparente di circa 0.85 su dati completamente casuali — sufficiente a far credere di aver trovato un ottimo classificatore su dati che non contengono alcuna informazione.

3. Il problema è architetturale, non algoritmico. Usare Ridge (o qualsiasi metodo penalizzato) invece di un filter non protegge dal leakage se λ viene scelto guardando l’intero dataset. Anzi, Ridge dimostra che il

leakage da tuning dell'iperparametro esiste anche senza alcuna selezione di variabili. La nested CV è l'unica procedura che chiude completamente questa backdoor, qualunque sia il metodo usato.

8.2 Questa non è teoria accademica

I seguenti lavori documentano casi reali in letteratura pubblicata in cui questa identica procedura errata ha prodotto risultati fuorvianti:

- **Ambroise & McLachlan (2002)**: dimostrano che studi di classificazione di tumori basati su microarray con AUC altissima perdono quasi tutta la loro capacità predittiva quando la feature selection viene spostata correttamente dentro la CV. *PNAS*, 99(10), 6562–6566.
- **Simon et al. (2003)**: analizzano sistematicamente pubblicazioni di classificazione con dati genomici su riviste di alto impatto, mostrando che la maggior parte usava la procedura errata. Il bias di pre-selezione spiega gran parte dei risultati “significativi” di quegli studi. *J. Natl. Cancer Inst.*, 95(1), 14–18.

Questi studi si trovano, nella heatmap dell'Esperimento 1, nella zona rossa più profonda: $n \approx 40\text{--}100$, $p \approx 1000\text{--}10000$.