


Feature Selection Prima della CV

Come una Procedura Innocente Invalida l'Intera Analisi

Eros Pinzani

Corso di Statistical Learning – Università degli Studi di Firenze



CONTESTO E SETUP TEORICO

1. L'Obiettivo dello Studio

Verificare l'impatto fatale di eseguire la **Feature Selection** (la scelta delle top- k variabili con maggior correlazione al target) fuori dal loop di validazione.

Mostreremo come questa prassi generi un **bias di selezione** che gonfia artificialmente le performance, anche su dati privi di significato.

2. Data Generating Process (DGP)

Tutti gli esperimenti usano dati in cui **non esiste alcun segnale predittivo** per costruzione:

- Predittori: $X_j \approx \mathcal{N}(0,1), \quad j=1,\dots,p$
- Target: $Y \sim \text{Bernoulli}(0.5), \quad Y \perp X_1, \dots, X_p$

3. La Metrica: Cos'è l'AUC?

Usiamo l'Area Under the Curve (AUC), equivalente alla statistica U di Wilcoxon-Mann-Whitney:

$$AUC = P(\text{score}_+ > \text{score}_-)$$

- Misura la probabilità che il modello assegni uno score più alto a un positivo reale rispetto a un negativo reale.
- **Valore Teorico in assenza di segnale: 0.50.**
- Ogni valore significativamente superiore a 0.50 nei nostri test è un puro *artefatto della procedura*.

IL MECCANISMO DEL LEAKAGE

L'ipotesi fondamentale della Cross-Validation è che il validation set sia **completamente ignoto** in fase di training. La feature selection preliminare viola silenziosamente questa ipotesi.

Pipeline ERRATA

1. Calcola la correlazione $\text{cor}(X_j, Y)$ usando l'**INTERO** dataset.
2. Seleziona i top- k predittori.
3. Applica la CV sul modello ridotto.


Il problema: Le variabili selezionate non sono davvero correlate con Y , ma mostrano una correlazione campionaria alta per puro caso, sfruttando anche le osservazioni che finiranno nel validation set. La CV non se ne accorge perché l'errore è "a monte".

Pipeline CORRETTA

1. Inizia il loop di CV sui fold.
2. Usa **SOLO** il training fold per calcolare $\text{cor}(X_j, Y_{\text{train}})$.
3. Seleziona i top- k predittori.
4. Valuta sul validation fold.

La soluzione: La selezione non "vede" mai il validation set. Questo garantisce stime non affette da ottimismo artificiale.

ESPERIMENTO 1: LA DIMOSTRAZIONE BASE



Setup del Caso di Riferimento

Parametri: $n=200$ osservazioni, $p=500$ predittori casuali, selezione di $k=20$ variabili, $B=100$ run Monte Carlo.

- **Pipeline ERRATA:** AUC media ≈ 0.81 . Il modello sembra eccellente, un risultato che in ambito clinico verrebbe pubblicato.
- **Pipeline CORRETTA:** AUC media ≈ 0.51 . Il modello riflette la reale assenza di segnale.

Ottimismo Medio: ~ 0.30 .


Le due distribuzioni non si sovrappongono quasi per nulla.

LA DIPENDENZA DAI PARAMETRI n E p


Heatmap dell'Ottimismo (AUC - 0.50)

L'esperimento è stato espanso su una griglia variando n e p (con $k=20$ fisso):

- Il rischio non è costante, ma esplode nell'angolo **Alto- p / Basso- n** .
- Con $n=50$ e $p=500$, l'ottimismo è quasi di 0.40 (AUC vicina a 0.90 su puro rumore).
- **Il problema reale:** Le coordinate tipiche dei dataset biomedici (es. dati genomici o microarray con pochi pazienti e migliaia di geni) cadono sistematicamente nella "zona rossa" del grafico.



L'EFFETTO DEL NUMERO DI VARIABILI SELEZIONATE (\$k\$)



Cosa succede se variamo \$k\$?

A parità di $n=200$ e $p=500$, l'ottimismo **non cresce linearmente** con il numero di variabili incluse (k).

- L'ottimismo sale rapidamente (AUC ≈ 0.72 con $k=5$).
- Raggiunge un **picco intorno a $k=20$** (AUC ≈ 0.80).
- Poi **decresce** all'aumentare di k (AUC scende a 0.52 per $k=200$).

Spiegazione: Riflette il trade-off bias-varianza. Inserire **troppe** variabili puro rumore (con correlazione spuria molto bassa) aggiunge solo varianza alla stima dei coefficienti logistici, "annacquando" l'illusione di segnale trovata nelle prime variabili.

DERIVAZIONE TEORICA DELL'OTTIMISMO


L'ottimismo è guidato dalla variabile che, per puro caso, risulta la "migliore" (trap candidate). Qual è il valore atteso di questa correlazione spuria?

- **Passo 1:** Sotto H_0 , la correlazione campionaria punto-biseriale r_j ha distribuzione asintotica $\mathcal{N}(0, 1/n)$.
- **Passo 2:** I valori standardizzati $Z_j = \sqrt{n}r_j$ sono circa $\mathcal{N}(0, 1)$. Il valore atteso del massimo in valore assoluto tra p variabili normali indipendenti si concentra attorno a $\sqrt{2 \log p}$.
- **Passo 3:** Riportando alla scala originale, il massimo della correlazione spuria attesa è:

$$\max_{j=1 \dots p} |r_j| \approx \sqrt{\frac{2 \log p}{n}}$$

Questa formula predice che l'errore metodologico scala esattamente con il logaritmo dei predittori e inversamente alla radice dei dati.

ESPERIMENTO 2: VALIDAZIONE DELLA PREVISIONE TEORICA



Regressione: Formula vs Simulazione ($k=5$)

- **$R^2 \approx 0.93$** : La formula coglie la corretta forma funzionale. Ogni variazione di n o p produce uno spostamento proporzionale a quello predetto dalla formula.
- **Coefficiente $a \approx 0.74$** : I punti giacciono sotto la bisettrice $y=x$. La teoria sovrastima l'ottimismo sistematicamente di circa il 26%.

Perché non è perfettamente allineato ($a=1$)?


1. La formula usa l'*union bound* (conservativo).
2. Noi usiamo le top- k ($k=5$), non solo la singola feature massima.
3. La varianza della regressione logistica attenua la capacità discriminante rispetto alla sola correlazione campionaria.

ESPERIMENTO 3: ROBUSTEZZA CON PREDITTORI CORRELATE

La correlazione "salva" dal leakage?

Cosa succede se le X_j non sono indipendenti, ma hanno struttura autoregressiva AR(1)?

- L'ottimismo **si riduce** all'aumentare della correlazione ρ tra i predittori (es. da 0.19 a $\rho=0$, scende a 0.05 per $\rho=0.9$).
- **Perché?** Variabili altamente correlate equivalgono a ridurre il numero effettivo di "direzioni indipendenti" esplorabili. Il p *effettivo* nella formula teorica risulta più basso.
- **Conclusione:** La dipendenza attenua la gravità del leakage, ma **non lo elimina**. Anche con $\rho=0.9$, la pipeline errata trova AUC spurie. L'errore concettuale resta.



ESPERIMENTO 4: IL PROBLEMA È ARCHITETTURALE


Il problema è causato dal semplice filtro di Pearson, o accade anche usando modelli penalizzati più sofisticati per fare ranking (metodi *embedded*)?

Pearson vs. Ridge Importance

- Abbiamo usato la grandezza dei coefficienti **Ridge** $\hat{\beta}_j$ come criterio (usiamo Ridge e non Lasso perché su puro rumore il Lasso azzerava quasi tutti i coefficienti a $\lambda_{\max}$, creando un ranking degenerare e non confrontabile).
- **Ridge (Fuori CV):** AUC ≈ 0.79 . Indistinguibile dal filtro errato di Pearson.
- **Ridge Nested (Dentro CV):** AUC ≈ 0.49 . Nessun leakage.

Il Criterio di Selezione Non Conta.

La sofisticazione algoritmica (Random Forest, Ridge, Lasso) non cura l'errore. Usare l'intero dataset per costruire il ranking introduce il leakage, indipendentemente dalla matematica sottostante.



CONCLUSIONI

I Tre Messaggi da Portare a Casa

1. **La CV stima l'errore dell'intera pipeline, non del modello.**

Qualsiasi preprocessing che sfrutta il target Y (selezione, imputazione, tuning) *deve* avvenire strettamente all'interno del loop di validazione.

2. **L'ottimismo è governato da $\sqrt{2 \log p / n}$.**

Su dataset "larghi e bassi" (High- p), l'apparente perfezione di un classificatore può derivare interamente dal fitting del rumore.

3. **Il problema è architetturale, non algoritmico.**


Non esiste un criterio di selezione "sicuro" se applicato fuori dalla CV. L'unica protezione matematica contro questo leakage è l'utilizzo rigoroso della **Nested Cross-Validation**.

IMAGE SOURCES



https://d3w13n53foase7.cloudfront.net/small_983acc60_e19a_4735_9d82_95b50b2f667e_logo_unifi_positivo_609fe5cf3b.jpg

Source: www.livetheworld.com




<https://amt.copernicus.org/articles/16/5051/2023/amt-16-5051-2023-f06.png>

Source: amt.copernicus.org



https://miro.medium.com/1*QUi8dmomLtfQ2VHN9rtcrQ.png

Source: blog.openalgo.in



https://rforhr.com/R-for-HR_files/figure-html/unnamed-chunk-858-3.png

Source: rforhr.com



https://static.vecteezy.com/system/resources/previews/005/490/645/non_2x/presentation-background-with-blue-plexus-line-dot-and-light-digital-texture-of-bionic-element-or-atom-web-science-website-structure-free-vector.jpg

Source: www.vecteezy.com