

Feature Selection prima della CV

*Come una procedura innocente invalida
l'intera analisi*

AUTORE:

Eros Pinzani



UNIVERSITÀ
DEGLI STUDI
FIRENZE

Da un secolo, oltre.

Contesto e Setup

*La **Feature Selection** è la tecnica volta a identificare i predittori più informativi rispetto al target, eliminando il rumore e migliorando la capacità di generalizzazione dell'algoritmo*

Obiettivo:

Verificare le conseguenze di eseguire la **Feature Selection** fuori dal loop della **Cross Validation** →
Genera un **bias di selezione** che gonfia le performance

Data Generating Process:

Comune a tutti gli esperimenti

- **Predittori:** $X_j \approx \mathcal{N}(0,1)$, $j = 1, \dots, p$
- **Target:** $Y \sim \text{Bernoulli}(0.5)$, $Y \perp X_1, \dots, X_p$
→ **Non esiste alcun segnale predittivo**

Metrica:

Viene utilizzata l'**Area Under the Curve (AUC)**

$$\text{AUC} = P(\widehat{Y}^+ > \widehat{Y}^-)$$

- Rappresenta la probabilità che un classificatore assegni un punteggio (**score**) più alto a un esempio **positivo** scelto casualmente rispetto a un esempio **negativo** scelto a caso
- **Risultato atteso** in assenza di segnale: **0,50**
- Negli esperimenti valori **AUC** superiori a 0,50 rappresentano **artefatti della procedura**

Il meccanismo del Leakage

*L'ipotesi fondamentale della **Cross Validation** è che il **validation set** sia completamente **ignoto** in fase di **training**. La Feature Selection preliminare viola silenziosamente questa ipotesi*

Pipeline Errata

1. Calcola la **correlazione** $\text{cor}(X_j, Y)$ usando l'intero dataset
2. Seleziona i **top-k** predittori
3. Applica la **CV** sul modello ridotto

Il problema: Le variabili mostrano correlazioni **spurie** "pescate" sul **validation set**. La **CV** non rileva il bias perché la selezione è avvenuta a monte

Pipeline Corretta


1. Inizia il loop di **CV** sui **fold**
2. Usa solo il **training fold** per calcolare $\text{cor}(X_j, Y_{\text{train}})$
3. Seleziona i **top-k** predittori
4. Valuta sul **validation fold**

La soluzione: La selezione non vede mai il **validation set**. Questo garantisce stime non affette da **ottimismo artificiale**

Esperimento 1: Distorsione nelle stime AUC

Setup:

$n = 200$, $p = 500$, $k = 20$, $B = 100$ run Monte Carlo



- **Pipeline Errata:** AUC media $\approx 0,81$. Il modello sembra eccellente
- **Pipeline Corretta:** AUC media $\approx 0,51$. Il modello cattura la reale assenza di segnale

Ottimismo dell'errore

Il "salto" di performance (circa **0,30**) è causato dall'**ottimismo dell'errore di training**:


$$Opt = \frac{2}{n} \sum_{i=1}^n Cov(Y_i, \widehat{Y}_i)$$

- La selezione esterna **massimizza** la **covarianza** tra target e predizioni, aumentando **AUC**
- Il modello non apprende la relazione reale

Esperimento 1: Come i parametri guidano l'ottimismo

Setup:

n, p variano, $k = 20$, $B = 100$ run Monte Carlo




- L'ottimismo **non scala in modo lineare** all'aumentare di k (variabili selezionate)
- Distorsione iniziale → picco massimo → collasso dell'ottimismo
- **Trade-off bias-varianza**: per $k = 200$ si includono predittori con **correlazioni spurie** sempre più **deboli** → la **varianza** nella stima dei coefficienti **aumenta** drasticamente

- L'ottimismo è **massimo** per **p grande** e **n piccolo** → AUC a $\approx 0,90$
- Per **$p = k = 20$** si ha un caso limite: **ottimismo nullo** perché numero di predittori = numero di variabili da selezionare → **Nessun processo di selezione** → AUC a 0,50

Setup:

$n = 200$, $p = 500$, k varia, $B = 100$ run Monte Carlo



Derivazione teorica dell'ottimismo

La seguente derivazione teorica è utile per verificare analiticamente e confermare su base numerica il comportamento dell'ottimismo osservato precedentemente in via sperimentale

1. La distribuzione base:

- **Ipotesi:** ogni predittore X_j è teoricamente **indipendente** dal target Y (correlazione nulla)
- Le correlazioni campionarie r_j non sono esattamente zero, fluttuano casualmente seguendo la distribuzione: $r_j \sim \mathcal{N}\left(0, \frac{1}{n}\right)$

2. La ricerca del massimo:

- La **feature selection** non sceglie una variabile a caso ma **estrae le migliori da p variabili**.
- Per la teoria dei valori estremi:

$$E \left[\max_{j=1 \dots p} |Z_j| \right] \approx \sqrt{2 \log p}$$

ovvero il massimo estratto da un gruppo di variabili normali aumenta con p

3. La formula finale:


- Si riporta il massimo ottenuto sulla **scala originale** moltiplicando per $1/\sqrt{n}$

$$\max_{j=1 \dots p} |r_j| \approx \sqrt{\frac{2 \log p}{n}}$$

Esperimento 2: Validazione della previsione teorica

Setup:

$k = 5$, $B = 100$ run Monte Carlo



- Ogni punto rappresenta l'esito di una simulazione Monte Carlo con una combinazione di n e p
- $R^2 \approx 0.93$: la formula teorica coglie la corretta forma funzionale
- **Coefficiente $a \approx 0.74$** : i punti si allineano sotto la bisettrice. La teoria **sovrastima** l'ottimismo di circa il 26%

Motivo della sovrastima


- **Union Bound** nella fase 2: è per definizione conservativa
- La media sulle **top-k variabili** smorza il picco della singola variabile massima trovata dalla formula
- La **regressione logistica** introduce varianza

Esperimento 3: Robustezza alla correlazione

Setup:

$n = 200$, $p = 100$, $k = 10$, $B = 100$ run Monte Carlo


- X_j sono tra loro **correlate** con struttura autoregressiva **AR(1)**
- L'**ottimismo** si **riduce** all'**aumentare** della **correlazione**: variabili altamente correlate $\rightarrow$ geometricamente meno direzioni indipendenti da esplorare
- La correlazione attenua il valore dell'ottimismo ma non lo elimina: l'errore concettuale della pipeline errata non si risolve



Esperimento 4: Il problema è architetturale

Setup:

$n = 50$, $p = 200$, $B = 100$ run Monte Carlo



- **Criterio:** grandezza dei coefficienti **Ridge** $|\widehat{\beta}_j|$ (non **Lasso** perché su puro rumore **azzera** quasi tutti i coefficienti creando un ranking degenerare)
- **Ridge Errato:** AUC $\approx 0,79$, come filtro errato di Pearson
- **Ridge Corretto:** AUC $\approx 0,49$

Il criterio di selezione non conta

L'uso di algoritmi più sofisticati (Ridge, Lasso, Random Forest, ecc.) non risolve l'errore. Usare tutto il dataset per costruire il ranking introduce sempre il problema

Conclusioni

1. **La CV valida l'intera pipeline:** Qualsiasi fase di pre-processing guidata dal target (come la Feature Selection) deve avvenire rigorosamente all'interno del loop di validazione
2. **L'ottimismo segue la legge $\sqrt{\frac{2 \log p}{n}}$:** Nei dataset ad alta dimensionalità (molte variabili, pochi campioni), l'apparente perfezione di un modello deriva spesso dal fitting del rumore.
3. **Il bias è architetturale, non algoritmico:** Usare criteri di selezione più complessi non sana l'errore metodologico. L'unica vera soluzione è l'uso della Nested Cross-Validation

Casi documentati in letteratura

- **Ambroise & McLachlan (2002)** — studi di classificazione di tumori su microarray con AUC altissima perdono quasi tutta la capacità predittiva quando la feature selection viene spostata dentro la CV
- **Simon et al. (2003)** — analisi sistematica di pubblicazioni genomiche su riviste ad alto impatto: la maggior parte usava la pipeline errata; il bias di pre-selezione spiega gran parte dei risultati "significativi"

References

- Ambroise & McLachlan (2002) - Selection bias in gene extraction on the basis of microarray gene-expression data
- Simon et al. (2003) - Pitfalls in the Use of DNA Microarray Data for Diagnostic and Prognostic Classification
- Medium - How cross-validation can go wrong and how to fix it
- Claude e Gemini per ricavare la formula teorica e per supporto nella stesura e revisione