

La Condizione di Irrapresentabilità del Lasso

Teoria, Simulazioni e Rimedi per la Model Selection Consistency

Pennelli Lorenzo Maria

28 giugno 2026

Contents

1	Setup	2
2	Background Teorico	3
2.1	Il Problema della Model Selection	3
2.2	Il Lasso	3
2.3	Le Condizioni KKT del Lasso	3
2.4	La Matrice di Gram e la Struttura a Blocchi	4
2.5	La Irrepresentable Condition (Zhao & Yu, 2006)	4
2.6	Elastic Net e Adaptive Lasso	4
3	DGP, Calcolo Analitico dell'IC e Struttura di Covarianza	5
3.1	Struttura della Covarianza a Blocchi	5
4	Funzioni degli Stimatori	6
5	Esperimento 1 — La Transizione di Fase	7
6	Esperimento 2 — Anatomia del Fallimento: FP vs FN	9
7	Esperimento 3 — $n \rightarrow \infty$ Non Basta	12
8	Esperimento 4 — Il Terzetto: Lasso vs Elastic Net vs Adaptive Lasso	15
9	Esperimento 5 — L'Illusione della Cross-Validation	21
9.1	Riferimenti	24

1 Setup

```
pkgs <- c("glmnet", "ggplot2", "patchwork", "dplyr", "tidyr",
          "MASS", "scales", "knitr", "kableExtra")
to_install <- pkgs[!pkgs %in% installed.packages()[,"Package"]]
if (length(to_install) > 0)
  install.packages(to_install, repos="https://cloud.r-project.org", quiet=TRUE)

# MASS caricata prima di dplyr: evita il conflitto su select() e MASS::select()
suppressPackageStartupMessages({
  library(MASS)
  library(glmnet); library(ggplot2); library(patchwork)
  library(dplyr); library(tidyr)
  library(scales); library(knitr); library(kableExtra)
})
# dplyr::select mascherava MASS::select; con l'ordine corretto non serve, ma
# lo esplicitiamo per sicurezza in caso di future modifiche all'ordine di caricamento.
select <- dplyr::select

# --- Tema grafico uniforme (ispirato al notebook Variable Importance) ---
tema <- theme_minimal(base_size = 12) +
  theme(
    plot.title       = element_text(face="bold", size=13, color="grey10"),
    plot.subtitle    = element_text(size=10, color="grey40", margin=margin(b=10)),
    legend.position   = "bottom",
    legend.title      = element_blank(),
    strip.text        = element_text(face="bold", size=11),
    strip.background  = element_rect(fill="grey93", color=NA),
    panel.grid.minor  = element_blank(),
    panel.grid.major  = element_line(color="grey92", linewidth=0.4),
    plot.margin       = margin(10,10,8,10)
  )
theme_set(tema)

# =====
# QUICK_RUN = TRUE -> ~3 min (B_MC=250, B_N=200)
# QUICK_RUN = FALSE -> ~12 min (B_MC=600, B_N=500) per rendering finale
# =====
QUICK_RUN <- TRUE
B_MC <- if (QUICK_RUN) 250 else 600
B_N <- if (QUICK_RUN) 200 else 500

# DGP principale: p=3, |S*|=2 => rho* = 1/2 = 0.50
N_MAIN <- 500; P_TOT <- 3; P_S <- 2
BETA_S <- c(3, 3) # segnale forte: evita FN artificiali con lambda.1se
SIGMA2 <- 1.0

RHO_GRID <- seq(0.05, 0.70, by=0.05) # IC in [0.10, 1.40]

# Palette colori unificata
COL_LASSO <- "#E63946" # rosso -> Lasso standard
COL_AL <- "#2A9D8F" # teal -> Adaptive Lasso
COL_EN <- "#8338EC" # viola -> Elastic Net
```

```
COL_S      <- "#1D3557"    # blu scuro -> variabili vere (S*)
COL_NS     <- "#E76F51"    # arancione -> variabili false (-S*)
SEED       <- 2025

cat(sprintf(
  "Config: %s | B_MC=%d | B_N=%d | n=%d | p=%d | |S*|=%d | rho*=%.2f | beta=%s\n",
  if(QUICK_RUN)"QUICK" else "FULL",
  B_MC, B_N, N_MAIN, P_TOT, P_S, 1/P_S, paste(BETA_S,collapse=",")))

## Config: QUICK | B_MC=250 | B_N=200 | n=500 | p=3 | |S*|=2 | rho*=0.50 | beta=3,3
```

2 Background Teorico

2.1 Il Problema della Model Selection

Nei modelli ad alta dimensione l'obiettivo non è solo prevedere bene, ma **identificare le variabili causalmente rilevanti**. Definiamo il *vero supporto*:

$$S^* = \{j : \beta_j^* \neq 0\}$$

Un estimatore è **selection consistent** se:

$$P(\hat{S} = S^*) \rightarrow 1 \quad \text{per } n \rightarrow \infty$$

Questa proprietà è *indipendente* dalla consistenza della stima: si può stimare bene i coefficienti senza recuperare il supporto esatto, e vice versa. Knight & Fu (2000) dimostrano la consistenza della *stima* del Lasso per $\lambda_n = o(n)$, ma la consistenza della *selezione* richiede condizioni aggiuntive sulla struttura di X .

2.2 Il Lasso

Il Lasso (Tibshirani, 1996) risolve:

$$\hat{\beta}^{\text{Lasso}} = \arg \min_{\beta \in \mathbb{R}^p} \left\{ \frac{1}{2n} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1 \right\}$$

La norma ℓ_1 produce soluzioni **esattamente sparse** — a differenza di Ridge (ℓ_2) che contrae senza azzerare. Il parametro λ regola il trade-off: $\lambda = 0$ riduce a OLS; λ grande azzerava tutto.

2.3 Le Condizioni KKT del Lasso

Le condizioni di Karush-Kuhn-Tucker caratterizzano completamente la soluzione ottima:

$$\frac{1}{n} X_j^\top (y - X\hat{\beta}) = \lambda \cdot \text{sign}(\hat{\beta}_j), \quad j \in \hat{S}$$

$$\left| \frac{1}{n} X_j^\top (y - X\hat{\beta}) \right| \leq \lambda, \quad j \notin \hat{S}$$

La **seconda** condizione è quella critica: affinché una variabile irrilevante $j \notin S^*$ rimanga correttamente a zero, il suo gradiente residuo deve stare strettamente sotto λ . Se la struttura di X non lo garantisce — indipendentemente da n e λ — il Lasso include la variabile falsa nel modello.

2.4 La Matrice di Gram e la Struttura a Blocchi

Definiamo $C^n = \frac{1}{n} X^\top X$, partizionata rispetto a S^* (prime q colonne) e $-S^*$ (ultime $p - q$):

$$C^n = \begin{pmatrix} C_{11}^n & C_{12}^n \\ C_{21}^n & C_{22}^n \end{pmatrix}$$

Il blocco **chiave** è $C_{21}^n = \frac{1}{n} X_{-S^*}^\top X_{S^*}$: misura come le variabili false si correlano con le vere. Importante: l'IC non dipende da C_{22}^n (covarianza intra-blocco falso) — solo dalla correlazione incrociata.

2.5 La Irrepresentable Condition (Zhao & Yu, 2006)

$$\left\| C_{21}^n (C_{11}^n)^{-1} \text{sign}(\beta_{S^*}^*) \right\|_\infty < 1$$

La quantità $C_{21}^n (C_{11}^n)^{-1} \text{sign}(\beta_{S^*}^*)$ è esattamente il vettore dei **coefficienti della regressione OLS** di ogni variabile falsa sulle variabili vere, proiettato nella direzione dei segni dei coefficienti veri. L'IC richiede che questo valore, per ogni variabile falsa, sia strettamente inferiore a 1.

Intuizione geometrica. Se una variabile rumore può essere scritta come combinazione lineare delle variabili vere con “peso totale” ≥ 1 , allora la sua correlazione con il residuo $y - X\hat{\beta}$ può superare la soglia λ — il Lasso non riesce a tenerla a zero. *La variabile falsa è troppo “rappresentabile” dalle vere: da qui il nome.* Ovviamente questa scrittura è corretta se e solo se (C_{11}^n) sia invertibile e quindi definita positiva. **Teorema 1 (sufficienza, Zhao & Yu 2006).** Se la Strong IC vale con margine $\eta > 0$ e $\lambda_n/n \rightarrow 0$, $\lambda_n n^{-(1+c)/2} \rightarrow \infty$:

$$P(\hat{\beta}^n(\lambda_n) =_s \beta^n) = 1 - o(e^{-n^c})$$

La convergenza è esponenzialmente rapida in n .

Teorema 2 (necessità, Zhao & Yu 2006). Se la Weak IC è violata per infiniti n , allora per *nessuna* scelta di λ_n si ha general sign consistency:

$$P(\hat{S}_{\text{Lasso}} = S^*) \not\rightarrow 1$$

IC è quindi **quasi necessaria e sufficiente** per la selezione consistente.

Corollario pratico (Corollary 2, Zhao & Yu 2006). Se le correlazioni sono bounded: $|r_{ij}| \leq \frac{c}{2q-1}$ per $c < 1$, la Strong IC è garantita. Questo bound è stretto: il Lasso è consistente solo se la correlazione tra ogni variabile falsa e il blocco vero non supera $1/(2q-1)$.

2.6 Elastic Net e Adaptive Lasso

Elastic Net (Zou & Hastie, 2005) aggiunge una penalità ℓ_2 :

$$\hat{\beta}^{\text{EN}} = \arg \min_{\beta} \frac{1}{2n} \|y - X\beta\|_2^2 + \lambda[\alpha \|\beta\|_1 + (1 - \alpha) \|\beta\|_2^2]$$

Il *grouping effect* migliora la stima e la stabilità numerica in presenza di collinearità. Tuttavia **non risolve la selezione**: costringendo le variabili correlate a entrare in gruppo, EN include sistematicamente anche il rumore correlato con il segnale vero — aumentando i falsi positivi rispetto al Lasso puro in zona IC violata.

Adaptive Lasso (Zou, 2006) usa pesi differenziali $w_j = |\hat{\beta}_j^{\text{init}}|^{-\gamma}$:

$$\hat{\beta}^{\text{AL}} = \arg \min_{\beta} \frac{1}{2n} \|y - X\beta\|_2^2 + \lambda \sum_{j=1}^p w_j |\beta_j|$$

Il meccanismo è asimmetrico per design:

- Variabili **vere**: $\hat{\beta}_j^{\text{init}}$ grande $\Rightarrow w_j$ piccolo $\Rightarrow$ penalizzazione bassa $\Rightarrow$ il coefficiente sopravvive.
- Variabili **false**: $\hat{\beta}_j^{\text{init}} \approx 0 \Rightarrow w_j \rightarrow \infty \Rightarrow$ penalizzazione altissima $\Rightarrow$ azzeramento.

Zou (2006) dimostra le **proprietà oracolo** dell'AL: selezione e stima asintoticamente equivalenti a conoscere S^* a priori, **senza richiedere IC**. L'inizializzazione via Ridge (anziché OLS) è necessaria quando ρ è alto perché OLS diventa numericamente instabile per collinearità elevata, producendo stime iniziali distorte che corrompono i pesi w_j .

3 DGP, Calcolo Analitico dell'IC e Struttura di Covarianza

3.1 Struttura della Covarianza a Blocchi

La nostra scelta di design ha un obiettivo preciso: un singolo parametro scalare ρ che controlli *esattamente* il valore dell'IC, permettendo di attraversare la soglia IC = 1 in modo controllato e verificabile analiticamente.

Costruiamo la matrice di covarianza teorica Σ in modo che le variabili all'interno dello stesso blocco siano indipendenti, ma ogni variabile falsa abbia una correlazione costante ρ con ciascuna variabile vera:

$$\Sigma_{jk} = \begin{cases} 1 & j = k \\ \rho & j \in S^*, k \notin S^* \text{ (o viceversa)} \\ 0 & \text{altrimenti} \end{cases}$$

Con questa struttura, il blocco di covarianza delle variabili vere è semplicemente la matrice identità ($C_{11} = I_{p_S}$), il che rende la sua inversa banale ($C_{11}^{-1} = I_{p_S}$). Il blocco di covarianza incrociata C_{21} (di dimensione $(p - p_S) \times p_S$) è composto interamente da valori ρ .

Se impostiamo il segnale in modo che tutti i coefficienti veri siano positivi ($\text{sign}(\beta_{S^*}^*) = \mathbf{1}_{p_S}$), il calcolo dell'Irrepresentable Condition si semplifica drasticamente. La moltiplicazione $C_{21}C_{11}^{-1}\mathbf{1}_{p_S}$ equivale semplicemente a sommare le righe della matrice C_{21} . Poiché ogni riga contiene esattamente p_S elementi pari a ρ , la formula si riduce a un'espressione scalare lineare:

$$\text{IC}(\rho) = \|C_{21}C_{11}^{-1}\mathbf{1}_{p_S}\|_{\infty} = \left\| \begin{pmatrix} \rho & \dots & \rho \\ \vdots & \ddots & \vdots \\ \rho & \dots & \rho \end{pmatrix} I_{p_S} \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \right\|_{\infty} = p_S \cdot \rho$$

La soglia critica in cui la consistenza si rompe è quindi $\rho^* = 1/p_S$ — calcolabile in forma chiusa e verificabile in modo esatto. Nel nostro scenario base con $p_S = 2$

```

make_Sigma <- function(rho, p_S, p_tot) {
  Sigma <- diag(p_tot)
  S <- seq_len(p_S); nS <- seq(p_S + 1, p_tot)
  for (j in S) for (k in nS) Sigma[j,k] <- Sigma[k,j] <- rho
  Sigma
}

compute_IC <- function(rho, p_S, p_tot, beta_S) {
  Sigma <- make_Sigma(rho, p_S, p_tot)
  S <- seq_len(p_S); nS <- seq(p_S + 1, p_tot)
  max(abs(Sigma[nS, S, drop=FALSE] %*%
          solve(Sigma[S, S, drop=FALSE]) %*%
          sign(beta_S)))
}

genera_dati <- function(n, rho, p_S, p_tot, beta_S, sigma2) {
  # Generazione diretta tramite equazioni strutturali (SEM)
  # Nota: la varianza residua di X3 è  $1 - 2\rho^2$ , che diventa negativa per  $\rho > 1/\sqrt{2}$ .
  # Con rho_grid <= 0.70 siamo appena sotto il limite, ma il clamp garantisce robustezza.
  var_res <- max(1 - 2 * rho^2, 0)

  X1 <- rnorm(n)
  X2 <- rnorm(n)
  Z3 <- rnorm(n) # Rumore specifico ortogonale

  # X3 è formata da una parte di segnale (X1, X2) e una parte di rumore puro
  X3 <- rho * X1 + rho * X2 + sqrt(var_res) * Z3

  X <- cbind(X1, X2, X3)
  beta <- c(beta_S, rep(0, p_tot - p_S))
  y <- drop(X %*% beta + rnorm(n, 0, sqrt(sigma2)))

  list(X=X, y=y, beta=beta)
}

```

4 Funzioni degli Stimatori

```

S_TRUE <- seq_len(P_S)

# LASSO STANDARD
# lambda.1se: conservativo - riduce FP in zona IC<1 (dove il segnale è forte),
# rendendo il crollo alla soglia più netto e leggibile visivamente.
run_lasso <- function(X, y, S_true, rule="lambda.1se", nfolds=5) {
  bhat <- as.vector(coef(cv.glmnet(X, y, alpha=1, nfolds=nfolds), s=rule))[-1]
  Sh <- which(bhat != 0)
  list(esatto=setequal(Sh,S_true),
       FP=length(setdiff(Sh,S_true)),
       FN=length(setdiff(S_true,Sh)))
}

# ADAPTIVE LASSO

```

```

# init="ridge": stabile anche per rho -> 1 (OLS instabile per collinearita').
# gamma controlla la forza della discriminazione tra vere e false.
run_adaptive_lasso <- function(X, y, S_true,
                             gamma=1, rule="lambda.1se",
                             init="ridge", nfolds=5) {
  if (init == "ridge") {
    br <- as.vector(coef(cv.glmnet(X,y,alpha=0,nfolds=nfolds),
                          s="lambda.min"))[-1]
  } else {
    br <- tryCatch(coef(lm(y~X))[-1], error=function(e) rep(0,ncol(X)))
  }
  w <- 1/(abs(br)+1e-6)^gamma;
  bhat <- as.vector(coef(cv.glmnet(X,y,alpha=1,
                                penalty.factor=w,nfolds=nfolds),s=rule))[-1]

  Sh <- which(bhat!=0)
  list(esatto=setequal(Sh,S_true),
       FP=length(setdiff(Sh,S_true)),
       FN=length(setdiff(S_true,Sh)))
}

# ELASTIC NET
# alpha_en in (0,1): bilancia L1 (sparsita') e L2 (grouping effect).
# alpha=0.5 e' il valore canonico di Zou & Hastie (2005).
run_en <- function(X, y, S_true, alpha_en=0.5, rule="lambda.1se", nfolds=5) {
  bhat <- as.vector(coef(cv.glmnet(X,y,alpha=alpha_en,nfolds=nfolds),s=rule))[-1]
  Sh <- which(bhat!=0)
  list(esatto=setequal(Sh,S_true),
       FP=length(setdiff(Sh,S_true)),
       FN=length(setdiff(S_true,Sh)))
}

```

5 Esperimento 1 — La Transizione di Fase

Ipotesi: $P(\hat{S}_{\text{Lasso}} = S^*)$ rimane vicina a 1 per $IC < 1$, poi crolla verticalmente alla soglia $IC = 1$.

Perché: è la verifica empirica del Teorema 1 e 2 di Zhao & Yu. Il crollo non dipende dalla scelta di λ — qualunque λ_n si usi, se IC è violata la selezione è inconsistente. La simulazione rende visibile questo fatto su n finito.

```

set.seed(SEED)
results_e1 <- lapply(RHO_GRID, function(rho) {
  ic <- compute_IC(rho, P_S, P_TOT, BETA_S)
  h <- replicate(B_MC, {
    d <- genera_dati(N_MAIN, rho, P_S, P_TOT, BETA_S, SIGMA2)
    run_lasso(d$X, d$y, S_TRUE)$esatto
  })
  data.frame(rho=rho, ic=ic, prob=mean(h), se=sd(h)/sqrt(B_MC))
})
df_e1 <- bind_rows(results_e1)
cat(sprintf("Soglia teorica IC=1 a rho=%.2f | Crollo empirico a rho=%.2f\n",

```

```
1/P_S,
df_e1 |> filter(prob < .5) |> slice_min(rho,n=1) |> pull(rho)))
```

```
## Soglia teorica IC=1 a rho*=0.50 | Crollo empirico a rho=0.50
```

```
# Coordinate per le frecce di testo dirette alla curva
```

```
ic_pts <- df_e1 |> filter(ic %in% c(0.40, 1.20))
```

```
ggplot(df_e1, aes(x=ic, y=prob)) +
```

```
# --- Sfondi zona OK / violata ---
```

```
annotate("rect", xmin=-Inf, xmax=1, ymin=-Inf, ymax=Inf,
  fill="#D5F5E3", alpha=0.40)+
```

```
annotate("rect", xmin=1, xmax=Inf, ymin=-Inf, ymax=Inf,
  fill="#FADBD8", alpha=0.40)+
```

```
# --- Ribbon errore standard (piu' sottile, meno invasivo) ---
```

```
geom_ribbon(aes(ymin=pmax(prob-2*se,0), ymax=pmin(prob+2*se,1)),
  fill=COL_LASSO, alpha=0.12)+
```

```
# --- Linea e punti ---
```

```
geom_line(color=COL_LASSO, linewidth=1.8)+
```

```
geom_point(color=COL_LASSO, size=3.0, shape=19)+
```

```
# --- Soglia IC = 1 ---
```

```
geom_vline(xintercept=1, color="grey30", linewidth=0.8, linetype="longdash")+
```

```
# --- Linea 50% ---
```

```
geom_hline(yintercept=0.5, linetype="dotted", color="grey55", linewidth=0.6)+
```

```
# --- Etichetta soglia: in cima, centrata, non sovrapposta alla curva ---
```

```
annotate("label",
  x=1.0, y=1.06,
  label="Soglia IC = 1 (rho* = 0.50)",
  color="grey20", size=3.0, fill="grey96",
  label.size=0.3, hjust=0.5, fontface="bold")+
```

```
# --- Zona verde: testo in alto a sinistra, lontano dalla curva ---
```

```
annotate("text",
  x=0.20, y=0.10,
  label="IC < 1\nLasso consistente",
  color="#1E8449", size=3.6, fontface="bold",
  hjust=0.5, vjust=0, lineheight=0.95)+
```

```
# --- Zona rossa: testo in basso a destra ---
```

```
annotate("text",
  x=1.35, y=0.88,
  label="IC \u2265 1\nLasso include\nvariabili false",
  color=COL_LASSO, size=3.6, fontface="bold",
  hjust=0.5, vjust=1, lineheight=0.95)+
```

```
scale_x_continuous(
  name=expression("Valore dell'IC"),
  breaks=seq(0, 1.4, 0.2),
  limits=c(0, 1.55))+
```

```
scale_y_continuous(
  labels=percent_format(accuracy=1),
  limits=c(-0.02, 1.10),
  breaks=seq(0, 1, 0.25),
  expand=c(0,0),
  name=expression("P(~hat(S) ~ S"~"*"~") - recupero esatto del supporto"))+
labs(
```

```
  title="Esperimento 1: La Transizione di Fase",
```


```

subtitle=sprintf(
  "n = %d | %d repliche Monte Carlo | fascia = \u00b12 errori standard",
  N_MAIN, B_MC))+
theme(plot.margin = margin(10, 14, 8, 10))

```

Esperimento 1: La Transizione di Fase

n = 500 | 250 repliche Monte Carlo | fascia = ± 2 errori standard



6 Esperimento 2 — Anatomia del Fallimento: FP vs FN

Ipotesi: quando IC è violata, il Lasso sbaglia per **eccesso** di variabili selezionate (FP), non per variabili vere mancate (FN).

Perché: $P(\hat{S} = S^*)$ è una misura aggregata. Questo esperimento scompone il fallimento, confermando il meccanismo diretto dell'IC: la variabile falsa supera la soglia λ sfruttando la correlazione con le vere, ma le vere continuano a essere recuperate ($FN \approx 0$). In applicazioni reali questo significa: il Lasso *trova* sempre i geni causali, ma li annacqua con decine di falsi biomarcatori.

```

set.seed(SEED + 10)
results_e2 <- lapply(RHO_GRID, function(rho) {
  ic <- compute_IC(rho, P_S, P_TOT, BETA_S)
  res <- replicate(B_MC, {

```

```

d <- genera_dati(N_MAIN, rho, P_S, P_TOT, BETA_S, SIGMA2)
r <- run_lasso(d$X, d$y, S_TRUE)
c(FP=r$FP, FN=r$FN)
})
data.frame(rho=rho, ic=ic,
            FP_avg=mean(res["FP",]), FP_se=sd(res["FP",])/sqrt(B_MC),
            FN_avg=mean(res["FN",]), FN_se=sd(res["FN",])/sqrt(B_MC))
})
df_e2 <- bind_rows(results_e2)

```

```

# Stile annotazione in-plot (come nell'immagine di riferimento)
ANNOT_COLOR <- "#8B1A1A" # rosso scuro usato per le etichette
Y_MAX <- 1.5 # range Y uguale per entrambi

p2a <- ggplot(df_e2, aes(x = ic, y = FP_avg)) +
  annotate("rect", xmin = -Inf, xmax = 1, ymin = -Inf, ymax = Inf,
           fill = "#D5F5E3", alpha = 0.45) +
  annotate("rect", xmin = 1, xmax = Inf, ymin = -Inf, ymax = Inf,
           fill = "#FADEBD", alpha = 0.45) +
  # annotazione titolo in stile immagine di riferimento
  annotate("text",
           x = mean(range(df_e2$ic)), # centro orizzontale
           y = Y_MAX * 0.97, # vicino al bordo superiore
           label = "Falsi Positivi - rumore incluso",
           color = ANNOT_COLOR, size = 3.5,
           hjust = 0.5, fontface = "italic") +
  # sottotitolo descrittivo (come "Crescono dopo IC = 1")
  annotate("text",
           x = mean(range(df_e2$ic)),
           y = Y_MAX * 0.88,
           label = "Crescono dopo IC = 1",
           color = "grey40", size = 2.8,
           hjust = 0.5, fontface = "italic") +
  geom_ribbon(aes(ymin = pmax(FP_avg - 2 * FP_se, 0), ymax = FP_avg + 2 * FP_se),
             fill = COL_LASSO, alpha = 0.15) +
  geom_line(color = COL_LASSO, linewidth = 1.7) +
  geom_point(color = COL_LASSO, size = 3) +
  geom_vline(xintercept = 1, color = "grey30", linewidth = 0.8,
             linetype = "longdash") +
  annotate("text", x = 1.01, y = (P_TOT - P_S) * 0.9,
           label = "IC = 1", color = "grey30", size = 3.0,
           hjust = 0, fontface = "italic") +
  scale_x_continuous(name = "IC", breaks = seq(0, 1.5, .2)) +
  scale_y_continuous(
    name = "Falsi Positivi medi",
    limits = c(0, Y_MAX),
    breaks = seq(0, Y_MAX, 0.25)
  ) +
  labs(title = NULL, subtitle = NULL) # rimosso: il titolo è ora in-plot

p2b <- ggplot(df_e2, aes(x = ic, y = FN_avg)) +
  annotate("rect", xmin = -Inf, xmax = 1, ymin = -Inf, ymax = Inf,
           fill = "#D5F5E3", alpha = 0.45) +

```

```


annotate("rect", xmin = 1, xmax = Inf, ymin = -Inf, ymax = Inf,
        fill = "#FADBD8", alpha = 0.45) +
# annotazione titolo in stile immagine di riferimento
annotate("text",
        x      = mean(range(df_e2$ic)),
        y      = Y_MAX * 0.97,
        label  = "Falsi Negativi",
        color  = ANNOT_COLOR, size = 3.5,
        hjust  = 0.5, fontface = "italic") +
annotate("text",
        x      = mean(range(df_e2$ic)),
        y      = Y_MAX * 0.88,
        label  = "Restano \u2248 su tutto l'intervallo",
        color  = "grey40", size = 2.8,
        hjust  = 0.5, fontface = "italic") +
geom_ribbon(aes(ymin = pmax(FN_avg - 2 * FN_se, 0), ymax = FN_avg + 2 * FN_se),
        fill = COL_S, alpha = 0.15) +
geom_line(color = COL_S, linewidth = 1.7) +
geom_point(color = COL_S, size = 3) +
geom_vline(xintercept = 1, color = "grey30", linewidth = 0.8,
        linetype = "longdash") +
annotate("text", x = 1.01, y = P_S * 0.9,
        label = "IC = 1", color = "grey30", size = 3.0,
        hjust = 0, fontface = "italic") +
scale_x_continuous(name = "IC", breaks = seq(0, 1.5, .2)) +
scale_y_continuous(
        name      = "Falsi Negativi medi",
        limits    = c(0, Y_MAX),
        breaks    = seq(0, Y_MAX, 0.25)
) +
labs(title = NULL, subtitle = NULL)

p2a + p2b +
plot_annotation(
        title      = "Esperimento 2: Anatomia del Fallimento del Lasso",
        subtitle    = sprintf(
                "Il Lasso non perde il segnale - viene contaminato dal rumore correlato | n=%d, B=%d MC",
                N_MAIN, B_MC),
        theme = theme(plot.title = element_text(face = "bold", size = 13))
)

```

Esperimento 2: Anatomia del Fallimento del Lasso

Il Lasso non perde il segnale — viene contaminato dal rumore correlato | $n=500$, $B=250$ MC



Risultato: i FP crescono monotonicamente dopo $IC = 1$; i FN rimangono ≈ 0 . Il Lasso non perde il segnale — viene contaminato dal rumore correlato che supera λ . Questo è il meccanismo fisico del fallimento IC: la variabile falsa è “irrapresentabile” solo se $IC < 1$; quando $IC \geq 1$ la sua rappresentazione supera la soglia λ .

7 Esperimento 3 — $n \rightarrow \infty$ Non Basta

Ipotesi: con IC violata, $P(\hat{S} = S^*)$ raggiunge un **plateau permanente** < 1 al crescere di n invece di convergere a 1.

Perché è il risultato più controintuitivo: la statistica classica insegna che con più dati “tutto converge”. Il Teorema 2 è categorico: se IC è violata, nessun λ_n porta $P \rightarrow 1$. Il vincolo è strutturale — nella geometria di Σ , non nel campione.

Nota tecnica: qui usiamo `lambda.min` invece di `lambda.1se` perché a n grande (tipicamente $n > 1000$) `lambda.1se` diventa eccessivamente conservativo e genera FN artificiali che abbassano artificialmente la curva IC-soddisfatta, oscurando la differenza tra i due scenari.

```
set.seed(SEED + 20)
rho_ok  <- 0.10  # IC = 0.20 -> soddisfatta, lontana dalla soglia
rho_bad <- 0.65  # IC = 1.30 -> piu' violata, plateau piu' netto e stabile
n_grid  <- c(100, 200, 350, 500, 1000, 2000, 5000, 10000, 20000)
B_N_e3  <- if (QUICK_RUN) 350 else 700
```

```

results_e3 <- lapply(n_grid, function(nn) {
  res <- replicate(B_N_e3, {
    d_ok <- genera_dati(nn, rho_ok, P_S, P_TOT, BETA_S, SIGMA2)
    d_bad <- genera_dati(nn, rho_bad, P_S, P_TOT, BETA_S, SIGMA2)
    c(ok = run_lasso(d_ok$X, d_ok$y, S_TRUE, rule="lambda.min")$esatto,
      bad = run_lasso(d_bad$X, d_bad$y, S_TRUE, rule="lambda.min")$esatto)
  })
  data.frame(n=nn,
    ok = mean(res["ok",]), se_ok = sd(res["ok",])/sqrt(B_N_e3),
    bad = mean(res["bad",]), se_bad = sd(res["bad",])/sqrt(B_N_e3))
})
df_e3 <- bind_rows(results_e3)
plateau <- mean(tail(df_e3$bad, 4))
cat(sprintf("IC soddisfatta a n=3000: %.1f%% | IC violata plateau stimato: %.1f%%\n",
  100*tail(df_e3$ok,1), 100*plateau))

## IC soddisfatta a n=3000: 99.4% | IC violata plateau stimato: 12.6%

ic_ok_label <- sprintf("IC = %.2f (rho = %.2f) - SODDISFATTA", P_S*rho_ok, rho_ok)
ic_bad_label <- sprintf("IC = %.2f (rho = %.2f) - VIOLATA", P_S*rho_bad, rho_bad)

df_e3_long <- df_e3 |>
  pivot_longer(c(ok, bad), names_to="scenario", values_to="prob") |>
  mutate(
    se = ifelse(scenario=="ok", se_ok, se_bad),
    scenario = recode(scenario, "ok"=ic_ok_label, "bad"=ic_bad_label)
  )

# Ricava le coordinate dell'ultimo punto di ciascuna curva per etichette dirette
last_ok <- df_e3_long |> filter(scenario==ic_ok_label) |> slice_max(n, n=1)
last_bad <- df_e3_long |> filter(scenario==ic_bad_label) |> slice_max(n, n=1)

ggplot(df_e3_long, aes(x=n, y=prob, color=scenario, fill=scenario)) +
  geom_ribbon(aes(ymin=pmax(prob-2*se,0), ymax=pmin(prob+2*se,1)),
    alpha=0.10, color=NA)+
  geom_line(linewidth=1.8)+
  geom_point(size=3.0)+
  # Obiettivo teorico: linea tratteggiata in cima
  geom_hline(yintercept=1, linetype="dashed", color="grey40", linewidth=0.8)+
  annotate("text", x=120, y=1.015,
    label="Obiettivo teorico P = 100%",
    size=2.9, color="grey35", hjust=0, fontface="italic")+
  # Etichette dirette a fine curva (sostituiscono la legenda in alto)
  annotate("label",
    x=last_ok$n * 0.72, y=last_ok$prob - 0.11,
    label=ic_ok_label,
    size=2.8, color=COL_AL, fill="white", label.size=0.25,
    hjust=1, fontface="bold")+
  annotate("label",
    x=last_bad$n * 0.80, y=last_bad$prob + 0.11,
    label=ic_bad_label,
    size=2.8, color=COL_LASSO, fill="white", label.size=0.25,
    hjust=1, fontface="bold")+

```


```

scale_color_manual(values=c(COL_AL, COL_LASSO),
                    breaks=c(ic_ok_label, ic_bad_label),
                    name=NULL)+
scale_fill_manual(values=c(COL_AL, COL_LASSO),
                  breaks=c(ic_ok_label, ic_bad_label),
                  guide="none")+
scale_x_log10(
  breaks=n_grid,
  labels=comma_format(),
  name="Dimensione campionaria n")+
scale_y_continuous(
  labels=percent_format(accuracy=1),
  limits=c(0, 1.05),
  breaks=seq(0, 1, 0.25),
  expand=c(0, 0),
  name=expression("P(" ~hat(S) ~" = S" ~"*" ~") - recupero esatto"))+
labs(
  title="Esperimento 3: Aumentare n Non Risolve",
  subtitle=sprintf(
    "Lasso con lambda.min | p = %d variabili, |S*| = %d vere | %d repliche MC per punto",
    P_TOT, P_S, B_N_e3))+
theme(
  legend.position = "none", # etichette dirette: legenda non serve
  plot.margin     = margin(10, 14, 8, 10))

```

Esperimento 3: Aumentare n Non Risolve

Lasso con lambda.min | $p = 3$ variabili, $|S^*| = 2$ vere | 350 repliche MC per punto



Risultato: la curva IC-soddisfatta converge a 100%. la curva IC-violata si stabilizza su un plateau permanente inferiore a 1 — non converge a 0, ma non raggiunge nemmeno 1. Il plateau non è a 0% — il Lasso occasionalmente recupera S^* per fluttuazione del rumore — ma la probabilità non converge. Questo è il Teorema 2.

8 Esperimento 4 — Il Terzetto: Lasso vs Elastic Net vs Adaptive Lasso

Ipotesi: Lasso < Elastic Net < Adaptive Lasso in termini di $P(\hat{S} = S^*)$.

Perché: in presenza di collinearità si ricorre spesso all'Elastic Net. Questo esperimento chiarisce la gerarchia: EN migliora la *stima* (stabilità, bias-varianza) ma non la *selezione* — il grouping effect costringe variabili correlate a entrare insieme, incluso il rumore. L'AL è l'unico che garantisce consistenza senza IC.

```
set.seed(SEED + 30)
results_e4 <- lapply(RHO_GRID, function(rho) {
  ic <- compute_IC(rho, P_S, P_TOT, BETA_S)
  res <- replicate(B_MC, {
    d <- genera_dati(N_MAIN, rho, P_S, P_TOT, BETA_S, SIGMA2)
```

```

    c(lasso = run_lasso(d$X, d$y, S_TRUE)$esatto,
      en = run_en(d$X, d$y, S_TRUE)$esatto,
      al = run_adaptive_lasso(d$X, d$y, S_TRUE)$esatto)
  })
  data.frame(rho = rho, ic = ic,
             lasso = mean(res["lasso",]), se_l = sd(res["lasso",])/sqrt(B_MC),
             en = mean(res["en",]), se_e = sd(res["en",])/sqrt(B_MC),
             al = mean(res["al",]), se_a = sd(res["al",])/sqrt(B_MC))
})
df_e4 <- bind_rows(results_e4)
df_e4_long <- df_e4 |>
  pivot_longer(c(lasso, en, al), names_to = "metodo", values_to = "prob") |>
  mutate(
    se = case_when(metodo == "lasso" ~ se_l,
                   metodo == "en" ~ se_e,
                   TRUE ~ se_a),
    metodo = recode(metodo,
                   "lasso" = "Lasso standard",
                   "en" = "Elastic Net (alpha=0.5)",
                   "al" = "Adaptive Lasso (gamma=1)")
  )

#evita la risimulazione in esp4B-plot
df_e4b_long <- df_e4_long |> dplyr::filter(ic <= 1.20)

```

```

# Esperimento 4a: Solo Lasso vs Elastic Net

```

```

df_e4_le <- df_e4_long |>
  filter(metodo %in% c("Lasso standard", "Elastic Net (alpha=0.5)"))

pal_le <- c("Lasso standard" = COL_LASSO,
           "Elastic Net (alpha=0.5)" = COL_EN)

ggplot(df_e4_le, aes(x = ic, y = prob, color = metodo, fill = metodo)) +
  annotate("rect", xmin = -Inf, xmax = 1, ymin = -Inf, ymax = Inf,
         fill = "#D5F5E3", alpha = 0.35) +
  annotate("rect", xmin = 1, xmax = Inf, ymin = -Inf, ymax = Inf,
         fill = "#FADBD8", alpha = 0.35) +
  geom_ribbon(aes(ymin = pmax(prob - 2*se, 0), ymax = pmin(prob + 2*se, 1)),
            alpha = 0.10, color = NA) +
  geom_line(linewidth = 1.8) +
  geom_point(size = 3.0) +
  geom_vline(xintercept = 1, color = "grey30",
            linewidth = 1.0, linetype = "longdash") +
  annotate("text", x = 1.01, y = 0.95,
         label = "IC = 1", color = "grey30",
         size = 3.0, hjust = 0, fontface = "italic") +
  annotate("text",
         x = 0.70, y = 1.055,
         label = "EN migliora la stima, ma non la selezione - entrambi crollano dopo IC = 1",
         color = "#8B1A1A", size = 3.3, hjust = 0.5, fontface = "italic") +
  annotate("label", x = 0.45, y = 0.62,
         label = "Elastic Net\nstima stabile,\nselezione no",
         size = 2.9, color = COL_EN, fill = "white",

```


```

        label.size = 0.25, fontface = "bold") +
annotate("label", x = 0.45, y = 0.22,
        label = "Lasso\ncrolla a IC = 1",
        size = 2.9, color = COL_LASSO, fill = "white",
        label.size = 0.25, fontface = "bold") +
scale_color_manual(values = pal_le, name = NULL) +
scale_fill_manual(values = pal_le, guide = "none") +
scale_x_continuous(
  name = expression("Valore dell'IC "),
  breaks = seq(0, 1.4, .2),
  limits = c(0, 1.55),
  sec.axis = sec_axis(~./P_S,
                      name = expression("Correlazione "*rho),
                      breaks = seq(0, 0.7, .1))) +
scale_y_continuous(
  labels = percent_format(accuracy = 1),
  limits = c(-0.03, 1.08),
  breaks = seq(0, 1, 0.25),
  expand = c(0, 0),
  name = expression("P(" ~hat(S) ~"= S" ^ "*" ~")")) +
labs(
  title = "Esperimento 4a: Lasso vs Elastic Net",
  subtitle = sprintf(
    "n = %d | %d repliche Monte Carlo | EN non risolve il problema di selezione",
    N_MAIN, B_MC)) +
theme(legend.position = "none",
      plot.margin = margin(10, 14, 8, 10))

```

Esperimento 4a: Lasso vs Elastic Net

n = 500 | 250 repliche Monte Carlo | EN non risolve il problema di selezione



```
# Esperimento 4b: Tutti e tre, grid IC troncato a 1.20

RHO_GRID_AL <- seq(0.05, 0.60, by = 0.05) # IC in [0.10, 1.20]

set.seed(SEED + 30)
results_e4b <- lapply(RHO_GRID_AL, function(rho) {
  ic <- compute_IC(rho, P_S, P_TOT, BETA_S)
  res <- replicate(B_MC, {
    d <- genera_dati(N_MAIN, rho, P_S, P_TOT, BETA_S, SIGMA2)
    c(lasso = run_lasso(d$X, d$y, S_TRUE)$esatto,
      en = run_en(d$X, d$y, S_TRUE)$esatto,
      al = run_adaptive_lasso(d$X, d$y, S_TRUE)$esatto)
  })
  data.frame(rho = rho, ic = ic,
             lasso = mean(res["lasso",]), se_l = sd(res["lasso",])/sqrt(B_MC),
             en = mean(res["en",]), se_e = sd(res["en",])/sqrt(B_MC),
             al = mean(res["al",]), se_a = sd(res["al",])/sqrt(B_MC))
})
df_e4b <- bind_rows(results_e4b)

df_e4b_long <- df_e4b |>
  pivot_longer(c(lasso, en, al), names_to = "metodo", values_to = "prob") |>
  mutate(
```

```

se = case_when(metodo == "lasso" ~ se_l,
               metodo == "en"   ~ se_e,
               TRUE           ~ se_a),
metodo = recode(metodo,
               "lasso" = "Lasso standard",
               "en"    = "Elastic Net (alpha=0.5)",
               "al"    = "Adaptive Lasso (gamma=1)")
)

pal4 <- c("Lasso standard"      = COL_LASSO,
         "Elastic Net (alpha=0.5)" = COL_EN,
         "Adaptive Lasso (gamma=1)" = COL_AL)

ggplot(df_e4b_long, aes(x = ic, y = prob, color = metodo, fill = metodo)) +
  annotate("rect", xmin = -Inf, xmax = 1, ymin = -Inf, ymax = Inf,
         fill = "#D5F5E3", alpha = 0.35) +
  annotate("rect", xmin = 1, xmax = Inf, ymin = -Inf, ymax = Inf,
         fill = "#FADBD8", alpha = 0.35) +
  geom_ribbon(aes(ymin = pmax(prob - 2*se, 0), ymax = pmin(prob + 2*se, 1)),
         alpha = 0.08, color = NA) +
  geom_line(linewidth = 1.8) +
  geom_point(size = 3.0) +
  geom_vline(xintercept = 1, color = "grey30",
            linewidth = 1.0, linetype = "longdash") +
  annotate("text", x = 1.01, y = 0.95,
         label = "IC = 1", color = "grey30",
         size = 3.0, hjust = 0, fontface = "italic") +
  annotate("text",
         x = 0.60, y = 1.055,
         label = "Solo l'Adaptive Lasso mantiene P 100% anche dopo IC = 1",
         color = "#8B1A1A", size = 3.3, hjust = 0.5, fontface = "italic") +
  annotate("label", x = 1.1, y = 0.75,
         label = "AL: consistente\n(proprietà oracolo)",
         size = 2.9, color = COL_AL, fill = "white",
         label.size = 0.25, fontface = "bold") +
  annotate("label", x = 0.50, y = 0.60,
         label = "EN: stima stabile\nma selezione no",
         size = 2.9, color = COL_EN, fill = "white",
         label.size = 0.25, fontface = "bold") +
  annotate("label", x = 0.50, y = 0.20,
         label = "Lasso:\ncrolla a IC = 1",
         size = 2.9, color = COL_LASSO, fill = "white",
         label.size = 0.25, fontface = "bold") +
  scale_color_manual(values = pal4, name = NULL) +
  scale_fill_manual(values = pal4, guide = "none") +
  scale_x_continuous(
    name = expression("Valore dell'IC "),
    breaks = seq(0, 1.2, .2),
    limits = c(0, 1.30),
    sec.axis = sec_axis(~./P_S,
                      name = expression("Correlazione "*rho),
                      breaks = seq(0, 0.6, .1))) +
  scale_y_continuous(
    labels = percent_format(accuracy = 1),

```


```

limits = c(-0.03, 1.08),
breaks = seq(0, 1, 0.25),
expand = c(0, 0),
name = expression("P(" ~ hat(S) ~ "=" ~ S ~ "^*" ~ ")") +
labs(
  title = "Esperimento 4b: Gerarchia completa - Lasso vs EN vs Adaptive Lasso",
  subtitle = sprintf(
    "n = %d | %d repliche MC ",
    N_MAIN, B_MC)) +
theme(legend.position = "none",
      plot.margin = margin(10, 14, 8, 10))

```

Esperimento 4b: Gerarchia completa — Lasso vs EN vs Adaptive

n = 500 | 250 repliche MC



Risultato: le tre curve si separano nettamente dopo $IC = 1$, confermando la gerarchia teorica. Lasso crolla immediatamente alla soglia. Elastic Net mantiene una probabilità intermedia (~50%) risultando peggio del Lasso perché il *grouping effect* aiuta la stima, ma non la selezione: include sistematicamente anche le variabili rumore correlate con quelle vere. L'Adaptive Lasso rimane vicino al 100% sull'intero intervallo testato fino a $IC = 1.20$, resistendo brillantemente dove le altre penalizzazioni crollano. (Nota: per livelli estremi di collinearità, come $\rho > 0.65$, anche l'AL inizierebbe a cedere a causa della distorsione della stima Ridge usata per i pesi iniziali, ma il suo vantaggio rimane netto nella finestra analizzata).

Messaggio chiave: L'AL è molto resistente e robusto rispetto al Lasso standard soprattutto dopo l'intervallo $IC > 1$.

9 Esperimento 5 — L'Illusione della Cross-Validation

Ipotesi: la CV ottimizza l'errore di *predizione* (MSE), non la correttezza della selezione. Con IC violata, la CV sceglie un λ che include variabili rumore perché queste migliorano la previsione out-of-sample.

Perché è necessario: un analista potrebbe obiettare “uso la CV per trovare il λ giusto”. Questo è l'errore più diffuso. La CV non conosce la differenza tra segnale e rumore correlato: entrambi abbassano il MSE. Mostriamo il regularization path annotato con i modelli scelti dalla CV, evidenziando i FP invisibili all'ottimizzatore.

Design: $p = 10$, $|S^*| = 2$, variabili false = combinazione lineare delle vere + piccolo rumore ($\rho \approx 0.97$, IC $\gg 1$). La scelta di costruire le variabili false esplicitamente (non via Σ a blocchi) permette di raggiungere correlazioni molto alte senza problemi di matrice non definita positiva.

```
set.seed(2026)
n_cv <- 500; p_s_cv <- 2; p_tot_cv <- 10
beta_cv_s <- c(3, 3)

X_vere <- matrix(rnorm(n_cv * p_s_cv), nrow = n_cv)
X_false <- vapply(seq_len(p_tot_cv - p_s_cv), function(j)
  0.85 * X_vere[, 1] + 0.85 * X_vere[, 2] + rnorm(n_cv, 0, 0.4),
  numeric(n_cv))
X_cv <- scale(cbind(X_vere, X_false))
beta_full <- c(beta_cv_s, rep(0, p_tot_cv - p_s_cv))
y_cv <- drop(X_cv %*% beta_full + rnorm(n_cv))
S_true_cv <- seq_len(p_s_cv)

# IC empirica
C_emp <- cor(X_cv)
ic_emp <- max(abs(C_emp[(p_s_cv + 1):p_tot_cv, 1:p_s_cv] %*%
  solve(C_emp[1:p_s_cv, 1:p_s_cv]) %*%
  sign(beta_cv_s)))

# fit
fit_path <- glmnet(X_cv, y_cv, alpha = 1, nlambda = 120, standardize = FALSE)
fit_cv5 <- cv.glmnet(X_cv, y_cv, alpha = 1, nfolds = 10)

lam_min <- fit_cv5$lambda.min
lam_1se <- fit_cv5$lambda.1se

# FP/FN scalari per il testo inline
coef_min <- abs(coef(fit_cv5, s = "lambda.min"))[-1]
coef_1se <- abs(coef(fit_cv5, s = "lambda.1se"))[-1]
fp_min <- length(setdiff(which(coef_min > 1e-8), S_true_cv))
fn_min <- length(setdiff(S_true_cv, which(coef_min > 1e-8)))
fp_1se <- length(setdiff(which(coef_1se > 1e-8), S_true_cv))
fn_1se <- length(setdiff(S_true_cv, which(coef_1se > 1e-8)))

# costruisci df del path
beta_mat <- as.matrix(t(coef(fit_path)[-1, ])) # righe = lambda, colonne = variabili
lam_vec <- fit_path$lambda

df_path <- as.data.frame(beta_mat)
colnames(df_path) <- c(paste0("X", 1:p_s_cv, " [VERA]"),
  paste0("X", (p_s_cv+1):p_tot_cv, " [falsa]"))
```

```

df_path$lambda <- lam_vec
df_path$log_lambda <- log(lam_vec)

df_long <- df_path |>
  pivot_longer(~c(lambda, log_lambda),
    names_to = "variabile", values_to = "coef") |>
  mutate(tipo = ifelse(grepl("VERA", variabile), "vera", "falsa"))

# Trova il primo lambda in cui ogni variabile entra (|coef| > 1e-4)
entry_points <- df_long |>
  filter(abs(coef) > 1e-4) |>
  group_by(variabile, tipo) |>
  summarise(lambda_entry = max(lambda), .groups = "drop") |> # max = primo lambda (path decresce)
  mutate(log_lambda_entry = log(lambda_entry))

# Valore del coef all'estremo sinistro (lambda piccolo) per posizionare etichette
label_pos <- df_long |>
  filter(lambda == min(lambda)) |>
  select(variabile, tipo, coef_end = coef)

# plot
col_vera <- COL_S # "#1D3557" blu scuro
col_falsa <- COL_LASSO # "#E63946" rosso

# Coordinate log dei lambda CV
log_min <- log(lam_min)
log_1se <- log(lam_1se)

# Modifica del plot per massimizzare la chiarezza dei FP

ggplot(df_long, aes(x = log_lambda, y = coef, group = variabile, color = tipo)) +

  # 1. Zona di contaminazione (evidenzia visivamente dove cade la scelta)
  # Estendiamo leggermente l'area per far capire che l'intera zona CV è "infetta"
  annotate("rect", xmin = log_min - 0.2, xmax = log_1se + 0.2,
    ymin = -0.1, ymax = 0.6, fill = "#FFD7D7", alpha = 0.3) +

  # 2. Linee del path (spesse per le vere, sottili per le false)
  geom_line(data = filter(df_long, tipo == "falsa"), linewidth = 0.6, alpha = 0.4) +
  geom_line(data = filter(df_long, tipo == "vera"), linewidth = 1.5, alpha = 0.9) +

  # 3. Linee di selezione
  geom_vline(xintercept = log_min, color = "black", linetype = "dashed", linewidth = 0.8) +
  geom_vline(xintercept = log_1se, color = "black", linetype = "dotted", linewidth = 0.8) +

  # 4. Annotazioni "FP" più aggressive con allineamento ottimizzato per l'asse standard
  annotate("text", x = log_min, y = 0.65, label = sprintf(".min\n(%d FP)", fp_min),
    color = "#8B0000", size = 3.5, fontface = "bold", vjust = 0, hjust = 1.1) +
  annotate("text", x = log_1se, y = 0.65, label = sprintf(".1se\n(%d FP)", fp_1se),
    color = "#8B0000", size = 3.5, fontface = "bold", vjust = 0, hjust = -0.1) +

  # 5. Focus visivo sulla "sopravvivenza" del rumore (su ENTRAMBE le scelte)
  # Disegniamo dei segmenti/punti che indicano quante linee rosse intersecano le linee verticali
  geom_point(data = filter(df_long, tipo == "falsa" & abs(log_lambda - log_min) < 0.05),

```

```

    aes(x = log_min, y = coef), color = col_falsa, size = 1.5) +
geom_point(data = filter(df_long, tipo == "falsa" & abs(log_lambda - log_1se) < 0.05),
    aes(x = log_1se, y = coef), color = col_falsa, size = 1.5) +

# scale
scale_color_manual(values = c("vera" = col_vera, "falsa" = col_falsa),
    labels = c("vera" = "Variabile VERA (S*)",
        "falsa" = "Variabile falsa (-S*)"),
    name = NULL) +

# MODIFICA ASSE X: Ora è continuo (crescente), senza scale_x_reverse
scale_x_continuous(name = expression("Penalizzazione crescente " %>% " " * log(lambda))) +
scale_y_continuous(name = "Coefficiente stimato",
    limits = c(-0.1, 3.15),
    breaks = seq(0, 3, 0.5)) +


labs(
    title = "Esperimento 5: La CV non risolve il problema",
    subtitle = sprintf(
        "IC empirica = %.2f >> 1 | p = %d variabili, di cui %d vere | n = %d ",
        ic_emp, p_tot_cv, p_s_cv, n_cv)) +

theme(
    legend.position = "top",
    legend.text = element_text(size = 10, face = "bold"),
    plot.margin = margin(10, 40, 8, 10)
)

```

Esperimento 5: La CV non risolve il problema

IC empirica = 1.36 >> 1 | $p = 10$ variabili, di cui 2 vere | $n = 500$



Tre takeaway finali:

1. **IC e' una condizione sulla struttura di X :** $\|C_{21}C_{11}^{-1}\text{sign}(\beta_{S^*}^*)\|_\infty < 1$ dipende dalla geometria della matrice di design — raccogliere piu' dati non la modifica.
2. **La CV non e' un antidoto.** Ottimizza la previsione, non la selezione causale. Con IC violata, rumore e segnale sono indistinguibili per il criterio MSE.
3. **L'Adaptive Lasso ripristina la consistenza.** I pesi $w_j \propto |\hat{\beta}_j^{\text{Ridge}}|^{-\gamma}$ emulano la penalizzazione oracolo: $\gamma = 1$ con Ridge e' il punto di partenza raccomandato.

9.1 Riferimenti

- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *JRSS-B*, 58(1), 267–288.
- Zhao, P., & Yu, B. (2006). On model selection consistency of lasso. *JMLR*, 7, 2541–2563.
- Zou, H. (2006). The adaptive lasso and its oracle properties. *JASA*, 101(476), 1418–1429.
- Zou, H., & Hastie, T. (2005). Regularization and variable selection via the elastic net. *JRSS-B*, 67(2), 301–320.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer.