

La Condizione di Irrapresentabilità del Lasso

*Il Limite Invalicabile del LASSO nella Selezione delle
Variabili*

AUTORE:

Lorenzo Maria Pennelli



UNIVERSITÀ
DEGLI STUDI
FIRENZE

Da un secolo, oltre.

Contesto: Lasso

Un metodo di regolarizzazione che minimizza i residui applicando una penalità L1, forzando i coefficienti meno importanti esattamente a zero.

$$\hat{\beta}^{LASSO} = \arg \min_{\beta \in \mathbb{R}^p} \left\{ \frac{1}{2n} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1 \right\}$$

Punti di Forza

- **Selezione delle variabili:** annulla l'impatto dei predittori inutili, eliminandoli di fatto dal modello. Modelli più snelli e interpretabili.
- **Gestione dell'alta dimensionalità:** funziona quando il numero di variabili è molto maggiore del numero di osservazioni.
- **Previene l'overfitting**

Limitazioni

- **Gestione della multicollinearità:** variabili altamente correlate, **Lasso** ne sceglie arbitrariamente.
- **Dipendenza dalla scala dei dati**
- **Parametro λ da tunare**
- **Consistenza Condizionata:** selezione del vero supporto non sempre garantita (*violazione della proprietà Oracle*).

Contesto: Proprietà Oracle

capacità di una procedura di selezionare il vero modello e stimare i parametri con la stessa accuratezza che si avrebbe conoscendo a priori le variabili realmente rilevanti.

Consistenza nella Selezione

Il metodo identifica correttamente le variabili realmente rilevanti e scarta quelle irrilevanti. All'aumentare dei dati, la probabilità di selezionare il modello corretto tende a 1

$$P(\hat{S} = S^*) \rightarrow 1 \quad \text{per } n \rightarrow \infty$$

$$S^* = \{j: \beta_j^* \neq 0\}$$

✓ Trova le variabili giuste

✓ Elimina il rumore

Normalità asintotica

Dopo aver individuato le variabili corrette, il metodo stima i coefficienti con la stessa precisione che si avrebbe conoscendo il modello vero in anticipo. Le stime diventano sempre più accurate

$$\sqrt{n}(\hat{\beta}_{S^*} - \beta_{S^*}^*) \xrightarrow{d} N(0, \Sigma_{\text{oracle}})$$

✓ Stime precise


✓ Inferenza statistica affidabile

*Il Lasso ha buone proprietà di Oracolo quando le variabili rilevanti non sono altamente correlate con le variabili rumore (**Irrepresentable Condition**)*

La Condizione di Irrapresentabilità

$$\|C_{21}^n (C_{11}^n)^{-1} \text{sgn}(\beta_{S^*}^*)\|_{\infty} < 1$$

Matrice empirica di Gram



- ### Cosa Misura

$C_{21}^n (C_{11}^n)^{-1} \text{sgn}(\beta^*)$ = **coefficiente OLS** di ogni variabile **falsa** sulle variabili **vere, proiettato** nella direzione del segnale.

→ *Quanto una variabile inattiva è "spiegata" dalle attive.*

- ### Intuizione geometrica

Se la norma ≥ 1 , una variabile rumore può essere scritta come **combinazione lineare** delle vere → il Lasso non la azzera.

→ *La variabile falsa è troppo "rappresentabile" dalle vere.*

- ### Implicazione

Il successo della selezione delle variabili non dipende da quanti dati raccogli, ma da come sono correlate tra loro le variabili nel dataset.

→ *corretta selezione delle variabili è una proprietà intrinseca della geometria del dataset*

Setup Esperimenti

Data Generating Process

$$Y = 3X_1 + 3X_2 + 0X_3 + \epsilon \quad \epsilon \sim \mathcal{N}(0,1)$$

$$X_1, X_2 \sim \mathcal{N}(0,1) \quad (\text{Variabili Causali indipendenti})$$

$$X_3 = \rho X_1 + \rho X_2 + \sqrt{1 - 2\rho^2} Z_3 \quad (\text{Variabile Rumore Correlata con Var}=1)$$

Semplificazione Analitica

Condizione teorica

$$\|C_{21}C_{11}^{-1}\text{sign}(\beta_{S^*})\|_{\infty} < 1$$



Sostituzione blocchi

$$C_{11}^{-1} = I \quad (X_1, X_2 \text{ indipendenti})$$

$$C_{21} = (\rho, \rho) \quad (\text{Correlazione con le vere})$$

$$\text{sign}(\beta_{S^*}) = (1,1) \quad (\text{segni positivi})$$



Risultato

$$(\rho, \rho) \cdot I \cdot \begin{pmatrix} 1 \\ 1 \end{pmatrix} = 2\rho < 1$$


Esperimento 1 — L'effetto della violazione IC

Setup:

$n=500$, $nsim = 250$, regola λ_{1se} (CV)

Esperimento 1: La Transizione di Fase

$n = 500$ | 250 repliche Monte Carlo | fascia ± 2 errori standard





Esperimento 2 — Perché il Lasso fallisce

Setup:

$n = 500$, $nsim = 250$, regola λ_{1se} (CV)

Esperimento 2: Anatomia del Fallimento del Lasso


Il Lasso non perde il segnale — viene contaminato dal rumore correlato | $n=500$, $B=250$ MC



Esperimento 3 — La dimensione campionaria

Setup:

nsim = 350, n crescente, regola lambda.min (CV), due scenari (IC = 0,20 e IC = 1,30)



Possibili Tentativi: Cross Validation ed Elastic Net

Se non è possibile cambiare i dati che violano questa caratteristica cosa possiamo fare?

Cross Validation

$$\min_{\lambda} MSE_{CV}$$

- **Delega** la scelta del parametro λ ai **dati**, **minimizzando l'errore** di predizione.
- Trovare il giusto equilibrio ("**trade-off**") tra **bias** e **varianza** in modo oggettivo, senza dover indovinare il parametro di regolarizzazione.
- **Suddividere** il dataset, **addestra** il modello **su una parte** e ne **testa** le capacità predittive **sull'altra** per trovare il λ che generalizza meglio
- **Aspettativa:** *La CV sceglierà un λ abbastanza severo da azzerare il rumore pur trattenendo il segnale causale.*

Elastic Net

$$\widehat{\beta}^{EN} = \arg \min_{\beta} \frac{1}{2n} \|y - X\beta\|_2^2 + \lambda[\alpha\|\beta\|_1 + (1 - \alpha)\|\beta\|_2^2]$$

- Aggiunge una **penalità L_2** al Lasso per gestire la forte **collinearità**
- Invece di selezionare una **sola variabile** a caso tra quelle correlate, tende a **includerle** o escluderle tutte in **blocco (Grouping Effect)**
- Superare l'instabilità del Lasso quando le variabili sono altamente correlate tra loro
- **Aspettativa:** *Stabilizzare le stime e migliorare il recupero del supporto S^**


Esperimenti 4, 5: Il collasso della CV ed Elastic Net

Setup:

10 variabili di cui 2 vere e restanti correlate, $n=500$, regola λ_{1se} e λ_{min} , singola simulazione

Esperimento 5: La CV non risolve il problema

IC empirica = 1.36 >> 1 | $p = 10$ variabili, di cui 2 vere | $n = 500$




- Entrambi i criteri falliscono, **lambda.min** include 6 falsi positivi; **lambda.1se** ne include 8. Il supporto vero non viene mai isolato.
- La **CV** ottimizza esclusivamente l'errore di predizione (**MSE**). Se $IC > 1$ il **rumore correlato** abbassa l'errore predittivo *quasi* quanto il **segnale vero**. L'algoritmo li considera **equivalenti**.

Setup:

DGP classico, $n = 500$, $nsim = 250$, regola λ_{1se} (CV), $\alpha = 0.5$

Esperimento 4 Lasso vs Elastic Net

$n = 500$ | 250 repliche Monte Carlo | EN non risolve il problema di selezione



- La probabilità di recupero esatto $P(\hat{S} = S^*)$ crolla appena si supera la soglia critica $IC=1$.
- Il **Grouping Effect**: costringe le variabili correlate a entrare nel modello insieme. Se IC violata, EN le include sistematicamente. **Migliora la stima, ma distrugge la selezione.**

L' Adaptive Lasso

Definizione

Estensione del Lasso che **assegna una penalizzazione diversa a ciascun coefficiente**, anziché utilizzare una penalizzazione uniforme.

Meccanismo

Modifica la **funzione obiettivo** introducendo dei **pesi adattivi** (w_j).
I pesi derivano da una **stima preliminare** dei coefficienti (**OLS**, **Ridge**, **Lasso**, **Elastic Net**).

$$\widehat{\beta}^{AL} = \arg \min_{\beta} \left\{ \frac{1}{2n} \|y - X\beta\|^2 + \lambda \sum_{j=1}^p w_j |\beta_j| \right\}$$
$$w_j = \frac{1}{|\widehat{\beta}_j^{init}|^{\gamma}}$$

Proprietà

✓ Penalizzazione adattiva

Le variabili importanti vengono penalizzate meno.
Le variabili poco rilevanti vengono penalizzate molto.

✓ Riduzione del bias verso zero

✓ Consistenza nella selezione

seleziona le variabili corrette con probabilità che tende a 1 $P(S^{\wedge}=S) \rightarrow 1$
Rispetta così le **Oracle Property** (sotto alcune ipotesi)

✗ **Richiede una stima preliminare affidabile dei coefficienti.**

✗ **La scelta dei pesi influenza il risultato finale.**

Esp. 6 — Lasso vs Elastic Net vs Adaptive Lasso

Setup:

$n = 500$, $nsim = 250$, regola λ_{1se} , inizializzazione Ridge

- Lasso**

Buono per selezione però cala drasticamente superata soglia

- Elastic Net**


Per Grouping Effect peggiore nella selezione tende a raccogliere più spesso il rumore

- Adaptive Lasso**

È la soluzione ideale in questo scenario. Riesce a essere rigoroso e robusto anche sotto stress

Esperimento 6: Gerarchia completa — Lasso vs EN vs Adaptive

$n = 500$ | 250 repliche MC



Conclusioni - Riepilogo

- **Il fallimento del Lasso è strutturale e deterministico:** la capacità del Lasso standard di selezionare il modello corretto non degrada in modo lineare, ma **crolla verticalmente** e drasticamente non appena la **Irrepresentable Condition (IC)** supera o eguaglia il valore di 1
- **La contaminazione da falsi positivi:** quando l'IC viene violata, il Lasso non fallisce perdendo le variabili rilevanti (i FN rimangono prossimi allo zero), ma viene "**contaminato**" **includendo rumore** che non viene risolto nemmeno con l'aumento della **dimensionalità campionaria**
- **L'illusione della Cross-Validation:** affidarsi a parametri come **lambda.min** o **lambda.1se** in presenza di variabili false ma correlate al segnale porta **all'inclusione di innumerevoli Falsi Positivi** che sfuggono al controllo della CV.
- **L'Adaptive Lasso come reale contromisura:** gode delle cosiddette **proprietà oracolo**, penalizzando in modo inversamente proporzionale a una stima iniziale (come la Ridge), riesce a mantenere una **probabilità di corretta selezione** prossima al **100%** anche in regioni in cui l'IC è **ampiamente violata**.

References

- Slides del corso riguardanti *Lasso, Adaptive Lasso, Elastic Net e Cross Validation*
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. JRSS-B, 58(1), 267–288.
- Zhao, P., & Yu, B. (2006). On model selection consistency of lasso. JMLR, 7, 2541–2563.
- Zou, H. (2006). The adaptive lasso and its oracle properties. JASA, 101(476), 1418–1429.
- Claude e Gemini per aiuto sul codice e impaginazione slide