

Bias da Variabile Omessa

Un Esperimento Monte Carlo

Francesco Faillace

Introduzione

In questo elaborato analizziamo le conseguenze statistiche dell'esclusione di una variabile esplicativa rilevante da un modello di regressione lineare, mediante simulazione Monte Carlo.

Il processo generatore dei dati (DGP) è il seguente:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + u_i, \quad u_i \sim N(0, 1)$$

dove i regressori sono estratti da una distribuzione normale bivariata:

$$\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \sim N_2(\mathbf{0}, \Sigma)$$

Vengono considerati due scenari distinti, che differiscono unicamente per la struttura di correlazione tra x_1 e x_2 :

- **Scenario A** — variabili correlate: $\Sigma = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix}$
- **Scenario B** — variabili indipendenti: $\Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$

Per ciascun scenario, ad ogni iterazione si stimano due versioni del modello: una che include entrambi i predittori (x_1 e x_2) e una che omette x_2 , salvando in entrambi i casi la stima $\hat{\beta}_1$.

Setup e generazione dei dati

Fissiamo il seme per garantire la riproducibilità dei risultati e definiamo i parametri della simulazione. La scelta $\beta_2 = -2$ con correlazione positiva $\rho = 0.5$ nello Scenario A produrrà un bias negativo ben visibile, come vedremo.

```
set.seed(42)

# Dimensione campionaria e numero di repliche Monte Carlo
n      <- 1000
n_sim  <- 1000

# Valori veri dei parametri
b0 <- 0
b1 <- 1
b2 <- -2

# Matrici di covarianza
```

```

Sigma_A <- matrix(c(1, 0.5, 0.5, 1), nrow = 2) # correlazione rho = 0.5
Sigma_B <- matrix(c(1, 0.0, 0.0, 1), nrow = 2) # indipendenza rho = 0

library(MASS)

# Funzione che genera un data.frame (y, x1, x2) dato Sigma
genera_campione <- function(Sigma) {
  X <- mvrnorm(n, mu = c(0, 0), Sigma = Sigma)
  u <- rnorm(n, mean = 0, sd = 1)
  y <- b0 + b1 * X[, 1] + b2 * X[, 2] + u
  data.frame(y = y, x1 = X[, 1], x2 = X[, 2])
}

```

Stima OLS: modello omissivo vs modello corretto

La funzione `stima_beta1` esegue due regressioni OLS sullo stesso campione e restituisce la stima di β_1 in entrambi i casi:

- **modello ridotto:** $y \sim x_1$ — ignora x_2
- **modello completo:** $y \sim x_1 + x_2$ — specifica correttamente il DGP

```

stima_beta1 <- function(dati) {
  mod_ridotto <- lm(y ~ x1, data = dati)
  mod_completo <- lm(y ~ x1 + x2, data = dati)
  c(
    ridotto = unname(coef(mod_ridotto)["x1"]),
    completo = unname(coef(mod_completo)["x1"])
  )
}

```

```

# Verifica su un singolo campione
cat("--- Singolo campione: Scenario A ---\n")

```

```
## --- Singolo campione: Scenario A ---
```

```
stima_beta1(genera_campione(Sigma_A))
```

```
##      ridotto      completo
## -0.04373778  1.00570184
```

```
cat("\n--- Singolo campione: Scenario B ---\n")
```

```
##
## --- Singolo campione: Scenario B ---
```

```
stima_beta1(genera_campione(Sigma_B))
```

```
##      ridotto      completo
##  1.0021627  0.9436065
```

Già su un campione singolo si intravede il fenomeno: nello Scenario A il modello ridotto fornisce una stima di $\hat{\beta}_1$ molto distante da 1, mentre nello Scenario B rimane vicina al valore vero. Tuttavia, un'unica replica non è sufficiente a trarre conclusioni robuste: potrebbe trattarsi di fluttuazione casuale. La simulazione Monte

Carlo risolve questo limite.

Simulazione Monte Carlo

Ripetiamo l'esperimento 1000 volte, raccogliendo in quattro vettori le stime $\hat{\beta}_1$ per ogni combinazione scenario-modello.

```
# Contenitori per le stime
rid_A <- numeric(n_sim)
comp_A <- numeric(n_sim)
rid_B <- numeric(n_sim)
comp_B <- numeric(n_sim)

for (i in seq_len(n_sim)) {
  sA <- stima_beta1(genera_campione(Sigma_A))
  sB <- stima_beta1(genera_campione(Sigma_B))
  rid_A[i] <- sA["ridotto"]
  comp_A[i] <- sA["completo"]
  rid_B[i] <- sB["ridotto"]
  comp_B[i] <- sB["completo"]
}

# Medie Monte Carlo
round(c(
  "E[b1] rid. A" = mean(rid_A),
  "E[b1] comp. A" = mean(comp_A),
  "E[b1] rid. B" = mean(rid_B),
  "E[b1] comp. B" = mean(comp_B),
  "Valore vero" = b1
), 3)
```

##	E[b1] rid. A	E[b1] comp. A	E[b1] rid. B	E[b1] comp. B	Valore vero
##	-0.002	0.998	0.996	0.999	1.000

I risultati numerici anticipano già le conclusioni: il modello ridotto nello Scenario A converge verso 0 anziché verso 1, coerentemente con il bias teorico atteso:

$$\text{Bias}(\hat{\beta}_1) = \beta_2 \cdot \frac{\text{Cov}(x_1, x_2)}{\text{Var}(x_1)} = -2 \cdot \frac{0.5}{1} = -1$$

Grafici di convergenza

Prima di analizzare le distribuzioni finali, verifichiamo la stabilità delle medie Monte Carlo al crescere del numero di repliche. Se la simulazione è ben calibrata, le medie cumulate devono smettere di oscillare e assestarsi su valori stabili ben prima dell'ultima iterazione.

```
# Colori
c_rid <- "#C0392B" # rosso - modello ridotto
c_comp <- "#1A6E74" # teal - modello completo
c_vero <- "#6C3483" # viola - valore vero

iterazioni <- seq_len(n_sim)

# Medie cumulate
cum_rid_A <- cumsum(rid_A) / iterazioni
```

```


cum_comp_A <- cumsum(comp_A) / iterazioni
cum_rid_B <- cumsum(rid_B) / iterazioni
cum_comp_B <- cumsum(comp_B) / iterazioni

par(mfrow = c(1, 2), mar = c(4, 4, 3, 2))

# --- Scenario A ---
ylim_A <- range(cum_rid_A, cum_comp_A, b1)
plot(iterazioni, cum_rid_A,
     type = "l", col = c_rid, lwd = 1.8,
     ylim = ylim_A,
     xlab = "Iterazioni", ylab = expression(bar(hat(beta))[1]),
     main = "Scenario A (rho = 0.5)")
lines(iterazioni, cum_comp_A, col = c_comp, lwd = 1.8)
abline(h = b1, col = c_vero, lwd = 2, lty = 2)
legend("right",
     legend = c("Modello ridotto", "Modello completo",
                 expression(beta[1] == 1)),
     col = c(c_rid, c_comp, c_vero),
     lty = c(1, 1, 2), lwd = 2, bty = "n", cex = 0.85)

# --- Scenario B ---
ylim_B <- range(cum_rid_B, cum_comp_B, b1)
plot(iterazioni, cum_rid_B,
     type = "l", col = c_rid, lwd = 1.8,
     ylim = ylim_B,
     xlab = "Iterazioni", ylab = expression(bar(hat(beta))[1]),
     main = "Scenario B (rho = 0)")
lines(iterazioni, cum_comp_B, col = c_comp, lwd = 1.8)
abline(h = b1, col = c_vero, lwd = 2, lty = 2)
legend("right",
     legend = c("Modello ridotto", "Modello completo",
                 expression(beta[1] == 1)),
     col = c(c_rid, c_comp, c_vero),
     lty = c(1, 1, 2), lwd = 2, bty = "n", cex = 0.85)

```



Il grafico di sinistra mostra con chiarezza il bias dello Scenario A: la curva rossa (modello ridotto) si stabilizza intorno a 0, mentre quella teal (modello completo) converge a 1. Nel grafico di destra entrambe le curve si sovrappongono e convergono al valore vero, a conferma che senza correlazione tra i regressori il bias non si manifesta.

Distribuzioni Monte Carlo

I quattro istogrammi seguenti mostrano la distribuzione empirica di $\hat{\beta}_1$ per ogni combinazione scenario-modello. La linea viola tratteggiata indica il valore vero $\beta_1 = 1$; la linea continua colorata indica la media delle 1000 stime.

```
c_fill <- "#E8F4F8"

par(mfrow = c(2, 2), mar = c(4, 4, 3.5, 1))


# helper per tracciare un pannello
pannello <- function(valori, titolo, colore_dens) {
  hist(valori,
    probability = TRUE,
    main = titolo,
    xlab = expression(hat(beta)[1]),
    col = c_fill,
    border = "white",
    breaks = 30)
  lines(density(valori), col = colore_dens, lwd = 2.5)
  abline(v = b1, col = c_vero, lwd = 2, lty = 2)
  abline(v = mean(valori), col = colore_dens, lwd = 2, lty = 1)
  legend("topright",
```

```

legend = c("Densità stimata",
           expression(beta[1] == 1),
           expression(E(hat(beta)[1]))),
col = c(colore_dens, c_vero, colore_dens),
lty = c(1, 2, 1), lwd = 2, bty = "n", cex = 0.8)
}

pannello(rid_A, "Scenario A - Modello ridotto", c_rid)
pannello(comp_A, "Scenario A - Modello completo", c_comp)
pannello(rid_B, "Scenario B - Modello ridotto", c_rid)
pannello(comp_B, "Scenario B - Modello completo", c_comp)

```



Interpretazione dei risultati

Scenario A ($\rho = 0.5$ — variabili correlate):

- *Modello ridotto*: la distribuzione è centrata su circa 0, con uno scarto di -1 rispetto al valore vero. L'effetto negativo di x_2 su y viene erroneamente attribuito a x_1 , trascinandone la stima verso il basso.

Il bias è deterministico e prevedibile.

- *Modello completo*: la distribuzione è centrata su 1. Specificare correttamente il modello annulla il bias.

Scenario B ($\rho = 0$ — variabili indipendenti):

- *Modello ridotto*: la distribuzione rimane centrata su 1. L'assenza di correlazione tra x_1 e x_2 impedisce al meccanismo del bias di attivarsi. Si osserva però una dispersione leggermente maggiore rispetto al modello completo: omettere una variabile rilevante aumenta la varianza dello stimatore.
 - *Modello completo*: distribuzione centrata su 1 e più concentrata rispetto al modello ridotto.
-

Conclusioni

L'esperimento Monte Carlo permette di verificare empiricamente un risultato ben noto in econometria. Il bias da variabile omessa si manifesta **esclusivamente** quando sono soddisfatte entrambe le condizioni seguenti:

1. La variabile esclusa esercita un effetto causale sulla variabile dipendente ($\beta_2 \neq 0$).
2. La variabile esclusa è correlata con almeno uno dei regressori inclusi nel modello ($\text{Cov}(x_1, x_2) \neq 0$).

Se una sola di queste condizioni viene meno, le stime restano non distorte. Tuttavia, escludere una variabile rilevante aumenta sempre la varianza delle stime — un costo in termini di precisione che persiste anche in assenza di bias.