Problema della Variabile Omessa

Simulazione Monte Carlo

Eros Pinzani

Impostare un esperimento di Monte Carlo per capire le conseguenze dell'omissione di una covariata rilevante.

<u>DGP</u>

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + u_i \tag{1}$$

$$\epsilon_i \sim N(0, 1) \tag{2}$$

$$x_1, x_2 \sim N_2(\underline{0}, \Sigma) \tag{3}$$

Nello scenario 1:

$$\Sigma = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix}$$

Nello scenario 2:

$$\Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Ad ogni simulazione:

1. Generare i dati da scenario 1
2. Stimare i parametri di un modello di regressione lineare con solo x_1 come predittore. Salvare la stima di β_1.
3. Stimare i parametri di un modello di regressione lineare con x_1 e x_2 come predittori. Salvare la stima di β_1.

Confrontare le distribuzioni Monte Carlo per i due scenari.
<u>Nota Bene</u>: Provare cosa succede al variare di β_1 e β_2. Provate ad esempio $\beta_1 = 1$ e $\beta_2 = -2$.

Obiettivo

Omissione di una variabile rilevante: si stima un modello di regressione lineare escludendo un predittore che, nel processo generatore dei dati reale, ha un effetto non nullo sulla variabile dipendente.

Questo notebook costruisce un **esperimento di Monte Carlo** per studiare le conseguenze di questa omissione sullo stimatore OLS di β_1. In particolare, vogliamo rispondere a due domande:

1. **Quando l'omissione distorce le stime?** La risposta dipende dalla correlazione tra la variabile omessa e i regressori inclusi nel modello.
2. **Di quanto?** La direzione e l'entità del bias dipendono sia dalla correlazione tra le covariate sia dall'effetto della variabile omessa sulla risposta.

Per isolare questi due effetti, confrontiamo due scenari:

- **Scenario 1**: x_1 e x_2 sono correlate ($\rho = 0.5$). L'omissione di x_2 inquina la stima di $\hat{\beta}_1$.
- **Scenario 2**: x_1 e x_2 sono indipendenti ($\rho = 0$). L'omissione di x_2 non introduce distorsione.

Ripetendo l'esperimento 20 000 volte, la distribuzione Monte Carlo di $\hat{\beta}_1$ rende visibile se lo stimatore è centrato sul valore vero $\beta_1 = 1$ oppure sistematicamente distorto.

Generazione dei dati

Prima di tutto fissiaomo un seme casuale (`set.seed`) per garantire la **riproducibilità** dei risultati: chiunque esegua il codice otterrà esattamente gli stessi numeri casuali.

Definimamo poi i **parametri veri** del DGP:

- $n = 1000$: numero di osservazioni per ogni simulazione.
- $\beta_0 = 0$, $\beta_1 = 1$, $\beta_2 = -2$: coefficienti veri del modello. Sono i valori che vogliamo vedere se riusciamo a recuperare o meno con la stima OLS.
- `sigma1` e `sigma2`: matrici di covarianza che determinano la struttura di dipendenza tra x_1 e x_2. Nello **Scenario 1** le due variabili sono correlate ($\rho = 0.5$), nello **Scenario 2** sono indipendenti ($\rho = 0$).

La funzione `generate_data(sigma)` incapsula tutta la logica di generazione: campiona le covariate dalla distribuzione normale bivariata usando `mvrnorm` (pacchetto `MASS`), genera il termine di errore $u_i \sim N(0, 1)$ e costruisce y secondo il DGP.

```r
set.seed(123)
n <- 1000
beta_0 <- 0
beta_1 <- 1
beta_2 <- -2
sigma1 <- matrix(c(1, 0.5, 0.5, 1), nrow = 2)
sigma2 <- matrix(c(1, 0, 0, 1), nrow = 2)
library(MASS)
# Funzione per generare i dati
generate_data <- function(sigma) {
    x <- mvrnorm(n, mu = c(0, 0), Sigma = sigma)
    u <- rnorm(n, mean = 0, sd = 1)
    y <- beta_0 + beta_1 * x[, 1] + beta_2 * x[, 2] + u
    data.frame(y = y, x1 = x[, 1], x2 = x[, 2])
}
# Generazione dei dati per entrambi gli scenari
data1 <- generate_data(sigma1)
data2 <- generate_data(sigma2)
```

Stima dei modelli

Qui stimiamo due modelli di regressione OLS sui dati generati, per ciascuno dei due scenari:

- **Modello omesso** (`model1`): include solo x_1 come predittore. È il modello "sbagliato" perché ignora x_2, che nel DGP ha un effetto reale ($\beta_2 = -2$).
- **Modello completo** (`model2`): include entrambi x_1 e x_2. È il modello "corretto", specificato esattamente come il DGP.

La funzione `estimate_models` restituisce la stima di $\hat{\beta}_1$ da entrambi i modelli, così possiamo confrontarle direttamente. Questo confronto su un singolo campione è solo un assaggio: il cuore dell'analisi è la simulazione Monte Carlo nella sezione successiva.

```r
# Funzione per stimare i modelli
estimate_models <- function(data) {
    model1 <- lm(y ~ x1, data = data)
    model2 <- lm(y ~ x1 + x2, data = data)
    c(beta1_omitted = unname(coef(model1)["x1"]), beta1_full = unname(coef(model2)["x1"]))
}
# Stima dei modelli per entrambi gli scenari
results1 <- estimate_models(data1)
results2 <- estimate_models(data2)
results1
```

```
## beta1_omitted    beta1_full
##   -0.08429152    0.96008513
```

```r
results2
```

```
## beta1_omitted    beta1_full
##     0.9855369     0.9863139
```

Su questo singolo campione si può già osservare il fenomeno chiave: il modello completo recupera $\hat{\beta}_1 \approx 1$ in entrambi gli scenari, mentre il modello omesso produce una stima distorta nello **Scenario 1** (dove x_1 e x_2 sono correlati) e rimane circa corretta nello **Scenario 2** (variabili indipendenti). Tuttavia, un singolo campione non è sufficiente per trarre conclusioni generali, poiché il risultato potrebbe essere casuale. Per questo ricorriamo alla simulazione Monte Carlo.

Confronto delle distribuzioni Monte Carlo

L'idea della **simulazione Monte Carlo** è semplice: invece di guardare un solo campione, ripetiamo l'intero esperimento 20 000 volte. Ad ogni iterazione:

1. Generiamo un nuovo campione di $n = 1000$ osservazioni (sia per lo Scenario 1 che per lo Scenario 2).
2. Stimiamo i due modelli (omesso e completo) su ciascun campione.
3. Salviamo la stima $\hat{\beta}_1$ ottenuta da ciascun modello.

Al termine, per ognuno dei quattro casi (2 scenari $\times$ 2 modelli), abbiamo un vettore di 20 000 stime. La **distribuzione empirica** di questi vettori ci dice:

- **Dove è centrato lo stimatore**: se la media è vicina al valore vero $\beta_1 = 1$, lo stimatore è non distorto (*unbiased*).
- **Quanto è disperso**: la varianza della distribuzione riflette l'incertezza campionaria dello stimatore.

```r
# Simulazione Monte Carlo
n_sim <- 1000

# Vettori per salvare le stime di beta1
beta1_omitted_s1 <- c()
beta1_full_s1    <- c()
beta1_omitted_s2 <- c()
beta1_full_s2    <- c()
```

```r
for (i in 1:n_sim) {
    data1 <- generate_data(sigma1)
    data2 <- generate_data(sigma2)
    results1 <- estimate_models(data1)
    results2 <- estimate_models(data2)
    beta1_omitted_s1[i] <- results1["beta1_omitted"]
    beta1_full_s1[i]    <- results1["beta1_full"]
    beta1_omitted_s2[i] <- results2["beta1_omitted"]
    beta1_full_s2[i]    <- results2["beta1_full"]
}

c(beta1_omitted_s1 = round(mean(beta1_omitted_s1), 3),
    beta1_full_s1 = round(mean(beta1_full_s1), 3),
    beta1_omitted_s2 = round(mean(beta1_omitted_s2), 3),
    beta1_full_s2 = round(mean(beta1_full_s2), 3),
    beta_1 = beta_1)
```

```
## beta1_omitted_s1    beta1_full_s1 beta1_omitted_s2    beta1_full_s2
##            0.000            0.999            0.996            1.001
##           beta_1
##            1.000
```

```r
# Palette colori
col_fill_omit <- "#D3EDEC"   # azzurro chiaro  - modello con variabile omessa
col_fill_full <- "#D3EDEC"   # stesso fill, si distinguono per titolo/densità
col_dens_omit <- "#990F3D"   # rosso scuro     - curva densità modello omesso
col_dens_full <- "#0D7680"   # verde-teal      - curva densità modello completo
col_true      <- "#593380"   # viola           - linea valore vero

# Confronto delle distribuzioni
par(mfrow = c(2, 2), mar = c(4, 4, 3, 1))

# --- Scenario 1: Modello con variabile omessa ---
hist(beta1_omitted_s1,
     probability = TRUE,
     main = "Scenario 1: Omitted Variable",
     xlab = expression(hat(beta)[1]),
     col = col_fill_omit,
     border = "white",
     breaks = 30,
     xlim = c(min(beta1_omitted_s1), max(beta_1 + 0.2, max(beta1_omitted_s1))))
lines(density(beta1_omitted_s1), col = col_dens_omit, lwd = 2.5)
abline(v = beta_1, col = col_true, lwd = 2, lty = 2)
abline(v = mean(beta1_omitted_s1), col = col_dens_omit, lwd = 2, lty = 1)
legend("topright", legend = c("Densità", expression(beta[1] == 1),
    expression(E(hat(beta)[1]))), col = c(col_dens_omit, col_true, col_dens_omit),
    lty = c(1, 2, 1), lwd = 2, bty = "n", cex = 0.8)

# --- Scenario 1: Modello completo ---
hist(beta1_full_s1,
     probability = TRUE,
     main = "Scenario 1: Full Model",
     xlab = expression(hat(beta)[1]),
     col = col_fill_full,
     border = "white",
     breaks = 30)
lines(density(beta1_full_s1), col = col_dens_full, lwd = 2.5)
```

```r
abline(v = beta_1, col = col_true, lwd = 2, lty = 2)
abline(v = mean(beta1_full_s1), col = col_dens_full, lwd = 2, lty = 1)
legend("topright", legend = c("Densità", expression(beta[1] == 1),
    expression(E(hat(beta)[1]))), col = c(col_dens_full, col_true, col_dens_full),
    lty = c(1, 2, 1), lwd = 2, bty = "n", cex = 0.8)

# --- Scenario 2: Modello con variabile omessa ---
hist(beta1_omitted_s2,
     probability = TRUE,
     main = "Scenario 2: Omitted Variable",
     xlab = expression(hat(beta)[1]),
     col = col_fill_omit,
     border = "white",
     breaks = 30)
lines(density(beta1_omitted_s2), col = col_dens_omit, lwd = 2.5)
abline(v = beta_1, col = col_true, lwd = 2, lty = 2)
abline(v = mean(beta1_omitted_s2), col = col_dens_omit, lwd = 2, lty = 1)
legend("topright", legend = c("Densità", expression(beta[1] == 1),
    expression(E(hat(beta)[1]))), col = c(col_dens_omit, col_true, col_dens_omit),
    lty = c(1, 2, 1), lwd = 2, bty = "n", cex = 0.8)

# --- Scenario 2: Modello completo ---
hist(beta1_full_s2,
     probability = TRUE,
     main = "Scenario 2: Full Model",
     xlab = expression(hat(beta)[1]),
     col = col_fill_full,
     border = "white",
     breaks = 30)
lines(density(beta1_full_s2), col = col_dens_full, lwd = 2.5)
abline(v = beta_1, col = col_true, lwd = 2, lty = 2)
abline(v = mean(beta1_full_s2), col = col_dens_full, lwd = 2, lty = 1)
legend("topright", legend = c("Densità", expression(beta[1] == 1),
    expression(E(hat(beta)[1]))), col = c(col_dens_full, col_true, col_dens_full),
    lty = c(1, 2, 1), lwd = 2, bty = "n", cex = 0.8)
```

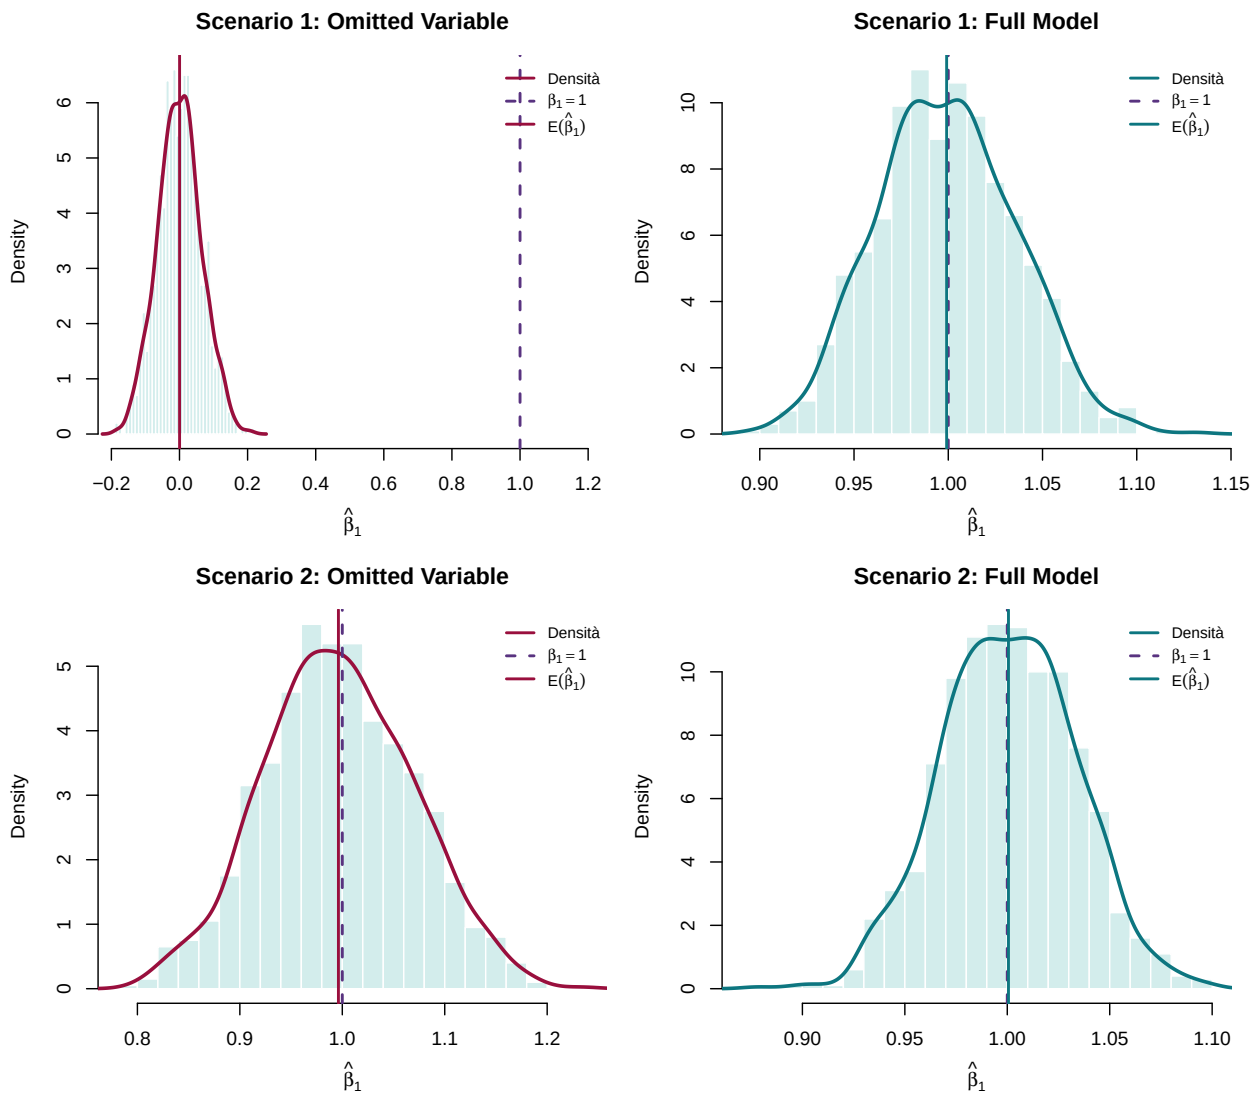

I quattro istogrammi mostrano la distribuzione Monte Carlo di $\hat{\beta}_1$ su 1000 simulazioni. La curva sovrapposta rappresenta la densità empirica stimata, mentre la linea tratteggiata viola indica il valore vero $\beta_1 = 1$.

Scenario 1 ($\text{Corr}(x_1, x_2) = 0.5$):

- *Modello con variabile omessa*: la distribuzione di $\hat{\beta}_1$ è centrata lontano dal valore vero. Poiché x_2 è correlata con x_1 e ha effetto negativo ($\beta_2 = -2$), l'omissione trasferisce parte dell'effetto di x_2 su $\hat{\beta}_1$, producendo una stima sistematicamente distorta verso il basso (**omitted variable bias**).
- *Modello completo*: la distribuzione è centrata sul valore vero $\beta_1 = 1$, confermando la consistenza dello stimatore OLS.

Scenario 2 ($\text{Corr}(x_1, x_2) = 0$):

- *Modello con variabile omessa*: la distribuzione rimane centrata sul valore vero. Quando le covariate sono ortogonali, l'omissione di x_2 non introduce bias su $\hat{\beta}_1$, pur aumentandone leggermente la varianza.
- *Modello completo*: distribuzione analoga allo Scenario 1, centrata su $\beta_1 = 1$.

Conclusione: il bias da variabile omessa si manifesta **solo quando la variabile esclusa è correlata con i regressori inclusi**. In assenza di correlazione, l'omissione non distorce le stime, ma riduce l'efficienza del modello.