Problema della Variabile Omessa

Simulazione Monte Carlo

Eros Pinzani

Impostare un esperimento di Monte Carlo per capire le conseguenze dell'omissione di una covariata rilevante.

<u>DGP</u>

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + u_i \tag{1}$$

$$\epsilon_i \sim N(0, 1) \tag{2}$$

$$x_1, x_2 \sim N_2(\underline{0}, \Sigma) \tag{3}$$

Nello scenario 1:

$$\Sigma = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix}$$

Nello scenario 2:

$$\Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Ad ogni simulazione:

1. Generare i dati da scenario 1
2. Stimare i parametri di un modello di regressione lineare con solo x_1 come predittore. Salvare la stima di β_1.
3. Stimare i parametri di un modello di regressione lineare con x_1 e x_2 come predittori. Salvare la stima di β_1.

Confrontare le distribuzioni Monte Carlo per i due scenari.
<u>Nota Bene</u>: Provare cosa succede al variare di β_1 e β_2. Provate ad esempio $\beta_1 = 1$ e $\beta_2 = -2$.

Obiettivo

In questo notebook costruiamo un esperimento di **Monte Carlo** — per vedere con i nostri occhi cosa succede quando si esclude dal modello una variabile rilevante.

Il modello "vero" che genera i dati (chiamato DGP, *Data Generating Process*) è:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + u_i$$

dove y_i è la variabile da spiegare, x_1 e x_2 sono i due predittori, $\beta_1 = 1$ e $\beta_2 = -2$ sono i loro effetti reali, e u_i è un termine di errore casuale. Il nostro obiettivo è stimare β_1 con due modelli diversi:

- un modello che include **solo** x_1 (il modello "sbagliato", che omette x_2),
- un modello che include **entrambe** x_1 e x_2 (il modello corretto).

Per capire quando l'omissione fa danni, confrontiamo due scenari che differiscono solo per la relazione tra le due variabili:

- **Scenario 1**: x_1 e x_2 sono **correlate** tra loro ($\rho = 0.5$): tendono a muoversi insieme, quindi ignorare x_2 "contamina" la stima di β_1.
- **Scenario 2**: x_1 e x_2 sono **indipendenti** ($\rho = 0$): non c'è nessun legame tra loro, quindi escludere x_2 non disturba la stima di β_1.

Generazione dei dati

Lavorare con dati simulati ha un grande vantaggio: **sappiamo già i valori veri** dei parametri, quindi possiamo controllare direttamente se le stime li recuperano. Nella realtà non conosciamo mai i valori veri — è proprio per questo che dobbiamo stimarli.

`set.seed(123)` fissa il punto di partenza del generatore di numeri casuali di R. Questo garantisce la **riproducibilità**: chiunque esegua il codice ottiene esattamente gli stessi numeri, i risultati non cambiano da un'esecuzione all'altra.

I parametri scelti per la simulazione sono:

- $n = 1000$: ogni campione simulato contiene 1000 osservazioni.
- $\beta_0 = 0$, $\beta_1 = 1$, $\beta_2 = -2$: gli effetti "veri" di ciascuna variabile. $\beta_1 = 1$ significa che aumentare x_1 di un'unità incrementa y di 1 (a parità di x_2). $\beta_2 = -2$ significa che x_2 ha un effetto negativo su y: se sale x_2, scende y.
- `sigma1` e `sigma2`: le **matrici di covarianza**, che descrivono la struttura di dipendenza tra x_1 e x_2. Una matrice di covarianza indica quale varianza ha ognuna delle due variabili e quanto sono correlate tra loro. Nello **Scenario 1** la correlazione è $\rho = 0.5$ (le due variabili sono parzialmente dipendenti), nello **Scenario 2** è $\rho = 0$ (completamente indipendenti).

La funzione `generate_data(sigma)` prende come input la matrice di covarianza ed esegue tre passi:

1. Campiona i valori di x_1 e x_2 dalla **distribuzione normale bivariata** — l'estensione a due dimensioni della classica "curva a campana" — con la struttura di correlazione specificata.
2. Genera l'errore casuale $u_i \sim N(0, 1)$: un rumore imprevedibile con media zero e varianza unitaria.
3. Calcola y applicando il DGP: $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u$.

```r
set.seed(123)
n <- 1000
beta_0 <- 0
beta_1 <- 1
beta_2 <- -2
sigma1 <- matrix(c(1, 0.5, 0.5, 1), nrow = 2)
sigma2 <- matrix(c(1, 0, 0, 1), nrow = 2)
library(MASS)
# Funzione per generare i dati
generate_data <- function(sigma) {
```

```r
    x <- mvrnorm(n, mu = c(0, 0), Sigma = sigma)
    u <- rnorm(n, mean = 0, sd = 1)
    y <- beta_0 + beta_1 * x[, 1] + beta_2 * x[, 2] + u
    data.frame(y = y, x1 = x[, 1], x2 = x[, 2])
}
# Generazione dei dati per entrambi gli scenari
data1 <- generate_data(sigma1)
data2 <- generate_data(sigma2)
```

Stima dei modelli

Una volta generato un campione, stimiamo β_1 usando la **regressione lineare OLS** (*Ordinary Least Squares*, minimi quadrati ordinari). OLS è il metodo più comune per stimare i coefficienti di un modello lineare: trova i valori di β che minimizzano la somma dei quadrati degli errori di previsione, cioè che fanno "aderire" il modello ai dati nel miglior modo possibile.

- **Modello omesso** (`model1`): regredisce y solo su x_1, ignorando completamente x_2.
- **Modello completo** (`model2`): regredisce y su x_1 e x_2, esattamente come il DGP vero.

La funzione `estimate_models` restituisce la stima di $\hat{\beta}_1$ da entrambi i modelli.

```r
# Funzione per stimare i modelli
estimate_models <- function(data) {
    model1 <- lm(y ~ x1, data = data)
    model2 <- lm(y ~ x1 + x2, data = data)
    c(beta1_omitted = unname(coef(model1)["x1"]), beta1_full = unname(coef(model2)["x1"]))
}
# Stima dei modelli per entrambi gli scenari
results1 <- estimate_models(data1)
results2 <- estimate_models(data2)
results1
```

```
## beta1_omitted    beta1_full
##   -0.08429152    0.96008513
```

```r
results2
```

```
## beta1_omitted    beta1_full
##     0.9855369     0.9863139
```

Su questo singolo campione si può già intravedere il fenomeno: il modello completo recupera $\hat{\beta}_1 \approx 1$ in entrambi gli scenari (è corretto), mentre il modello omesso produce una stima distorta nello **Scenario 1** (dove x_1 e x_2 sono correlate) e rimane circa corretta nello **Scenario 2** (variabili indipendenti).

Tuttavia, un singolo campione non basta per trarre conclusioni certe: il risultato che osserviamo potrebbe essere una coincidenza casuale. Per avere la certezza che quello che vediamo sia un fenomeno sistematico e ripetibile, dobbiamo ripetere l'esperimento tante volte. È esattamente quello che fa la simulazione Monte Carlo.

Confronto delle distribuzioni Monte Carlo

Cos'è una simulazione Monte Carlo?

La **simulazione Monte Carlo** è una tecnica che usa la ripetizione al posto del calcolo teorico. L'idea di base è semplice: se vogliamo sapere come si comporta uno stimatore "in media", basta farlo lavorare su tantissimi campioni diversi e guardare cosa otteniamo.

Immagina di ripetere questo esperimento 1000 volte:

1. Generiamo un nuovo campione da 1000 osservazioni (sia per lo Scenario 1 che per lo Scenario 2).
2. Stimiamo il modello omesso e il modello completo su ciascun campione.
3. Salviamo la stima $\hat{\beta}_1$ da entrambi i modelli.

Alla fine, per ognuno dei quattro casi (2 scenari $\times$ 2 modelli) abbiamo 1000 stime. La loro **distribuzione empirica** (l'istogramma di tutti questi valori) risponde direttamente alle domande:

- **Lo stimatore è distorto?** Se la media delle stime è diversa dal valore vero $\beta_1 = 1$, lo stimatore è **biased** (distorto). La distanza sistematica dal valore vero si chiama **bias** (o distorsione).
- **Quanto è preciso?** Quanto sono "sparse" le stime attorno alla loro media? Più è dispersa la distribuzione, meno preciso è lo stimatore.

```r
# Simulazione Monte Carlo
n_sim <- 1000

# Vettori per salvare le stime di beta1
beta1_omitted_s1 <- c()
beta1_full_s1    <- c()
beta1_omitted_s2 <- c()
beta1_full_s2    <- c()

for (i in 1:n_sim) {
    data1 <- generate_data(sigma1)
    data2 <- generate_data(sigma2)
    results1 <- estimate_models(data1)
    results2 <- estimate_models(data2)
    beta1_omitted_s1[i] <- results1["beta1_omitted"]
    beta1_full_s1[i]    <- results1["beta1_full"]
    beta1_omitted_s2[i] <- results2["beta1_omitted"]
    beta1_full_s2[i]    <- results2["beta1_full"]
}

# Palette colori
col_fill_omit <- "#D3EDEC"   # azzurro chiaro  - modello con variabile omessa
col_fill_full <- "#D3EDEC"   # stesso fill, si distinguono per titolo/densità
col_dens_omit <- "#990F3D"   # rosso scuro     - curva densità modello omesso
col_dens_full <- "#0D7680"   # verde-teal      - curva densità modello completo
col_true      <- "#593380"   # viola           - linea valore vero

c(beta1_omitted_s1 = round(mean(beta1_omitted_s1), 3),
    beta1_full_s1 = round(mean(beta1_full_s1), 3),
    beta1_omitted_s2 = round(mean(beta1_omitted_s2), 3),
    beta1_full_s2 = round(mean(beta1_full_s2), 3),
    beta_1 = beta_1)
```

```
## beta1_omitted_s1    beta1_full_s1 beta1_omitted_s2    beta1_full_s2
##            0.000            0.999            0.996            1.001
##           beta_1
##            1.000
```

Convergenza delle medie Monte Carlo

Prima di interpretare i risultati finali, è buona pratica verificare che la simulazione sia abbastanza lunga da produrre risultati **stabili**. I grafici di convergenza mostrano come evolve la media delle stime $\hat{\beta}_1$ all'aumentare del numero di iterazioni.

I due grafici mostrano questa convergenza separatamente per il **modello omesso** (in alto) e il **modello completo** (in basso). In entrambi:

- la **linea continua** = Scenario 1 ($\rho = 0.5$, variabili correlate),
- la **linea tratteggiata** = Scenario 2 ($\rho = 0$, variabili indipendenti),
- la **linea viola** = valore vero $\beta_1 = 1$ (il bersaglio).

Nel **modello omesso** (grafico in alto) si vede che la curva dello Scenario 1 si stabilizza intorno a 0, non a 1. Questo non è un errore casuale che scompare con più dati: è il **bias sistematico**. L'errore è strutturale — viene dal fatto che il modello è mal specificato. La formula esatta prevede:

$$\text{Bias}(\hat{\beta}_1) = \beta_2 \cdot \frac{\text{Cov}(x_1, x_2)}{\text{Var}(x_1)} = -2 \cdot 0.5 = -1$$

Il termine $\frac{\text{Cov}(x_1,x_2)}{\text{Var}(x_1)}$ misura quanto x_2 varia "insieme" a x_1: maggiore è la correlazione, maggiore è il bias. Poiché $\beta_2 = -2$, il modello omesso sottostima sistematicamente β_1, ottenendo $E[\hat{\beta}_1] = 1 + (-1) = 0$. La curva dello Scenario 2 invece converge correttamente a 1: senza correlazione tra le variabili, il meccanismo che causa il bias non scatta.

Nel **modello completo** (grafico in basso) entrambe le curve convergono rapidamente verso 1, a prescindere dallo scenario. Includere tutte le variabili rilevanti garantisce stime corrette.

```r
# Convergenza delle medie Monte Carlo al crescere delle iterazioni
iters          <- seq_len(n_sim)
cum_omitted_s1 <- cumsum(beta1_omitted_s1) / iters
cum_full_s1    <- cumsum(beta1_full_s1)    / iters
cum_omitted_s2 <- cumsum(beta1_omitted_s2) / iters
cum_full_s2    <- cumsum(beta1_full_s2)    / iters

par(mfrow = c(2, 1), mar = c(4, 4, 3, 2))
ylim_omit <- range(cum_omitted_s1, cum_omitted_s2, beta_1)
ylim_full <- range(cum_full_s1, cum_full_s2, beta_1)

# --- Convergenza: Modello con variabile omessa ---
plot(iters, cum_omitted_s1,
     type = "l", col = col_dens_omit, lwd = 1.5,
     ylim = ylim_omit,
     xlab = "Numero di iterazioni",
     ylab = expression(bar(hat(beta))[1]),
     main = "Convergenza: Modello Omesso")
lines(iters, cum_omitted_s2, col = col_dens_omit, lwd = 1.5, lty = 2)
abline(h = beta_1, col = col_true, lwd = 2, lty = 2)
legend("topright",
       legend = c("Scenario 1", "Scenario 2", expression(beta[1] == 1)),
       col = c(col_dens_omit, col_dens_omit, col_true),
       lty = c(1, 2, 2), lwd = 2, bty = "n", cex = 0.8)

# --- Convergenza: Modello completo ---
plot(iters, cum_full_s1,
     type = "l", col = col_dens_full, lwd = 1.5,
     ylim = ylim_full,
     xlab = "Numero di iterazioni",
     ylab = expression(bar(hat(beta))[1]),
     main = "Convergenza: Modello Completo")
lines(iters, cum_full_s2, col = col_dens_full, lwd = 1.5, lty = 2)
abline(h = beta_1, col = col_true, lwd = 2, lty = 2)
legend("topright",
       legend = c("Scenario 1", "Scenario 2", expression(beta[1] == 1)),
       col = c(col_dens_full, col_dens_full, col_true),
       lty = c(1, 2, 2), lwd = 2, bty = "n", cex = 0.8)
```

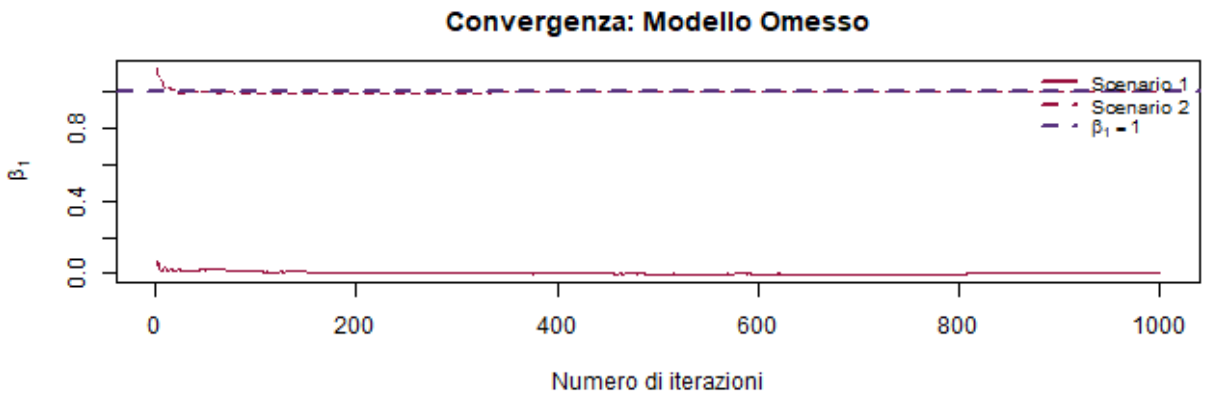

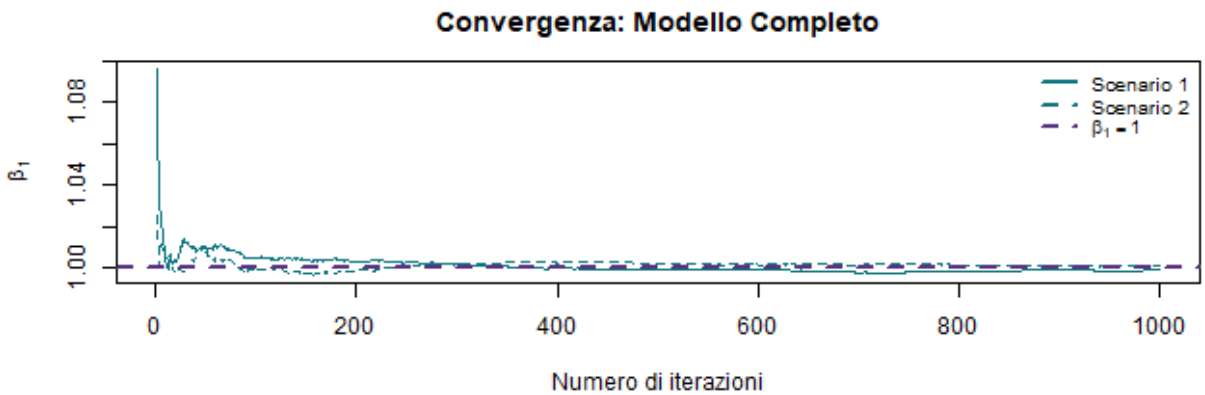

Distribuzioni degli stimatori

Una volta verificata la convergenza, possiamo analizzare la **forma completa** delle distribuzioni Monte Carlo. I quattro istogrammi organizzano le 1000 stime $\hat{\beta}_1$ per scenario (righe) e per tipo di modello (colonne), e ci permettono di vedere non solo dove è centrata la distribuzione, ma anche quanto è ampia e simmetrica.

Come leggere ogni grafico:

- **Le barre dell'istogramma**: ogni barra indica quante volte (su 1000 simulazioni) la stima $\hat{\beta}_1$ è caduta in quell'intervallo di valori. Più alta è la barra, più spesso lo stimatore ha prodotto quel risultato.
- **La curva sovrapposta**: è la densità di probabilità stimata, cioè una versione levigata dell'istogramma che mostra la "forma" complessiva della distribuzione.
- **La linea viola tratteggiata**: indica il valore vero $\beta_1 = 1$ — il nostro bersaglio.
- **La linea continua colorata**: indica la media delle 1000 stime, cioè dove lo stimatore "punta" in media.

Se la linea colorata e la linea viola coincidono, lo stimatore è non distorto: in media centra il bersaglio. Se sono distanti, lo stimatore è biased: manca sistematicamente il bersaglio nella stessa direzione.

```
# Confronto delle distribuzioni
par(mfrow = c(2, 2), mar = c(4, 4, 3, 1))

# --- Scenario 1: Modello con variabile omessa ---
hist(beta1_omitted_s1,
     probability = TRUE,
     main = "Scenario 1: Omitted Variable",
     xlab = expression(hat(beta)[1]),
     col = col_fill_omit,
     border = "white",
     breaks = 30,
```

```r
     xlim = c(min(beta1_omitted_s1), max(beta_1 + 0.2, max(beta1_omitted_s1))))
lines(density(beta1_omitted_s1), col = col_dens_omit, lwd = 2.5)
abline(v = beta_1, col = col_true, lwd = 2, lty = 2)
abline(v = mean(beta1_omitted_s1), col = col_dens_omit, lwd = 2, lty = 1)
legend("topright", legend = c("Densità", expression(beta[1] == 1),
    expression(E(hat(beta)[1]))), col = c(col_dens_omit, col_true, col_dens_omit),
    lty = c(1, 2, 1), lwd = 2, bty = "n", cex = 0.8)

# --- Scenario 1: Modello completo ---
hist(beta1_full_s1,
     probability = TRUE,
     main = "Scenario 1: Full Model",
     xlab = expression(hat(beta)[1]),
     col = col_fill_full,
     border = "white",
     breaks = 30)
lines(density(beta1_full_s1), col = col_dens_full, lwd = 2.5)
abline(v = beta_1, col = col_true, lwd = 2, lty = 2)
abline(v = mean(beta1_full_s1), col = col_dens_full, lwd = 2, lty = 1)
legend("topright", legend = c("Densità", expression(beta[1] == 1),
    expression(E(hat(beta)[1]))), col = c(col_dens_full, col_true, col_dens_full),
    lty = c(1, 2, 1), lwd = 2, bty = "n", cex = 0.8)

# --- Scenario 2: Modello con variabile omessa ---
hist(beta1_omitted_s2,
     probability = TRUE,
     main = "Scenario 2: Omitted Variable",
     xlab = expression(hat(beta)[1]),
     col = col_fill_omit,
     border = "white",
     breaks = 30)
lines(density(beta1_omitted_s2), col = col_dens_omit, lwd = 2.5)
abline(v = beta_1, col = col_true, lwd = 2, lty = 2)
abline(v = mean(beta1_omitted_s2), col = col_dens_omit, lwd = 2, lty = 1)
legend("topright", legend = c("Densità", expression(beta[1] == 1),
    expression(E(hat(beta)[1]))), col = c(col_dens_omit, col_true, col_dens_omit),
    lty = c(1, 2, 1), lwd = 2, bty = "n", cex = 0.8)

# --- Scenario 2: Modello completo ---
hist(beta1_full_s2,
     probability = TRUE,
     main = "Scenario 2: Full Model",
     xlab = expression(hat(beta)[1]),
     col = col_fill_full,
     border = "white",
     breaks = 30)
lines(density(beta1_full_s2), col = col_dens_full, lwd = 2.5)
abline(v = beta_1, col = col_true, lwd = 2, lty = 2)
abline(v = mean(beta1_full_s2), col = col_dens_full, lwd = 2, lty = 1)
legend("topright", legend = c("Densità", expression(beta[1] == 1),
    expression(E(hat(beta)[1]))), col = c(col_dens_full, col_true, col_dens_full),
    lty = c(1, 2, 1), lwd = 2, bty = "n", cex = 0.8)
```

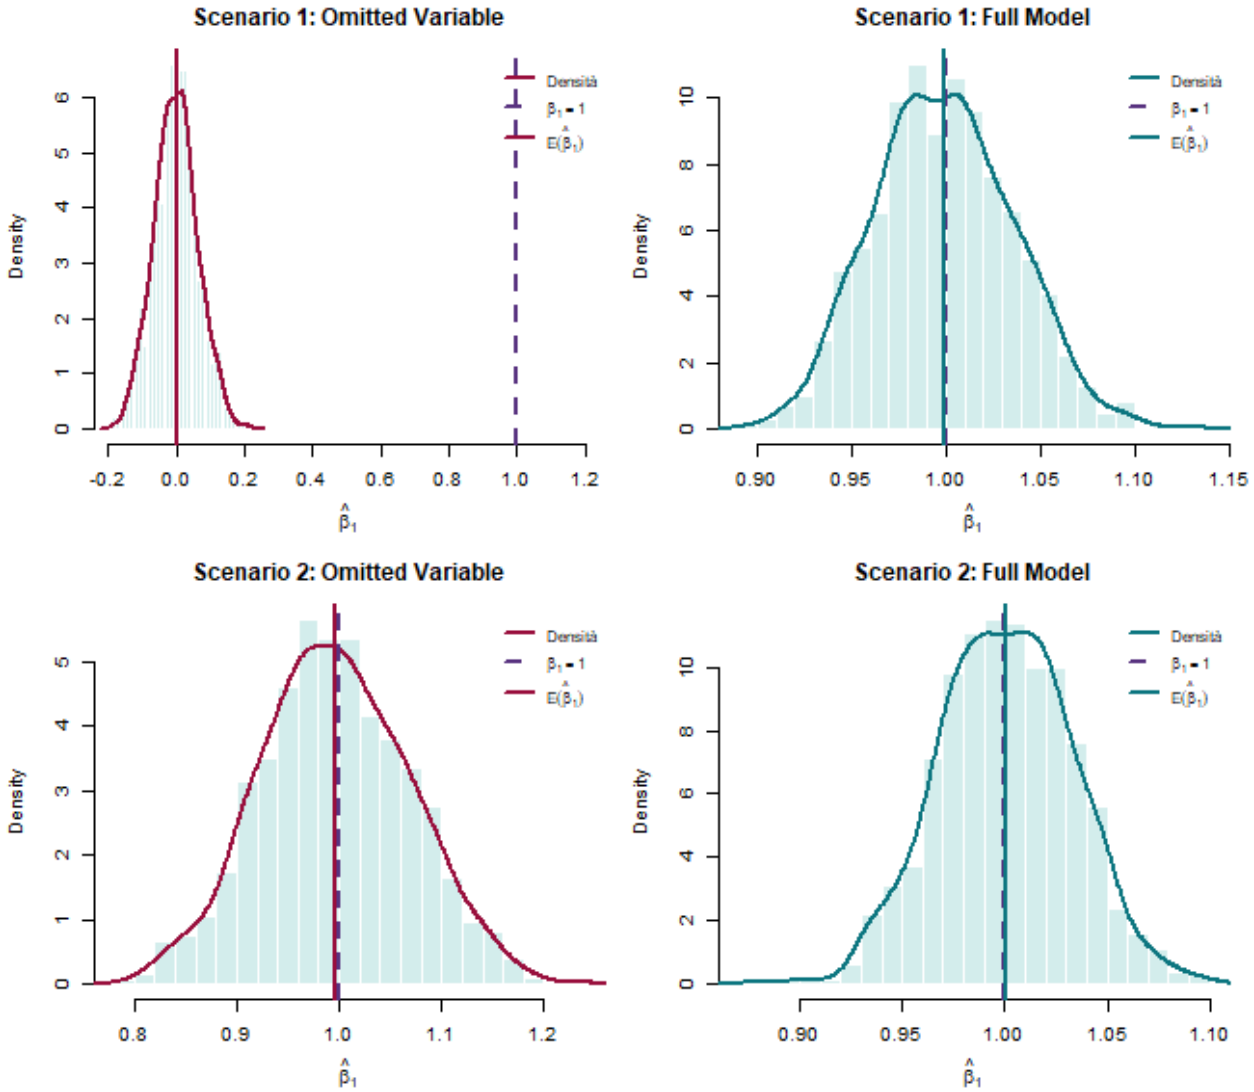

I grafici confermano esattamente quello che la teoria prevede.

Scenario 1 (le due variabili sono correlate, $\rho = 0.5$):

- *Modello omesso* (in alto a sinistra): la distribuzione è centrata intorno a 0, lontana dal valore vero $\beta_1 = 1$. Perché accade questo? Perché x_2 ha un effetto su y ($\beta_2 = -2$) e allo stesso tempo è correlata con x_1. Quando escludiamo x_2 dal modello, il coefficiente di x_1 deve "farsi carico" anche dell'effetto di x_2: siccome quest'ultima ha un effetto negativo ($\beta_2 < 0$) e le due variabili sono correlate positivamente, la stima di β_1 viene trascinata verso il basso. Il bias non è casuale: è sistematico e prevedibile dalla formula teorica.
- *Modello completo* (in alto a destra): la distribuzione è centrata su 1 — la stima è corretta. Includere x_2 elimina completamente il bias.

Scenario 2 (le due variabili sono indipendenti, $\rho = 0$):

- *Modello omesso* (in basso a sinistra): la distribuzione è centrata su 1, nonostante x_2 sia assente dal modello. Qui il bias non compare perché x_1 e x_2 non si "confondono" a vicenda: dal momento che non c'è correlazione tra di loro, escludere x_2 non disturba la stima di β_1. Si può notare però che la distribuzione è leggermente più larga rispetto al modello completo: escludere una variabile rilevante aumenta l'errore casuale del modello, rendendolo meno preciso (anche se non distorto).

- *Modello completo* (in basso a destra): risultato quasi identico allo Scenario 1 — la distribuzione è centrata su 1 e ben concentrata.

Conclusione generale: il bias da variabile omessa non compare sempre. Compare solo se la variabile esclusa soddisfa *entrambe* le condizioni seguenti:

1. Ha un **effetto reale** sulla variabile dipendente ($\beta_2 \neq 0$) — se la variabile omessa non conta, non può creare danni.
2. È **correlata** con almeno uno dei predittori inclusi nel modello — se è indipendente, non "contamina" le altre stime.

Se anche una sola delle due condizioni non è soddisfatta, l'omissione non distorce le stime. Tuttavia, escludere una variabile rilevante riduce sempre la precisione delle stime, aumentando la loro variabilità.